



FRIEDRICH-SCHILLER-
UNIVERSITÄT
JENA

FRIEDRICH-SCHILLER-UNIVERSITÄT JENA

FAKULTÄT FÜR MATHEMATIK UND INFORMATIK

Social Media Daten

— Use Cases, Beschaffung und Speicherung sowie praktische Umsetzung am Beispiel von Veröffentlichungen zum Themenfeld Wasser in den Netzwerken BlueSky und Mastodon

Bachelorarbeit zur Erlangung des akademischen Grades
Bachelor of Science (B.Sc.) im Studiengang Informatik

Von
Julia Boden

Gutachter:
Prof. Dr. Birgitta König-Ries

Betreuer:
Divyasha Sunil Naik,
Leila Feddoul

LEHRSTUHL FÜR VERTEILTE INFORMATIONSSYSTEME

AUGUST 2024

Kurzfassung

Soziale Netzwerke werden zunehmend als Datenquelle für Studien in Anwendungsbereichen wie Marketing, Politik, Gesundheitswesen und vielen weiteren herangezogen. Die Twitter-API wurde dafür bislang häufig als einzige Datenquelle verwendet. Seit der Kommerzialisierung dieser im Jahr 2023 wurden allerdings schon einige Forschungsprojekte, die auf Twitter-Daten basieren sollten, abgebrochen. In dieser Arbeit wird deswegen primär die Möglichkeit untersucht, Inhalte zum Themenbereich „Wasser“ aus den Social-Media-Plattformen BlueSky und Mastodon, die als Alternativen zu Twitter bekannt sind, vereinheitlicht in einer MySQL-Datenbank zu speichern. So können Informationen aus beiden Plattformen als Datengrundlage genutzt werden. Dafür müssen auch rechtliche Aspekte bezüglich Verwendung personenbezogener Daten berücksichtigt werden.

Um Informationen beider Plattformen im selben Format zu speichern, wurden zunächst die Response-Schemata der API-Endpunkte verglichen, die nutzergenerierte Beiträge mit bestimmten enthaltenen Schlüsselwörtern zurückgeben. Für jede Eigenschaft in diesen Schemata wurde untersucht, ob sie im Response-Schema der anderen Plattform vorhanden ist und ob die Information für zuvor mittels Literaturrecherche herausgearbeitete Anwendungsfälle im Kontext Wassermanagement relevant ist. Je nach Relevanz entsprechender Information für diese Anwendungsfälle wurde entschieden, ob sie in die Datenbank aufgenommen wird. Anschließend wurde ein passendes Datenbankschema entwickelt. Einträge in die Datenbank wurden mittels der verwendeten API-Endpunkte der Plattformen vorgenommen.

Danksagung

Für die Ermöglichung der Bachelorarbeit im Fachbereich Informatik der Friedrich-Schiller-Universität Jena und der Bereitstellung dieser zeitgemäßen Aufgabenstellung danke ich insbesondere Frau Prof. König-Ries und meinen Betreuerinnen Divyasha Sunil Naik sowie Leila Feddoul. Ihre Rückmeldungen auf Fragen meinerseits erfolgten meistens innerhalb weniger Minuten und waren stets konstruktiv.

Außerdem danke ich den Mitgliedern der FUSION-Gruppe, also der Forschungsgruppe in der diese Arbeit geschrieben wurde, für die ständige Hilfsbereitschaft während der wöchentlichen Meetings und die stets angenehme Arbeitsatmosphäre. Besonders hervorheben möchte ich auch das mehrtägige Retreat der FUSION-Gruppe, an dem ich teilnehmen durfte. Die spannenden Workshops, z.B. zu den Anwendungsmöglichkeiten von Künstlicher Intelligenz in wissenschaftlichen Arbeiten, haben mir neue und wertvolle Kenntnisse vermittelt, die ich direkt beim Schreiben der vorliegenden Arbeit anwenden konnte.

Inhaltsverzeichnis

Abbildungsverzeichnis	III
Tabellenverzeichnis	V
Abkürzungsverzeichnis	VI
1 Einleitung	1
1.1 Motivation	1
1.2 Einordnung in das ThWIC-SONAR-Projekt und Vorgehen	2
2 Thematisch angrenzende Forschungsbeiträge	4
3 Begriffsklärungen	5
3.1 Soziale Medien	5
3.2 Soziale Netzwerke	5
3.3 Social Media Daten	6
4 Use Cases von Social Media Daten	7
4.1 Gängige Anwendungsbereiche und Analysemethoden	7
4.1.1 Katastrophenmanagement	8
4.1.2 Landwirtschaft	9
4.1.3 Ethik	9
4.1.4 Regierung	9
4.1.5 Gesundheitsversorgung	10
4.1.6 Bildung	11
4.2 Eingesetzte Social Media Netzwerke	11
5 Rechtliche Fragestellungen zur Verarbeitung von Daten aus Sozialen Medien	13
5.1 Relevante Regelwerke und Begriffsklärungen	13
5.1.1 Relevante Regelwerke: DSGVO, BDSG, Landesdatenschutzgesetze	13
5.1.2 Begriffsklärungen gemäß DSGVO und BDSG	14
5.2 Erlaubnistatbestände zur Verarbeitung personenbezogener Daten	14
5.2.1 Einwilligung der betroffenen Person	14
5.2.2 Verarbeitung personenbezogener Daten	16

5.2.3	Verarbeitung besonderer Kategorien personenbezogener Daten	17
5.3	Zusammenfassung geeigneter Maßnahmen	20
6	Projekt: Datenbankentwurf	22
6.1	Verwendete Plattformen	22
6.1.1	Mastodon und BlueSky	22
6.1.2	Verwendete Such-Endpunkte	23
6.1.3	Föderation	23
6.2	Response-Schemata	24
6.2.1	Mastodon	24
6.2.2	BlueSky	28
6.3	Vereinheitlichung der Response-Schemata	30
6.3.1	Informationen zum Beitrag	31
6.3.2	Weitere Informationen über den Beitrag	36
6.3.3	Account-Informationen	37
6.3.4	Medienanhänge	42
6.3.5	Erwähnungen anderer Nutzer	43
6.3.6	Hashtags	44
6.3.7	Emojis	44
6.3.8	Voransichten von Webseiten	44
6.3.9	Umfrage	44
6.3.10	Zusammenfassung: für das ThWIC-Projekt verwendete Merkmale	45
6.3.11	Zusätzliche Informationen für die ThWIC-Datenbank	50
6.4	Vereinheitlichtes Datenbankschema	50
6.4.1	Entwurf des Datenbankschemas	50
6.4.2	Kritik: Vergleichbarkeit von Mastodon- und BlueSky-Beiträgen	55
6.5	Ausblick: Weiterentwicklungsmöglichkeiten	56
7	Schlussbetrachtung	59
	Literaturverzeichnis	VII
	Anhang	XVI

Abbildungsverzeichnis

1.1	ThWIC-SONAR Projekt	2
6.1	Datenbankschema als EER-Diagramm	53
1	Erstellung eines Mastodon-Beitrags mit Sichtbarkeitsstufe „quiet public“ („unlisted“) . . .	XVI
2	Mastodon-Beitrag mit „unlisted“ Sichtbarkeitsstufe wird öffentlich aufgefunden	XVIII
3	Beispiel für einen Mastodon-Beitrag („Post“)	XX
4	Die primäre Sprache eines Mastodon-Beitrags ist per default Englisch	XXI
5	Festgelegte Sprache für einen Beitrag wird von Mastodon nicht überprüft	XXI
6	Die primäre Sprache eines BlueSky-Beitrags ist per default Englisch	XXII
7	Festgelegte Sprache für einen Beitrag wird von BlueSky nicht überprüft	XXII
8	Eigener Mastodon-Beitrag wurde geboostet	XXIII
9	Reposts erscheinen nicht in Mastodon Suche	XXIII
10	Profil in Mastodon erstellen: Beschreibung („Bio“) und Metadaten („Extra fields“) werden separat angegeben	XXIII
11	Erstellung eines Mastodon-Beitrags, der für ein Experiment wieder gelöscht wird	XXIV
12	Erstellter Beitrag wurde über Such-Request aufgefunden	XXIV
13	Mastodon-Beitrag löschen	XXV
14	Mastodon-Beitrag wurde tatsächlich gelöscht	XXV
15	Delete & re-draft: Mastodon-Beitrag erstellen	XXV
16	Mastodon-Beitrag mit Such-Endpunkt aufgefunden	XXVI
17	Delete & re-draft: Mastodon-Beitrag	XXVI
18	Delete & re-draft: Warnung	XXVII
19	Re-drafting des Mastodon-Beitrags	XXVII
20	Delete & re-draft: ursprünglicher Beitrag nicht mehr auffindbar	XXVII
21	Delete & re-draft: neuer Beitrag ist über Keyword-Suche auffindbar	XXVIII
22	Delete & re-draft: ursprünglicher Beitrag nicht auffindbar	XXVIII
23	Migrating: Test Account erstellt	XXIX
24	Migrating: Beitrag erstellen	XXIX
25	Migrating: Beitrag ist auffindbar	XXX
26	Migrating: Alias erstellen	XXX
27	Migrating	XXXI

28	Migrating: moved-Informationen werden angezeigt	XXXII
29	Migrating: ID nicht gefunden	XXXII
30	Migrating: unterschiedliche IDs	XXXIII
31	Migrating: Such-Endpunkt kann noch verwendet werden	XXXIV
32	Migrating: Account mit ursprünglicher Domain auffindbar	XXXV
33	Migrating: Informationen mittels ursprünglicher Domain und ID	XXXVI
34	SQL-Befehle zum Erstellen der Datenbank	XXXVIII

Tabellenverzeichnis

4.1	Häufig verwendete Social Media Netzwerke	11
5.1	Maßnahmen und Möglichkeiten zur Umsetzung	21
6.1	Informationen zum Beitrag: ausgewählte Merkmale für die Datenbank	47
6.2	Account-Informationen: ausgewählte Merkmale für die Datenbank	48
6.3	Medienanhänge: ausgewählte Merkmale für die Datenbank	48
6.4	Erwähnungen anderer Nutzer: ausgewählte Merkmale für die Datenbank	49
6.5	Hashtags: ausgewählte Merkmale für die Datenbank	49
6.6	Umfrage: ausgewählte Merkmale für die Datenbank	50
6.7	Vergleich von Mastodon- und Bluesky-Beiträgen	55
1	Schlüsselwörter, Themen und Kategorien im ThWIC-Projekt	XVI

Abkürzungsverzeichnis

Abkürzung	Beschreibung
Abs.	Absatz
API	Application Programming Interfaces (Programmierschnittstellen)
Art.	Artikel
BDSG	Bundesdatenschutzgesetz
bzgl.	bezüglich
bzw.	beziehungsweise
CID	Content Identifier
DID	Decentralized Identifier
DSGVO	Datenschutz-Grundverordnung
e.g.	zum Beispiel
EU	Europäische Union
evtl.	eventuell
FSU Jena	Friedrich-Schiller-Universität Jena
ggf.	gegebenenfalls
GUI	Graphical User Interface
HTML	Hypertext Markup Language
HTTP	Hypertext Transfer Protocol
ID	Identität
i.d.R.	in der Regel
jwl.	jeweils
Kap.	Kapitel
LDSG	Landesdatenschutzgesetz
lit.	Literal (Buchstabe)
LLM	Large Language Model
NSID	Namespaced Identifiers
sog.	sogenannte
Tab.	Tabelle
ThWIC	Thüringer Wasser-Innovationscluster
u.a.	unter anderen
URI	Unified Resource Identifier
URL	Uniform Resource Locator
vgl.	vergleiche
z.B.	zum Beispiel

1 Einleitung

1.1 Motivation

Immer wieder werden durch Inhalte aus den Sozialen Medien Missstände sowie Informationen über gesellschaftliche Themen aufgedeckt und führen zu öffentlichen Diskussionen und Veränderungen. Bereits 2014 spielten Soziale Netzwerke eine entscheidende Rolle bei der Informationsgewinnung über den Abschuss des Malaysia Airlines Flug MH 17 über der Ostukraine.¹ Dazu konnte z.B. Bellingcat, ein internationales Recherchekollektiv das zu unterschiedlichen Themen Open-Source-Recherchen durchführt,² mittels Smartphone-Fotos aus Sozialen Medien und Satellitenbildern nahezu lückenlos zeigen, wie die Flugabwehrbatterie in die Ostukraine transportiert wurde, am Abschussort stationiert wurde und mit geringerer Raketenbestückung direkt nach dem Abschuss nach Russland gebracht wurde.³ Bereits damals wurde also ein komplexer und internationaler Vorfall nahezu in Echtzeit „dokumentiert“, sodass entscheidende Details aufgeklärt werden konnten.

Mittlerweile wurde den Menschen durch weiteren technologischen Fortschritt in den meisten Ländern der ständige Zugang zum Internet ermöglicht, sodass rund fünf Milliarden Menschen weltweit als Nutzer sozialer Medien gelten.⁴ Durch diese weit verbreitete Nutzung sozialer Medien werden riesige Datenmengen generiert, die insbesondere für Regierungen, Unternehmen und Sozialwissenschaftler von Interesse sind.⁵ Typische Forschungsbereiche umfassen hierbei z.B. Marketing, Tourismus und Krisenmanagement.⁶

Eine Studie dazu zeigt allerdings auch, dass an Universitäten für solche Projekte häufig lediglich ein einziges Social Media Netzwerk zur Informationsbeschaffung und für Analysen genutzt wird,⁷ obwohl das Analysieren mehrerer Netzwerke besonders im sozialwissenschaftlichen Bereich empfohlen wird.⁸

ThWIC („Thüringer Wasser-Innovationscluster“) bezeichnet ein interdisziplinäres Forschungsprojekt, in dem innovative Lösungen für nachhaltiges Wassermanagement erarbeitet und verwirklicht werden, um globale Probleme hinsichtlich Wasserknappheit sowie damit verbundene Konfliktpotenziale zu adressieren.⁹ Es beinhaltet ein Teilprojekt, „ThWIC-SONAR“, in dem ein Large Language Model („LLM“) entwickelt wird, das speziell zum Themenbereich Wasser trainiert wird. Die Antworten dieses LLMs sollen zudem nicht nur durch Empfehlungen von wissenschaftlichen Dokumenten sowie Nachrichten gestützt sein, sondern ggf. auch durch zur Anfrage passenden Social Media Beiträgen aus verschiedenen Netzwerken. Dafür müssen diese Inhalte aus unterschiedlichen Social

¹Vgl. o.V. (o.J.): MH17 Die Beweise aus öffentlichen Quellen, S. 1ff.

²Vgl. o.V. (o.J.): Bellingcat auf Deutsch, Bellingcat, Abrufdatum: 28.06.2024.

³Haric, P./Grüblbauer, J. (12.03.2016): Geopolitische Herausforderungen digitaler Souveränität im neo-imperialen Zeitalter und die Bedeutung von Qualitätsmedien, S. 174.

⁴Vgl. o.V. (31.07.2024): Social Media Trends – Welche Plattformen sind am beliebtesten, Statista, Abrufdatum: 01.08.2024.

⁵Vgl. Felt, M. (29.04.2016): Social media and the social sciences: How researchers employ Big Data analytics, S. 1.

⁶Vgl. Zachlod, C. et al. (2022): Analytics of social media data - State of characteristics and application, S. 1.

⁷Vgl. Hemphill, L./Hedstrom, M./Leonard, S. (6.5.2019): How can we save social media data, S. 9.

⁸Vgl. Felt, M. (29.04.2016): Social media and the social sciences: How researchers employ Big Data analytics, S. 3.

⁹Vgl. o.V. (o.J.): Thüringer Wasser-Innovationscluster, Friedrich-Schiller-Universität Jena, Abrufdatum: 14.06.2024.

Media Netzwerken zunächst gesammelt und in einem sinnvollen und vereinheitlichten Format gespeichert werden.

1.2 Einordnung in das ThWIC-SONAR-Projekt und Vorgehen

Die folgende Abbildung gibt einen groben Überblick über das ThWIC-SONAR-Projekt. Der darin rot markierte Bereich zeigt die Einordnung der vorliegenden Arbeit.




Abbildung 1.1: ThWIC-SONAR Projekt

Primäre Zielsetzung des ThWIC-SONAR-Projekts ist es, ein auf den Themenbereich Wasser spezialisiertes LLM zu entwickeln, das ein effizienteres Wassermanagement unterstützt. Bei diesem soll von den Usern nicht nur ein Modus für dessen Antwort, nämlich ausschweifend (explorativ) oder zielgerichtet (strict) wählbar sein, sondern es sollen auch zur Antwort passende und vom System empfohlene Quellenangaben, wie Publikationen oder Social Media Beiträge, mit ausgegeben werden können. Dabei wird die Entwicklung des LLMs von dem Unternehmen „Epic Insights“ vorgenommen. Die Sammlung von Daten aus verschiedenen Quellen und deren weitere Nutzung, beispielsweise für Analysen oder zur Entwicklung eines Knowledge-Graphs zum Thema Wasser, erfolgt durch die FSU Jena.

Zielstellung dieser Arbeit ist es dabei, Social Media Daten, insbesondere Beiträge von Usern, aus verschiedenen Plattformen zu sammeln sowie in einem vereinheitlichten und für das ThWIC-SONAR-Projekt sinnvollen Format zu speichern. Für die Datensammlung aus anderen Quellen wurden von der Universität bereits einige Schlüsselwörter mit Einordnung dieser in grobe Themengebiete sowie spezifischere Kategorien ermittelt. Diese wurden auch für die Datensammlung aus Sozialen Medien zur Verfügung gestellt. Ein Teil dieser Schlüsselwortsammlung ist der Übersicht halber im Anhang hinterlegt (vgl. Tab. 1).

Insgesamt wird in dem vorliegenden Dokument die Vorbereitung der Datensammlung behandelt. Das Vorgehen für die eigentliche Datensammlung und Speicherung kann dem beiliegenden Code entnommen werden.

Da Social Media Daten das ThWIC-Projekt ggf. nicht lediglich durch Verwendung im LLM unterstützen können, wird zunächst mittels Literaturrecherche über gängige Anwendungsmöglichkeiten von Social Media Daten informiert. Daraus werden mögliche weitere Use Cases für das ThWIC-Projekt abgeleitet. Außerdem wird hierbei

analysiert, welche Daten zur Erfüllung dieser Use Cases benötigt werden. Bevor anschließend mit der Datensammlung begonnen wird, müssen rechtliche Fragestellungen bzgl. der Verwendung von personenbezogenen Daten geklärt werden. Ein wichtiger Punkt ist auch die nähere Betrachtung der beiden zu verwendenden Social Media Plattformen BlueSky und Mastodon. Es wird eine Erläuterung zu deren relevanten API-Endpunkten zur Sammlung der Daten vorgenommen.

Anschließend werden die den Response-Schemata der Endpunkte zu entnehmenden Informationen erklärt. Für diese Daten wird jeweils geprüft, ob sie für das ThWIC-Projekt von Relevanz sind und ob sich entsprechende Informationen mit Daten der anderen Plattform vergleichen und vereinheitlicht speichern lassen. Aus den relevanten Informationen wird letztlich ein MySQL-Datenbankschema entworfen. Die Einträge in die Datenbank werden durch Extraktion der Daten aus den API-Responses der verwendeten Endpunkte vorgenommen. Dieser Schritt kann im beigefügten Code nachvollzogen werden.

Zuletzt erfolgt eine kritische Auseinandersetzung über die Verwendung und den Vergleich beider Social Media Plattformen innerhalb einer Datenanalyse bzw. einem ThWIC-bezogenen Use Case. Außerdem wird ein kurzer Ausblick über Weiterentwicklungsmöglichkeiten der Datenbank gegeben.

2 Thematisch angrenzende Forschungsbeiträge

Dieses Kapitel gibt eine Übersicht über veröffentlichte Forschungsbeiträge, die einen thematischen Bezug zur vorliegenden Arbeit haben.

Kankanamge et al. (2020) nutzten Social Media Daten bereits im Kontext Wasser. Sie sammelten Echtzeit-Twitter-Daten aus den Jahren 2010 bis 2011, um den Katastrophenschweregrad bei Überschwemmungen im Zeitverlauf zu bestimmen sowie zur Identifikation besonders betroffener Gebiete. Der Katastrophenschweregrad und die Auswirkungen wurden durch Meinungen und Wahrnehmungen lokaler Gemeinschaften interpretiert.¹

In einem Review-Artikel von Zachlod, C. et al. (2022) wurden 94 Veröffentlichungen aus den Jahren 2017 bis 2020 über Social Media Analysen hinsichtlich Anwendungsbereichen von Social Media Daten, eingesetzten Social Media Plattformen und Methoden zusammengefasst und analysiert.²

Hemphill, L. et al. (2019) untersuchten aktuelle Ansätze zur Anwendung und Speicherung von Social Media Daten. Sie stellten dabei auch für Social Media Daten spezifische Eigenschaften und damit einhergehende Problematiken bei deren Verwendung heraus.³

Das Prinzip, Social Media Daten aus unterschiedlichen Plattformen zu sammeln, wurde von Sing, P. et al. (2019) untersucht. Sie schlagen vor, die gewonnenen Daten in einer Cloud-Datenbank zu speichern. In ihrem Projekt verwendeten sie letztlich allerdings nur Twitter-Daten. Dadurch konnte die indische Regierung die Stimmung einiger Bürger beeinflussen und durch ortsbasierte Analysen konnten Maßnahmen für bestimmte Zielgruppen ergriffen werden.⁴

Von Wiegmann, M. et al. (2024) wurden Social Media Daten aus insgesamt 1.015 Mastodon Instanzen gesammelt. Dafür wurden die neuen Such-Funktionen von Mastodon verwendet, die erst seit September 2023 öffentlich zugänglich sind.⁵

Rechtliche Aspekte zur Verwendung von Social Media Daten für Forschungszwecke wurden von Golla, S. et al. (2018) untersucht. Es wurden relevante Gesetze aus der DSGVO und dem BDSG identifiziert und erläutert.⁶

¹Vgl. Kankanamge, N. et al. (2020): Determining disaster severity through social media analysis: Testing the methodology with South East Queensland Flood tweets.

²Vgl. Zachlod, C. et al. (2022): Analytics of social media data - State of characteristics and application.

³Vgl. Hemphill, L./Hedstrom, M./Leonard, S. (6.5.2019): How can we save social media data?

⁴Vgl. Singh, P. et al. (16.04.2019): Smart Monitoring and Controlling of Government Policies Using Social Media and Cloud Computing.

⁵Vgl. Wiegmann, M. et al. (2024): A Mastodon Corpus to Evaluate Federated Microblog Search.

⁶Vgl. Golla, S./Hofmann, H./Bäcker, M. (28.01.2018): Connecting the Dots.

3 Begriffsklärungen

Im Folgenden werden die Begriffe „Soziale Medien“, „Soziale Netzwerke“ und „Social Media Daten“ erklärt. Dabei wird auch eine Abgrenzung des in dieser Arbeit behandelten Themenbereichs vorgenommen.

3.1 Soziale Medien

Unter Sozialen Medien (englisch: „Social Media“) werden digitale Technologien verstanden, die das Teilen von Ideen und Informationen entlang ihrer Nutzer erleichtern.¹ Es gibt viele verschiedene Arten von Sozialen Medien, die sich insbesondere hinsichtlich Art und Umfang der Kommunikation zwischen Nutzern sowie der Zielgruppe voneinander unterscheiden.² Beispielsweise werden unter Sozialen Medien Soziale Netzwerke, Instant Messaging-Dienste, Blogs, Wikis, Webforen, Bewertungsportale und Multimediaportale verstanden.³ Im Rahmen dieser Arbeit liegt der Fokus auf der Datengewinnung aus Sozialen Netzwerken. Andere Formen Sozialer Medien werden also nicht weiter berücksichtigt.

Im Januar 2024 gab es bereits über 5 Milliarden aktive Social Media Identitäten.⁴ Die im Januar 2023 beliebtesten Sozialen Netzwerke und Messenger, gemessen an ihrer Anzahl monatlich aktiver Nutzer, waren Facebook, YouTube, WhatsApp, Instagram und WeChat. Dabei kam Facebook auf ca. 2,96 Milliarden monatlich aktive Nutzer, während WeChat monatlich etwa 1,31 Milliarden aktive Nutzer hatte.⁵

3.2 Soziale Netzwerke

Soziale Netzwerke sind eine Art von Sozialen Medien (vgl. Kap. 3.1). Bei ihnen handelt es sich um Plattformen, für deren Nutzung i.d.R. eine Registrierung vorausgesetzt wird. Von Außenstehenden können hier veröffentlichte Inhalte häufig gar nicht oder nur beschränkt angesehen werden. Nutzer erstellen Personen- oder Unternehmensprofile, um über diese Kontakt zu anderen registrierten Profilen aufzubauen oder zu pflegen. Verknüpfungen zwischen den Accounts werden häufig durch Freundschafts- oder Kontaktanfragen realisiert, die entsprechend bestätigt oder auch abgelehnt werden können. Zur Kommunikation zwischen den einzelnen Nutzern gibt es viele unterschiedliche Möglichkeiten. Beispielsweise können Beiträge veröffentlicht werden und von anderen Nutzern kommentiert oder weiterverbreitet werden. Häufig können zusätzlich dazu auch Privatnachrichten an ausgewählte Nutzer gesendet werden.⁶

¹Vgl. Dollarhide, M. (31.07.2024): Social Media, Investopedia, Abrufdatum: 05.08.2024.

²Vgl. Schwartmann, R./Ohr, S. (2015): Recht der Sozialen Medien, S. 7.

³Vgl. Schwartmann, R./Ohr, S. (2015): Recht der Sozialen Medien, S. VII.

⁴Vgl. Kemp, S. (31.01.2024): Digital 2024: Global Overview Report, Datareportal, Abrufdatum: 23.07.2024.

⁵Vgl. o.V. (06.05.2024): Ranking der größten Social Networks und Messenger nach der Anzahl der Nutzer im Januar 2024, Statista, Abrufdatum: 14.05.2024.

⁶Vgl. Schwartmann, R./Ohr, S. (2015): Recht der Sozialen Medien, S. 7.

Facebook gilt als bekanntestes Soziales Netzwerk.⁷ Für Forschungsarbeiten wird hingegen zumeist Twitter (bzw. mittlerweile „X“) verwendet.⁸ Die Twitter-API zur Datengewinnung wurde allerdings kommerzialisiert,⁹ sodass zunehmend Alternativen für diese Plattform berücksichtigt werden. Mastodon und BlueSky gelten als solche Twitter-Alternativen.¹⁰ Die in Kapitel 1.2 erklärte Datengewinnung für das ThWIC-Projekt wird mittels dieser beiden Plattformen realisiert. Die Sozialen Netzwerke Mastodon und BlueSky werden deswegen im Projektteil dieser Arbeit genauer beschrieben (vgl. Kap. 6.1.1).

3.3 Social Media Daten

Grundlegend können alle Informationen, die Sozialen Medien entnommen werden können, als Social Media Daten bezeichnet werden. Dies gilt also sowohl für nutzergenerierte Inhalte wie Beiträge, Likes oder Kommentare, als auch für systemgenerierte Informationen wie Zeitstempel von Beiträgen und pseudonymisierte Kennungen wie Account-IDs.¹¹ Zusätzlich dazu weisen Social Media Daten häufig bestimmte Eigenschaften auf, die bei der Erfassung, Speicherung und Verwendung zu Problemen führen können und berücksichtigt werden sollten:¹²

Skalierung: Die Datenmengen, die aus Sozialen Netzwerken erfasst werden können, sind oft enorm und umfassen sowohl nutzergenerierte Inhalte als auch systemgenerierte Informationen. Für Forscher kann es schwierig sein, genau zu definieren, welche Daten davon benötigt werden und somit erfasst und ggf. gespeichert werden sollen.¹³

Geschwindigkeit: Social Media Daten werden ständig von den Nutzern aktualisiert. Historische Daten sind dabei häufig schwerer zu erfassen als aktuelle Daten. Da Beiträge i.d.R. jederzeit von den Benutzern gelöscht werden können, kann nicht erwartet werden, einen einmal erfassten Datensatz zu einem späteren Zeitpunkt komplett rekonstruieren zu können.¹⁴

Plattform-Abhängigkeit und Eigentumsverhältnisse: Social Media Plattformen haben unterschiedliche Nutzungsbedingungen und Algorithmen, wodurch insbesondere der Zugang und die Berechtigung zur Nutzung der Daten beeinflusst wird.¹⁵ Außerdem können die Algorithmen der Plattform dazu führen, dass ein mittels API erfasster Datensatz nicht ganz repliziert werden kann, auch wenn i.d.R. weiterhin ähnliche Datensätze zurückgegeben werden.¹⁶

Manchmal werden Informationen mittels auf Social Media Plattformen durchgeführten Umfragen gewonnen und ausgewertet.¹⁷ Diese Art von Social Media Daten wird in dieser Arbeit aber nicht behandelt.

⁷Vgl. o.V. (06.05.2024): Ranking der größten Social Networks und Messenger nach der Anzahl der Nutzer im Januar 2024, Statista, Abrufdatum: 14.05.2024.

⁸Vgl. Zachlod, C. et al. (2022): Analytics of social media data - State of characteristics and application, S. 9.

⁹Vgl. o.V (o.J.): X API, X Developer Platform, Abrufdatum: 24.06.2024.

¹⁰Vgl. Dampz, N. (27.10.2023): Was von Twitter übrigblieb, tagesschau, Abrufdatum: 26.06.2024.

¹¹Vgl. Hemphill, L./Hedstrom, M./Leonard, S. (6.5.2019): How can we save social media data, S. 15.

¹²Vgl. ebenda, S. 23.

¹³Vgl. ebenda, S. 16.

¹⁴Vgl. ebenda, S. 16.

¹⁵Vgl. ebenda, S. 15.

¹⁶Vgl. Felt, M. (29.04.2016): Social media and the social sciences: How researchers employ Big Data analytics, S. 3.

¹⁷Vgl. Michaelidou, N./Micevski, M. (2019): Consumers' ethical perceptions of social media analytics practices: Risks, benefits and potential outcomes

4 Use Cases von Social Media Daten

In diesem Kapitel wird aufgezeigt, in welchen Themenbereichen und für welche Arten von Analysen Social Media Daten bislang hauptsächlich verwendet werden. Daraus werden Verwendungsmöglichkeiten solcher Daten fürs ThWIC-Projekt abgeleitet, die über den primären Zweck, also das Recommendation-System (vgl. z.B. Kap. 1.2), hinausgehen. Auch die Häufigkeit der dafür eingesetzten Social Media Netzwerke wird untersucht. So wird herausgearbeitet, welche Social Media Daten fürs ThWIC-Projekt relevant sind und nach Möglichkeit im praktischen Teil der Arbeit gesammelt und vereinheitlicht gespeichert werden sollen. Wesentliche Vorarbeit hierzu findet sich in einem Review-Artikel, in dessen Rahmen 94 Veröffentlichungen aus den Jahren 2017 bis 2020 über Social Media Analysen u.a. hinsichtlich Anwendungsbereichen, eingesetzten Social Media Netzwerken und Methoden zusammengefasst und analysiert wurden.¹

4.1 Gängige Anwendungsbereiche und Analysemethoden

In 56 der 94 Veröffentlichungen wurde mit Datensätzen aus sozialen Medien gearbeitet. Diese wurden auf ihre Analysemethoden hin überprüft. Insgesamt wurden 28 verschiedene Analysemethoden und Kombinationen dieser angewandt. Die Stimmungsanalyse wurde am häufigsten verwendet, nämlich 28 Mal. Die Worthäufigkeitsanalyse wurde 18 Mal, die Themenmodellierung 17 Mal und die Inhaltsanalyse 16 Mal verwendet.

Alle Veröffentlichungen ließen sich auf 16 Anwendungsbereiche aufteilen. Diese umfassen Landwirtschaft, Bankwesen, Business Intelligence, Kommunikation, Katastrophenmanagement, disruptive Technologien, Bildung, Ethik, Regierung, Gesundheitsversorgung und öffentliche Gesundheit, Tourismus, Journalismus, Management, Marketing, Terrorismus sowie sonstige Bereiche. In der Kategorie „sonstige Bereiche“ sind Publikationen zusammengefasst, die sich auf die methodische (Weiter-)Entwicklung der Analyse von Social-Media-Daten beziehen. Außerdem wurde betont, dass die Zugehörigkeit zu mehreren Kategorien nicht auszuschließen ist.² Insgesamt ließen sich die meisten Veröffentlichungen dabei den Kategorien Marketing, Tourismus, disruptive Technologien und Katastrophenmanagement zuweisen.³

Im ThWIC-Projekt wird insbesondere das Problem Wasserknappheit adressiert, mit der primären Zielsetzung eines effizienten Wassermanagements (vgl. Kap. 1.2). Da Wasserknappheit in einigen Regionen der Erde bereits Menschenleben gefährdet und das Potenzial hat, sich zukünftig weiter auszubreiten, lassen sich auf ein effizienteres Wassermanagement abzielende Analysen von Social Media Daten u.a. der Kategorie Katastrophenmanagement zuordnen. Unter Berücksichtigung der für das ThWIC-Projekt definierten Schlüsselwörter (vgl. Anhang, Tab. 1) für das ThWIC-Projekt, nach denen in den sozialen Medien gesucht werden soll, können auch Themen aus den Bereichen Landwirtschaft, Ethik, Regierung und Gesundheitsversorgung sowie Bildung mit der Wasserproblematik verknüpft sein. Beispielsweise können durch in der Landwirtschaft verwendete Chemikalien zu Wasserverschmut-

¹Vgl. Zachlod, C. et al. (2022): Analytics of social media data - State of characteristics and application, S. 1.

²Vgl. ebenda, S. 6.

³Vgl. ebenda, S. 1.

zung und damit weniger Trinkwasser führen, eine schlechte Wasserqualität kann gesundheitliche Folgen haben, eine gerechte Wasserverteilung kann zu den Aufgaben einer Regierung gehören und dabei ethische Fragen aufwerfen. Den Schlüsselwörtern „water literacy“ oder „lake literacy“ ist zu entnehmen, dass Bildung im Bereich Wasser ebenfalls im Rahmen des ThWIC-Projekts untersucht wird. Die Veröffentlichungen, die einer dieser Kategorien zugeordnet wurden sowie Untersuchungen von Social Media Datensätzen enthalten, werden im Folgenden konkreter beschrieben, um sie insbesondere hinsichtlich ihrer verwendeten Analysemethoden und konkreter Anwendungsfälle zu untersuchen. Daraus werden dann einige mögliche Anwendungsfälle für das ThWIC-Projekt sowie die dazu benötigten Informationen aus Sozialen Netzwerken hergeleitet.

4.1.1 Katastrophenmanagement

Kankanamge et al. (2020) nutzten Echtzeit-Twitter-Daten aus den Jahren 2010 bis 2011, um den Katastrophenschweregrad bei Überschwemmungen im Südosten von Queensland im Zeitverlauf zu bestimmen sowie zur Identifikation von besonders stark betroffenen Gebieten. Der Katastrophenschweregrad und die Auswirkungen wurden durch Meinungen und Wahrnehmungen der lokalen Gemeinschaften interpretiert. Für die Abgrenzung schwer betroffener Gebiete wurden Tweets geolokalisiert.⁴

Von Ragini et al. (2018) wurde ein Algorithmus im Bereich des maschinellen Lernens entwickelt, mit dem Texte aus Sozialen Medien während einer Katastrophe analysiert werden können. Dadurch sollen gefährdete Personen identifiziert und erreicht werden können.⁵

Fathi et al. (2020) untersuchten die Herausforderungen und technischen Anforderungen, um Daten aus Sozialen Medien effektiv für Rettungs- und Unterstützungsteams nutzbar zu machen.⁶ Als wesentliche und zeitintensive Herausforderung wurde das manuelle Sammeln, Filtern und Dokumentieren von benutzergenerierten Inhalten aus unterschiedlichen Sozialen Netzwerken herausgestellt. Es wird darauf hingewiesen, dass fortgeschrittene Tools an dieser Stelle unterstützen müssen, um erfolgreich agieren zu können. Auch das Identifizieren und Analysieren neuer relevanter Inhalte in Echtzeit stellt bislang ein Problem dar.⁷

Park et al. (2019) forschten, wie Touristen soziale Netzwerke in unvorhersehbaren Krisen nutzen. Die Autoren entwickelten dabei ein Schema, um die Struktur des Informationsaustauschs zwischen Touristen, Tourismus Organisationen und anderen beteiligten Akteuren zu bewerten.⁸

Xu et al. (2017) entwickelten ebenfalls eine Methode und schlagen vor, Weibo-Daten über urbane Notfallereignisse zu sammeln und daraus jeweils Zusammenfassungen zu generieren.⁹

Ein Anwendungsbeispiel im Bereich Katastrophenmanagement kann für das ThWIC-Projekt also die Überwachung von Wasserkrisen, wie Überschwemmungen oder Wasserknappheit, sein. Dafür können Echtzeit-Daten aus Sozialen Netzwerken, die Meinungen und Wahrnehmungen betroffener Personen beinhalten, genutzt werden, um den Schweregrad dieser Krisen einzuschätzen. Hierfür bedarf es Echtzeit-Posts und Kommentare zur Wasserkrise. Gegebenenfalls können sogar besonders stark betroffene Gebiete abgegrenzt werden. Dies kann durch Geolokalisierung von Beiträgen erfolgen. Sollen Wasserkrisen mittels Social Media Daten zusammengefasst werden, so können dafür auch historische Daten, wie in der Vergangenheit veröffentlichte Beiträge, verwendet werden. Ein weiterer

⁴Vgl. Kankanamge, N. et al. (2020): Determining disaster severity through social media analysis: Testing the methodology with South East Queensland Flood tweets.

⁵Vgl. Ragini, J./Anand, R./Bhaskar, V. (2018): Mining crisis information: A strategic approach for detection of people at risk through social media analysis.

⁶Vgl. Fathi, R. et al. (2020): VOST: A case study in voluntary digital participation for collaborative emergency management.

⁷Vgl. ebenda, S. 23.

⁸Vgl. Park, D./Kim, W./Choi, S. (29.07.2018): Application of social media analytics in tourism crisis communication.

⁹Vgl. Xu, Z. et al. (23.12.2016): Building the Multi-Modal Storytelling of Urban Emergency Events Based on Crowdsensing of Social Media Analytics.

möglicher Anwendungsfall ist die Unterstützung von Hilfsorganisationen während Wasserkrisen, z.B. indem gefährdete Personen identifiziert werden und so erreicht werden können. Hierfür werden insbesondere Beiträge und Kommentare in Echtzeit benötigt.

4.1.2 Landwirtschaft

Eine Publikation, die dem Themenbereich „Landwirtschaft“ zuzuordnen ist, wurde von Whittingham et al. (2020) veröffentlicht. Hier untersuchten die Autoren anhand von Kommunikationsdaten aus 522 öffentlichen Twitter-Accounts, wie individuelle Unterschiede, bspw. hinsichtlich Persönlichkeitsmerkmalen und persönlichen Werten, die Wahrnehmung beeinflussen, ob gentechnisch veränderte Lebensmittel als sicher gelten oder nicht.¹⁰

Pilař et al. (2018) analysierten die Wahrnehmung von Bio-Lebensmitteln sowie die Motivation zum Kauf dieser. Dafür wurden verschiedene Studien verglichen und insgesamt 344.231 Beiträge von 73.380 Instagram Profilen ausgewertet.¹¹

Für das ThWIC-Projekt können also bspw. die Stimmungen und Meinungen von Personen bzgl. Verwendung einiger mit Wasserverschmutzung in Verbindung gebrachter Stoffe in der Landwirtschaft untersucht werden. Dafür werden insbesondere Beiträge und Kommentare benötigt, die Schlüsselwörter dieser Thematik beinhalten. Zudem kann es dahingehend vorteilhaft sein, wenn zusätzliche Informationen über den Herausgeber, wie das Alter oder der Wohnort, bekannt sind. So kann zusätzlich noch geprüft werden, ob bzw. wie persönliche Informationen die Meinungsbildung beeinflussen.

In der Kategorie Landwirtschaft wurden also User-Beiträge (Tweets und Posts) verwendet, um Stimmungsanalysen einzelner User sowie Analysen zu deren Persönlichkeit durchzuführen.

4.1.3 Ethik

Michaelidou und Micevski (2019) untersuchten in ihrer Publikation, inwieweit Social-Media-Nutzer die von Dritten durchzuführende Analyse ihrer in sozialen Netzwerken generierten Daten für ethisch halten. Dafür wurden 316 Social-Media-Nutzer hinsichtlich dieser Fragestellung analysiert. Allerdings wurden die Daten mittels Umfrage an die Teilnehmer gewonnen.¹² Datensammlung durch Umfragen ist nicht Bestandteil dieser Arbeit.

Trotzdem könnten Social Media Beiträge und Kommentare über die Verteilung von Wasserressourcen analysiert werden. Dies könnte helfen, Meinungen der Bevölkerung über die Gerechtigkeit der Wasserverteilung (ggf. auch während einer konkreten Krisensituation) zu verstehen. Hierfür werden also auch hauptsächlich Beiträge und Kommentare mit entsprechenden Inhalten für eine Meinungs- bzw. Stimmungsanalyse benötigt.

4.1.4 Regierung

Brooker et al. (2018) kritisieren, dass die Analyse von Social Media Daten häufig auf „Momentaufnahmen“ beschränkt ist, indem zur Sammlung der Datengrundlage Suchstrategien für bestimmte Schlüsselwörter verwendet werden. Deswegen nutzen sie stattdessen User-Timelines aus Twitter, also eine chronologische Sammlung aller Tweets bestimmter User, um bspw. zu analysieren, wie regelmäßig diese User über Sozialhilfe twittern und wie sie über die Situation der Sozialhilfe im Vereinigten Königreich schreiben. Dadurch wurde die sozialpolitische Meinung der einzelnen User sowie die Veränderung dieser über einen längeren Zeitraum hinweg untersucht.¹³

¹⁰Vgl. Whittingham, N./Boecker, A./Grygorcyk (07.04.2019): Personality traits, basic individual values and GMO risk perception of twitter users.

¹¹Vgl. Pilař, L. et al. (2018): Questionnaire vs. Social Media Analysis - Case Study of Organic Food.

¹²Vgl. Michaelidou, M./Micevski, M. (2019): Consumers ethical perceptions of social media analytics practices: Risks, benefits and potential outcomes.

¹³Vgl. Brooker, P. et al. (2018): Researching with Twitter timeline data.

Juma'h und Alnsour (2018) analysierten die Tweets eines amerikanischen Präsidenten und deren Einfluss auf einzelne Unternehmen und den Aktienmarkt.¹⁴ Im Gegensatz zu den zuvor beschriebenen Untersuchungen wurde hier also nicht die Auswirkung realer Ereignisse oder Probleme auf die in Sozialen Medien geteilten Informationen untersucht, sondern es wurde die Wirkung einzelner Social Media Beiträge einer für die Fragestellung als relevant angenommenen Person auf die Welt betrachtet.

Maynard et al. (2017) präsentieren in ihrer Publikation nicht nur ein Schema, um große Mengen an Social Media Inhalten zu sammeln und zu analysieren, sondern sie wenden dies auch beispielhaft an. So wurden Tweets von britischen Politikern und die Reaktion der Öffentlichkeit darauf vor Parlamentswahlen analysiert. Darauf aufbauend wurde untersucht, wie sich diese Politiker sowie die Öffentlichkeit zum Thema Klimawandel positionieren. Außerdem wurden öffentliche Tweets vor dem Brexit hinsichtlich dieser Thematik untersucht.¹⁵ Neben Stimmungsanalysen wurden hier also auch die Beiträge ausgewählter Personen und die Reaktionen anderer User auf diese analysiert.

Mehmet et al. (2018) analysierten die Stimmungen in 83 Facebook-Artikeln und den dazugehörigen Kommentaren, um herauszufinden, wie verschiedene Interessengruppen die Bekämpfung von Karpfen als Schädlinge der einheimischen Fauna in Australien bewerten.¹⁶

Ozturkcan et al. (2017) nutzten öffentliche Twitter Beiträge, um das Teilen von Information während Protesten zu analysieren. Dabei wurde festgestellt, dass durch Echtzeit-Daten die zeitliche Abfolge dieser Ereignisse nachvollzogen werden kann.¹⁷

Kim et al. (2018) verwenden 9974 öffentliche Tweets, die in einer Zeitspanne von 14 Monaten gesammelt wurden. Die Tweets wurden als „Feedback“ hinsichtlich der Nutzung und Erfahrungen mit öffentlichem Raum verstanden und sie wurden insbesondere analysiert, um den öffentlichen Raum auf Verbesserungsmöglichkeiten zu prüfen. Dabei stellte sich die Echtzeit-Datengenerierung als Vorteil heraus.¹⁸

Auch im politischen Bereich werden Social Media Daten also hauptsächlich für Stimmungs- bzw. Meinungsanalysen eingesetzt. Für das ThWIC-Projekt könnte z.B. die öffentliche Meinung über Regierungsmaßnahmen im Kontext Trinkwasser untersucht werden, indem Beiträge und Kommentare zu entsprechender Maßnahme analysiert werden. Das Analysieren der Beiträge einzelner User über einen längeren Zeitraum hinweg kann ebenfalls sinnvolle Erkenntnisse liefern und in Twitter z.B. über sog. „User-Timelines“ realisiert werden. Durch diese Art der Analyse kann untersucht werden, ob sich die Meinung der User, z.B. nach einem bestimmten politischen Ereignis, ändert. Außerdem kann es sinnvoll sein, einige für die Analyseaufgabe relevante Social Media Profile im Themenbereich Trinkwasser zu identifizieren und die Reaktionen, z.B. in Form von Likes, auf deren Beiträge zu beobachten. Die separate Betrachtung ausgewählter Personen könnte hier z.B. helfen, die Meinung von Experten für Trinkwasser oder politischen Entscheidungsträgern und deren Einfluss auf die öffentliche Meinung zu verstehen.

4.1.5 Gesundheitsversorgung

Kang et al. (2017) analysierten Twitter-Daten über die öffentliche Meinung zu einer neuen Essenspolitik in Schulen, um Fettleibigkeit bei Kindern präventiv anzugehen. Dabei wurden auch Meinungsverschiedenheiten hinsichtlich Geschlecht und Region untersucht. Weiterhin wurde eine Kontentanalyse durchgeführt, um die Gründe für die Meinungsbildungen zu identifizieren.¹⁹

¹⁴Vgl. Ahmad, H./Alnsour, Y. (2018): Using social media analytics: The effect of President Trump's tweets on companies performance.

¹⁵Vgl. Maynard, D. et al. (2017): A framework for real-time semantic social media analysis.

¹⁶Vgl. Mehmet, M. et al. (2018): The public reaction to the carp control herpes virus in Australia.

¹⁷Vgl. Ozturkcan, S. et al. (2017): An analysis of the Gezi Park social movement tweets.

¹⁸Vgl. Kim, H./Chae, B./Park, S. (2017): Exploring public space through social media.

¹⁹Vgl. Kang, Y. et al. (2017): The public's opinions on a new school meals policy for childhood obesity prevention.

Für das ThWIC-Projekt könnten zum Thema Gesundheitsversorgung bspw. die Beiträge von Gebieten mit wesentlich schlechter Wasserqualität oder Trinkwassermangel untersucht werden, um zu überprüfen, ob bzw. wie und bei welchen Bevölkerungsgruppen dies ggf. einen Einfluss auf die physische sowie psychische Gesundheit hat. Hierfür werden also wieder Beiträge betroffener Personen sowie Informationen über die Herausgeber benötigt, um sie Bevölkerungsgruppen zuordnen zu können.

4.1.6 Bildung

Widmar et al. (2020) untersuchten hauptsächlich mittels Twitter-Daten die Vorstellungen über den Beruf des Tierarztes. Es wurde eine Stimmungsanalyse durchgeführt, um positive und negative Assoziationen mit dem Beruf zu erkennen sodass Vorschläge abgeleitet werden konnten, wie Werbekampagnen zu mehr Tierärzten führen können.²⁰ Im Bereich Bildung könnten für das ThWIC-Projekt beispielsweise Stimmungen und Meinungen zu Beiträgen und Reaktionen auf Werbekampagnen im Kontext Wasser analysiert werden. Diese Kampagnen könnten z.B. zum Wassersparen aufrufen oder Bildungsinitiativen im Bereich Wasser fördern. Die Analyseergebnisse könnten aufzeigen, welche Kampagnen besonders erfolgreich sind. Daraus könnten ebenfalls Vorschläge abgeleitet werden, wie solche Kampagnen zukünftig besser angenommen werden.

4.2 Eingesetzte Social Media Netzwerke

Aus vorherigem Kapitel geht bereits hervor, dass in den Themenbereichen, denen auch das ThWIC-Projekt zugeordnet werden kann, am häufigsten Twitter-Beiträge als Datengrundlage verwendet werden (vgl. Kap. 4.1.1 bis Kap. 4.1.6).

Dies deckt sich mit den Erkenntnissen von Zachlod et al. (2022). Sie verglichen, welche Social Media Netzwerke in den 94 Veröffentlichungen berücksichtigt wurden. Das Ergebnis ist in folgender Tabelle dargestellt:

Publication year	Facebook	Twitter	Instagram	YouTube	TripAdvisor	LinkedIn	Other
2017	4	11	3	4	2	2	10
2018	8	15	4	3	1	1	3
2019	7	17	3	1	4	1	5
2020	6	12	3	0	1	0	3
Total	25	55	13	8	8	4	21

Tabelle 4.1: Häufig verwendete Social Media Netzwerke
(Quelle: Zachlod et al. (2022))

Die Häufigkeit der verwendeten Netzwerke ist nach den Publikationsjahren der einzelnen Arbeiten sortiert. In der letzten Zeile sind diese Häufigkeiten aus allen Jahren zusammengefasst. Unter die Kategorie „Others“ fallen Social Media Netzwerke, die in weniger als vier der Publikationen berücksichtigt wurden, z.B. „Foursquare“ und „Google +“.²¹

Auffällig ist hier zunächst, dass Twitter mit 55 von insgesamt 134 verwendeten Social Media Netzwerken mit Abstand am häufigsten genutzt wurde. Facebook, die zweithäufigste Datenquelle, wurde nur 25 Mal verwendet und damit weniger als halb so häufig wie Twitter. Außerdem geht aus der Tabelle hervor, dass in einigen Veröffentlichungen mehrere Netzwerke berücksichtigt wurden. Denn es wurden nur 94 Publikationen analysiert, aber 134 Social Media Netzwerke darin erkannt.

Ob Twitter allerdings weiterhin die primäre Datenquelle bleibt, ist unklar. Denn im Oktober 2022 wurde Twitter

²⁰Vgl. Widmar, N. et al. (2020): Public Perceptions of Veterinarians from Social and Online Media Listening.

²¹Vgl. Zachlod, C. et al. (2022): Analytics of social media data - State of characteristics and application, S. 9.

offiziell von Elon Musk übernommen.²² Daraufhin wurde nicht nur der Name von Twitter zu „X“ geändert, sondern auch andere Änderungen vorgenommen, wie z.B. die Einschränkung oder Abschaffung von Sicherheitsmaßnahmen. Die Benutzerzahlen sind zurückgegangen und Desinformationen nehmen zu. Außerdem wurden einige Journalisten gesperrt und es wurde dafür gesorgt, dass Beiträge einzelner Personen eine höhere Reichweite bekommen.²³ Die Twitter-API ist zudem nicht mehr kostenlos verfügbar.²⁴ Dadurch wurden bereits viele Forschungsprojekte abgebrochen. Bereits im Jahr 2023 ging die Anzahl an Veröffentlichungen der mit Hilfe von Twitter-Daten durchgeführten wissenschaftlichen Arbeiten im Vergleich zum Vorjahr um 13 % zurück. Es wird vermutet, dass ein Großteil dieser Publikationen aus 2023 mit Daten durchgeführt wurde, die zu einem Zeitpunkt gesammelt wurden, als die API von Twitter noch (weitestgehend) kostenlos zur Verfügung stand.²⁵ Als Twitter-Alternativen gelten derzeit u.a. BlueSky, Mastodon und Threads von dem Facebook-Konzern Meta.²⁶

²²Vgl. Chapekis, A./Smith, A. (2023): How U.S. adults on Twitter use the site in the Elon Musk era, Policy Commons, Abrufdatum: 07.06.2024.

²³Vgl. Dampz, N. (27.10.2023): Was von Twitter übrigblieb, tagesschau, Abrufdatum: 08.06.2024.

²⁴Vgl. o.V. (o.J.): X API, X Developer Platform, Abrufdatum: 08.06.2024.

²⁵Vgl. Murtfeldt, R. et al. (2024): RIP Twitter API, S. 1.

²⁶Vgl. Dampz, N. (27.10.2023): Was von Twitter übrigblieb, tagesschau, Abrufdatum: 08.06.2024.

5 Rechtliche Fragestellungen zur Verarbeitung von Daten aus Sozialen Medien

Die Speicherung und Verarbeitung von Daten aus Sozialen Medien ist in der Sozialforschung bereits gängige Praxis. Häufig geht sie allerdings mit erheblichen Rechtsproblemen einher, die i.d.R. in der Datenschutzgrundverordnung (DSGVO) sowie dem Bundesdatenschutzgesetz (BDSG) begründet sind.¹ Auch die Landesdatenschutzgesetze können hierzu weitere relevante Gesetze enthalten.² Dieses Kapitel wird deswegen über den Schutz von Daten aus Sozialen Netzwerken sowie Rechte und Pflichten bei deren Verwendung informieren. Da es sich beim ThWIC-Projekt u.a. um ein Forschungsprojekt der Universität Jena handelt (vgl. Kap. 1.2), wird die Rechtmäßigkeit der Verwendung entsprechender Daten für die wissenschaftliche Forschung besonders hervorgehoben.

5.1 Relevante Regelwerke und Begriffsklärungen

Im Folgenden sind kurz die einzelnen Verordnungen und Gesetzgebungen erklärt, die zur Speicherung und Verarbeitung von Daten zu natürlichen Personen, und somit auch zur Sammlung von Informationen aus Sozialen Medien, berücksichtigt werden müssen. Weiterhin sind Begriffsklärungen zum besseren Verständins relevanter Abschnitte dieser Regelwerke Bestandteil des Kapitels.

5.1.1 Relevante Regelwerke: DSGVO, BDSG, Landesdatenschutzgesetze

Europäische Datenschutzgrundverordnung (DSGVO): Die europäische Datenschutzgrundverordnung gilt seit dem 25.5.2018³ mit der primären Zielsetzung, innerhalb der europäischen Union ein einheitliches Datenschutzniveau zu gewährleisten.⁴

Bundesdatenschutzgesetz (BDSG): Ergänzend zur DSGVO gilt deutschlandweit⁵ das Bundesdatenschutzgesetz (BDSG), das zeitgleich mit der DSGVO in Kraft getreten ist. Dieses dient der Konkretisierung einiger Verordnungen der DSGVO.⁶

Landesdatenschutzgesetz (LDSG): Weiterhin gibt es die Landesdatenschutzgesetze (LDSGs) der einzelnen Bundesländer, die sich primär auf öffentliche Stellen des jeweiligen Landes beziehen.⁷

¹Vgl. Golla, S./Hofmann, H./Bäcker, M. (28.01.2018): Connecting the Dots, S. 1.

²Vgl. o.V. (o.J.): LDSG, Intersoft Consulting, Abrufdatum: 09.05.2024.

³Vgl. o.V. (o.J.): DSGVO, Intersoft Consulting, Abrufdatum: 09.05.2024.

⁴Vgl. o.V. (o.J.): Art. 1 DSGVO, Intersoft Consulting, Abrufdatum: 09.05.2024.

⁵Vgl. o.V. (o.J.): § 1 BDSG, Intersoft Consulting, Abrufdatum: 09.05.2024.

⁶Vgl. o.V. (o.J.): BDSG, Intersoft Consulting, Abrufdatum: 10.05.2024.

⁷Vgl. o.V. (o.J.): LDSG, Intersoft Consulting, Abrufdatum: 09.05.2024

5.1.2 Begriffsklärungen gemäß DSGVO und BDSG

Die DSGVO bezieht sich ausschließlich auf die Verarbeitung **„personenbezogener Daten“**.⁸ Darunter werden Daten verstanden, die eine natürliche Person identifizieren oder identifizierbar machen. Als „identifizierbar“ gilt eine natürliche Person, die direkt oder indirekt mittels einem oder mehrerer besonderer Merkmale identifiziert werden kann. Typische Beispiele für eine direkte Identifizierung sind der Name der Person oder Standortdaten. Aber auch durch Zuordnungsmöglichkeiten der natürlichen Person zu einer (Online-)Kennung mittels Zusatzinformationen (wie z.B. einer Liste mit Kennungen und zugehörigen Namen) oder physischen, genetischen, psychischen, interessensbasierten und weiteren Merkmalen lassen sich Betroffene indirekt identifizieren. Somit fallen i.d.R. also auch pseudonymisierte personenbezogene Daten unter den Schutz der DSGVO.⁹

Weiterhin sind in Art. 9 Abs. 1 DSGVO **„besondere Kategorien personenbezogener Daten“** definiert. Bei diesen handelt es sich um Daten über rassische und ethnische Herkunft, politische Meinungen, religiöse oder weltanschauliche Überzeugungen, Gewerkschaftszugehörigkeit, genetische Daten, biometrische Daten zur eindeutigen Identifizierung einer natürlichen Person, Gesundheitsdaten oder Daten zum Sexualleben oder der sexuellen Orientierung einer natürlichen Person. Für diese Informationen besteht gemäß Art. 9 Abs. 1 DSGVO ein grundlegendes Verarbeitungsverbot. Ausnahmen hierfür finden sich in Art. 9 Abs. 2 DSGVO. Diese werden im folgenden Kapitel genauer erläutert.

Unter der **„Verarbeitung“** von Daten werden gemäß Art. 4 Abs. 2 DSGVO alle automatisierten sowie nicht automatisierten Vorgänge mit personenbezogenen Daten definiert. Dazu gehören auch die für diese Arbeit besonders relevanten Vorgänge wie das Erfassen, die Organisation, das Ordnen, die Speicherung sowie die Verwendung entsprechender Informationen.¹⁰

5.2 Erlaubnistatbestände zur Verarbeitung personenbezogener Daten

Für personenbezogene Daten ist die Rechtmäßigkeit deren Verarbeitung in Art. 6 Abs. 1 DSGVO festgelegt und für die in Kap. 9 Abs. 1 DSGVO definierten besonderen Kategorien personenbezogener Daten besteht ein Verarbeitungsverbot. Ausnahmen zur Zulässigkeit der Verarbeitung letzterer sind restriktiver als die Verarbeitung personenbezogener Daten¹¹ und finden sich vor allem in Kap. 9 Abs. 2 DSGVO. Sowohl Kap. 6 Abs. 1 lit. a) als auch Kap. 9 Abs. 2 lit. a) DSGVO beinhalten Ausnahmen bei Einwilligung der von der Datenverarbeitung betroffenen Personen. Weiterhin sind Art. 6 Abs. 1 lit. e) und Abs. 1 lit. f) sowie Art. 9 Abs. 2 lit. e) und Abs. 2 lit. j) für die Verwendung personenbezogener bzw. besonderer personenbezogener Daten für Forschungsprojekte relevant. Diese Erlaubnistatbestände werden im Folgenden analysiert und in Bezug zum ThWIC-Projekt gesetzt.

5.2.1 Einwilligung der betroffenen Person

Eine Einwilligung ist in Art. 4 Abs. 11 DSGVO als eine von der betroffenen Person freiwillig abgegebene Willensbekundung bezüglich der Verarbeitung ihrer Daten in Form einer eindeutigen Handlung definiert. Diese muss stets für einen bestimmten Fall erfolgen (vgl. Art. 4 Abs. 11 DSGVO).

Eine Verarbeitung von personenbezogenen Daten ist gemäß Art. 6 Abs. 1 lit. a) DSGVO zulässig, falls die betroffene Person eine entsprechende Einwilligung dazu erteilt hat. Auch für besondere Kategorien personenbezogener

⁸Vgl. o.V. (o.J.): Art. 2 DSGVO, Intersoft Consulting, Abrufdatum: 11.05.2024.

⁹Vgl. o.V. (o.J.): Art. 4 DSGVO, Intersoft Consulting, Abrufdatum: 11.05.2024.

¹⁰Vgl. ebenda.

¹¹Vgl. Golla, S./Hofmann, H./Bäcker, M. (28.01.2018): Connecting the Dots, S. 3.

Daten ist die Verarbeitung nach Art. 9 Abs. 2 a) DSGVO bei Einwilligung möglich. Im Vergleich zu Art. 6 Abs. 1 lit. a) ist der Begriff der „Einwilligung“ hier allerdings strikter formuliert. Erstens müssen nämlich die betroffenen personenbezogenen Daten in der Einwilligung genannt werden. Zweitens muss die Einwilligung „ausdrücklich“ erfolgen. Außerdem kann es sein, dass das Verarbeitungsverbot im konkreten Fall auf Grund des Unionsrechts oder des Rechts von Mitgliedstaaten (für Deutschland hier also das BDSG¹²) nicht aufgehoben werden kann.¹³

In der Datenschutzrichtlinie von Mastodon, der jeder User bei Accounterstellung zustimmen muss, ist keine Form der Einwilligung zur Verarbeitung personenbezogener Daten durch Dritte enthalten. Stattdessen wird direkt im ersten Abschnitt betont, dass sich die Datenschutzrichtlinie lediglich darauf bezieht, wie Mastodon selbst mit den personenbezogenen Daten der User umgeht. Für von Mastodon unabhängige Personen oder Unternehmen gilt die Richtlinie dementsprechend nicht.¹⁴

In der Datenschutzrichtlinie für BlueSky, die ebenso von allen Usern akzeptiert werden muss um BlueSky nutzen zu können, wird unter dem Abschnitt „Your Privacy Rights and Choices“ darauf verwiesen, dass es einige Gesetze zu beachten gilt, die BlueSky Usern gewisse Rechte bezüglich Informationen zu ihrer Person gewähren. Im Abschnitt „SUPPLEMENTAL NOTICE FOR CERTAIN JURISDICTIONS“ wird deutlich, dass auch BlueSky selbst sich an die DSGVO halten muss und dass die Akzeptanz der Datenschutzrichtlinie als Einwilligung für BlueSky betrachtet wird, personenbezogene Daten insbesondere zur Verwaltung und Verbesserung des Services oder bei „berechtigtem Interesse“ zu verarbeiten. Zudem wird an dieser Stelle darauf hingewiesen, dass auch Dritte ein berechtigtes Interesse an der Verarbeitung personenbezogener Daten haben können und in diesem Fall ebenso rechtmäßig die Daten verarbeiten dürfen.¹⁵ Als berechtigtes Interesse definiert BlueSky dabei die in dem Abschnitt „HOW WE USE PERSONAL INFORMATION“ der Datenschutzrichtlinie gegebenen Fälle. Hier findet sich u.a. auch der Absatz „Other purposes“. Darunter fallen auch Zwecke zur Datenverarbeitung, die mit dem geltenden Gesetz konform gehen.¹⁶

Weiterhin kann in Erwägung gezogen werden, für ein Forschungsprojekt selbst eine Einwilligung zu entwerfen und diese von betroffenen Personen bestätigen oder ablehnen zu lassen. Für das ThWIC-Projekt müsste dafür für jeden zu speichernden Social Media Beitrag eine Einwilligung verschickt und ausgewertet werden, oder wenigstens geprüft werden, ob der betroffene User bereits für einen anderen Beitrag die Einwilligung gegeben hat. Für das ThWIC-Projekt ist ein solches Vorgehen aus mehreren Gründen wenig zielführend.

Erstens müsste für jeden durch die Suchanfragen zurückgegebenen Beitrag eine Nachricht an den Account geschrieben werden, der ihn veröffentlicht hat. Auch für die Updates der Datenbank müsste der Einwilligungsprozess weiterhin stattfinden. Trotz teilweiser Automatisierungsmöglichkeiten dafür würde hierbei also ein enormer Aufwand entstehen.

Zweitens muss durch das Einholen einer Einwilligung zur Verarbeitung von personenbezogenen Daten auch mit einer resultierenden Informationsmenge gerechnet werden, die die Wirklichkeit weniger genau darstellt als die eigentliche Datenmenge aller Beiträge zu einem Schlüsselwort. Denn User von Accounts die beispielsweise gezielt und professionell erstellt wurden, um Erkenntnisse im Wasser Kontext teilen zu können, würden einer Verarbeitung ihrer veröffentlichten Beiträge zu akademischen Zwecken vermutlich häufiger zustimmen als User von Accounts die lediglich für private Zwecke erstellt wurden. Würden die Einwilligungen bestimmter Arten von Accounts über-

¹²Vgl. o.V. (o.J.): BDSG, Intersoft Consulting, Abrufdatum: 10.05.2024.

¹³Vgl. o.V. (o.J.): Art. 9 DSGVO, Intersoft Consulting, Abrufdatum: 11.05.2024.

¹⁴Vgl. o.V. (o.J.): Privacy Policy, Mastodon Social, Abrufdatum: 13.05.2024.

¹⁵Vgl. o.V. (o.J.): Bluesky App Privacy Policy: SUPPLEMENTAL NOTICE FOR CERTAIN JURISDICTIONS, Bluesky, Abrufdatum: 11.05.2024.

¹⁶Vgl. o.V. (o.J.): Bluesky App Privacy Policy: HOW WE USE PERSONAL INFORMATION, Bluesky, Abrufdatum: 11.05.2024.

wiegen, würde dies zu einer Verzerrung der Informationen führen. Diese Verzerrung könnte Forschungsergebnisse einiger in Kap. 4 definierten Use Cases, z.B. von Meinungsanalysen, beeinträchtigen, da die gesammelten Daten nicht mehr die unterschiedlichen Interessen, Meinungen und Bevölkerungsgruppen abbilden.

Ein weiteres Problem ist, dass eine Einwilligung die Datenmenge insgesamt reduzieren kann, da evtl. viele Nutzer skeptisch hinsichtlich der Verwendung ihrer Daten sind und somit nur eine kleine und nicht repräsentative Gruppe von Nutzern ihre Einwilligung gibt. Zur Durchführung von Umfragen wurde hierzu sogar herausgefunden, dass die Bereitschaft, online einer Datenverarbeitung zuzustimmen, nur bei ca. 48 bis 69 % liegt, während sie bei in Präsenz durchgeführten Umfragen zwischen 67 und 94 % liegt.¹⁷ Da die Einwilligung für das ThWIC-Projekt auf Grund des hohen Aufwands (vgl. oben) ebenfalls online verschickt werden würde, könnte dies die Datenbasis an Social Media Beiträgen also stark einschränken.

Zusammenfassend kann die Datenschutzrichtlinie von Mastodon also nicht als eine Form der Einwilligung fürs ThWIC-Projekt betrachtet werden, persönliche Daten zu verarbeiten, während die Datenschutzrichtlinie von BlueSky einen Interpretationsspielraum hierfür lässt. Die eigenständige Einholung von Einwilligungen zur Datenverarbeitung kann sowohl die Menge als auch die Qualität der gesammelten Daten wesentlich und negativ beeinflussen. Außerdem würde die Anzahl an Einwilligungen, die verschickt und ausgewertet werden müssten, einen starken Mehraufwand für das ThWIC-Projekt bedeuten. Aus diesen Gründen wird im Rahmen der Erhebung von Social Media Beiträgen für das ThWIC-Projekt von den Erlaubnistatbeständen zur Verarbeitung personenbezogener Daten und besonderer personenbezogener Daten mittels Einwilligung abgesehen. Stattdessen werden im Folgenden andere Gesetze herangezogen, die die Sammlung und Verarbeitung von (besonderen) personenbezogenen Daten zu Forschungszwecken rechtfertigen.

5.2.2 Verarbeitung personenbezogener Daten

Zur Verarbeitung personenbezogener Daten sind in Art. 6 Abs. 1 lit. a) bis f) sechs Bedingungen angegeben, von denen für eine rechtmäßige Verarbeitung mindestens eine erfüllt sein muss. Zu Forschungszwecken sind neben der Einwilligung (vgl. vorheriges Kapitel) zwei dieser Bedingungen besonders hervorzuheben¹⁸ (vgl. auch Art. 6 Abs. 1 DSGVO).

So bietet Art. 6 Abs. 1 lit. e) DSGVO für einige Forschungsprojekte eine weitere Möglichkeit, personenbezogene Daten zu verarbeiten. Dort ist nämlich festgelegt, dass die Verarbeitung erfolgen darf, falls sie im öffentlichen Interesse liegt oder in Ausübung öffentlicher Gewalt erfolgt, wobei dem für die Datenverarbeitung Verantwortlichen diese Gewalt übertragen wurde. In § 3 BDSG ist dazu ergänzt, dass dieser Absatz in Deutschland für öffentliche Stellen gilt. Somit können sich also u.a. öffentlich-rechtliche Hochschulen und andere Forschungseinrichtungen darauf beziehen.¹⁹

Es steht derzeit außer Frage, dass Forschung zur Wasserversorgung von öffentlichem Interesse ist. Außerdem handelt es sich beim ThWIC-Projekt um ein Forschungsvorhaben, das von der Universität Jena und weiteren öffentlichen Forschungseinrichtungen bearbeitet wird. Auch bei der vorliegenden Arbeit handelt es sich um eine wissenschaftliche Abschlussarbeit der Universität Jena im Rahmen des ThWIC-Projekts. Damit sollte Art. 6 Abs. 1 lit. e) für die Rechtmäßigkeit der Erhebung sowie Speicherung und Verarbeitung einiger personenbezogener Daten aus BlueSky und Mastodon für das ThWIC-Projekt herangezogen werden können.

Zuletzt bietet auch Art. 6 Abs. 1 lit. f) DSGVO eine Möglichkeit zur Verarbeitung personenbezogener Daten, falls dies zur Wahrung der berechtigten Interessen des Verantwortlichen oder eines Dritten erforderlich ist. Dabei

¹⁷Vgl. Jäckle, A./Burton, J. (Dezember 2022): How and why does the mode of data collection affect consent to data linkage, S. 3.

¹⁸Vgl. Golla, S./Hofmann, H./Bäcker, M. (28.01.2018): Connecting the Dots, S. 5.

¹⁹Vgl. auch ebenda.

müssen die berechtigten Interessen zur Datenverarbeitung aber die Interessen oder Grundrechte sowie Grundfreiheiten der betroffenen Person bezüglich des Datenschutzes überwiegen. Hierbei kann wissenschaftliche Forschung innerhalb der EU als ein solches berechtigtes Interesse betrachtet werden. Dies geht beispielsweise aus Art. 13 GRCh (Freiheit der Wissenschaft) hervor.²⁰ Als Anmerkung zu diesem Artikel der DSGVO gilt allerdings auch, dass Behörden sich nicht auf ihn berufen dürfen (vgl. Art. 6 Abs. 1 (Unterabsatz) DSGVO). Somit lässt sich die Verarbeitung personenbezogener Daten auch für öffentlich-rechtlich organisierten Hochschulen sowie andere Forschungseinrichtungen nicht mit diesem Absatz rechtfertigen.²¹

Zusammenfassend gilt also, dass für die Rechtmäßigkeit der Sammlung von personenbezogenen Daten für das ThWIC-Projekt aus den Social Media Plattformen BlueSky und Mastodon im Rahmen dieser Arbeit von Art. 6 Abs. 1 lit. e) DSGVO Gebrauch gemacht wird. Dies ist möglich, da das ThWIC-Projekt im öffentlichen Interesse liegt und da es u.a. im Rahmen dieser Arbeit akademisch bearbeitet wird.

5.2.3 Verarbeitung besonderer Kategorien personenbezogener Daten

Ob die Verarbeitung besonders sensibler personenbezogener Daten für wissenschaftliche Zwecke in Frage kommt, muss insbesondere anhand Art. 9 Abs. 2 DSGVO abgewogen werden. Die für Forschungszwecke wichtigsten Ausnahmetatbestände finden sich neben der Einwilligung in Art. 9 Abs. 2 lit. a) (vgl. Kap. 5.2.1) in den Artikeln 9 Abs. 2 lit. e) und j).²²

Art. 9 Abs. 2 lit. e) DSGVO beinhaltet eine Aufhebung des Verarbeitungsgebots nach Abs. 1, falls die von der Datenverarbeitung betroffene Person ihre sensiblen Daten „offensichtlich öffentlich“ gemacht hat. Eine Definition für „offensichtlich öffentlich“ oder „Öffentlichkeit“ ist in der DSGVO nicht zu finden (vgl. Art. 9 Abs. 2 und Art. 4 DSGVO). Ob Beiträge auf einer Social Media Plattform, die zwar grundsätzlich allen Menschen zugänglich ist, jedoch eine vorherige Erstellung eines Accounts erfordert, als eindeutig öffentlich betrachtet werden können, bleibt an dieser Stelle also ungeklärt. Außerdem rechtfertigt Art. 9 DSGVO nicht, wie bzw. ob mit Daten verfahren werden kann, die zwar „offensichtlich veröffentlicht“ sind, dabei aber von einer anderen Person als der von der Datenverarbeitung betroffenen Person veröffentlicht wurden (vgl. Art. 9 DSGVO). Dabei wäre dies gerade fürs ThWIC-Projekt relevant, da ja Social Media Beiträge gesammelt werden sollen. Diese können natürlich auch (besondere) personenbezogene Informationen über andere Personen enthalten.

In der Datenschutzerklärung von BlueSky, die von allen Usern akzeptiert werden muss um BlueSky nutzen zu können, wird direkt im Abschnitt „Overview“ darauf hingewiesen, dass alle Profile und Posts öffentlich sind. Es kann also davon ausgegangen werden, dass BlueSky Nutzern bewusst ist, dass ihre Profildaten und Beiträge grundsätzlich öffentlich und somit für jede Person im Internet sichtbar und verwendbar sind.²³ Für Mastodon wurde eine solche Information hingegen nicht in die Datenschutzerklärung aufgenommen. Es wurde lediglich darüber informiert, dass es sein kann, dass veröffentlichte Inhalte auch von anderen Servern im Mastodon Netzwerk heruntergeladen werden können.²⁴ Der weiteren Verarbeitung von Daten durch andere Personen oder andere Organisationen als Mastodon hat ein Nutzer durch Akzeptieren der Datenschutzverordnung deswegen aber noch nicht direkt zugestimmt.

Bezüglich der Verwendung besonderer personenbezogener Daten, die nicht von der betroffenen Person selbst veröffentlicht wurden, ist in Art. 4 Abs. 2 DSGVO festgelegt, dass unter Datenverarbeitung in der DSGVO u.a. auch die Verbreitung von Daten verstanden wird, die mittels einer Veröffentlichung auf einer Social Media Plattform natürlich gegeben ist. Gemäß Art. 9 Abs. 1 DSGVO haftet also zunächst derjenige, der personenbezogene Daten

²⁰Vgl. auch ebenda.

²¹Vgl. auch ebenda.

²²Vgl. Golla, S./Hofmann, H./Bäcker, M. (28.01.2018): Connecting the Dots, S. 4.

²³Vgl. o.V. (o.J.): Bluesky App Privacy Policy, Bluesky, Abrufdatum: 12.05.2024.

²⁴Vgl. o.V. (o.J.): Privacy Policy, Mastodon Social, Abrufdatum: 13.05.2024.

einer anderen Person unrechtmäßig veröffentlicht hat. Hierfür gelten auch lediglich die Ausnahmetatbestände, die in Art. 9 Abs. 2 DSGVO geregelt sind.

Weiterhin sind in Art. 14 Abs. 1 bis 4 DSGVO dahingehend Informationspflichten beschrieben, die der für die Datenverarbeitung Verantwortliche gegenüber der betroffenen Person erfüllen muss. Dazu gehört beispielsweise das Mitteilen über die Zwecke zur Verarbeitung entsprechender personenbezogener Daten (s. Abs. 1 lit. c) DSGVO) und die Dauer, für die Daten gespeichert werden (s. Abs. 2 lit. a) DSGVO). Für diese Informationspflichten sind aber in Artikel 14 Abs. 5 Ausnahmen definiert. Nach Art. 5 lit. b) DSGVO dürfen diese Daten auch ohne Informationserteilung an die betroffene Person für Forschungszwecke verarbeitet werden, falls die Informationserteilung die Verarbeitungsziele ernsthaft beeinträchtigt oder gar unmöglich machen würde. Dies wäre für das ThWIC-Projekt zutreffend, da für jeden erhobenen Social Media Beitrag geprüft werden müsste, ob Informationen über Dritte enthalten sind. Falls ja, müssten diese Personen identifiziert und, falls die Identifikation erfolgreich verläuft, angeschrieben werden. Zuletzt müsste ihre Antwort abgewartet und wieder ausgewertet werden, um schließlich den Beitrag speichern zu können bzw. verwerfen zu müssen. Durch die Nicht-Auffindbarkeit einiger Personen würde also nicht nur die Datenmenge reduziert werden, sondern die Informationserteilung würde auch einen enormen Aufwand bedeuten. Ein Grund dafür, sich im Rahmen des ThWIC-Projekts trotzdem nicht gänzlich auf diesen Artikel zur Ausnahme der Informationspflicht zu berufen, ist, dass in diesem stets von „personenbezogenen Daten“ die Rede ist (vgl. Art. 14 DSGVO). Es ist also anzunehmen, dass mit besonderen Kategorien personenbezogener Daten strengere Informationspflichten bzw. Ausnahmen für die Informationspflicht gelten dürften.

Gemäß Art. 82 Abs. 6 DSGVO ist in Art. 79 Abs. 2 DSGVO weiterhin geschrieben, dass für Klagen, die sich auf Verstöße der DSGVO beziehen, i.d.R. die Gerichte des Mitgliedstaats der Verantwortlichen zuständig sind. Für Deutschland sind Strafvorschriften dahingehend in § 42 Abs. 1 und 2 BDSG geregelt und beziehen sich lediglich auf „allgemein zugängliche Daten“, und nicht wie die DSGVO auf „offensichtlich von der betroffenen Person veröffentlichte Daten“. Daraus könnte gefolgert werden, dass auch besonders sensible öffentliche Daten gemäß Art. 9 Abs. 1 DSGVO, die nicht von der betroffenen Person selbst veröffentlicht wurden aber allgemein zugänglich sind, deutschlandweit ohne zu befürchtender Strafe verarbeitet werden können und somit für das ThWIC-Projekt verwendet werden können. Nach § 84 BDSG beziehen sich diese Strafvorschriften zu „allgemein zugänglichen Daten“ auch auf öffentliche Stellen und somit auf die Datensammlung im Rahmen des ThWIC-Projekts. Auch von Bußgeldstrafen sind öffentliche Stellen in Deutschland grundsätzlich ausgenommen (vgl. § 43 Abs. 3 BDSG). An dieser Stelle bliebe also lediglich zu klären, ob Daten bereits als „nicht allgemein zugänglich“ gelten, wenn zur Sammlung oder Einsicht dieser lediglich eine jeder Person zustehende Registrierung auf einer Social Media Plattform notwendig ist. Aber hierzu ist im BDSG keine weiterführende Information enthalten (vgl. BDSG²⁵).

Je nach tatsächlicher Bedeutung von „offensichtlich öffentlichen“ und „allgemein zugänglichen“ Daten ist es einer Privatperson also rechtmäßig ermöglicht, von der betroffenen Person selbst veröffentlichte sensible Daten zu verarbeiten. Ob dies allerdings auch für die besonderen personenbezogenen Daten einer Person gilt, die von einer anderen Person veröffentlicht wurden, ist nicht genau festgelegt. Gemäß BDSG ist ein solcher Fall aber auch nicht direkt strafbar.

Ein für das ThWIC-Projekt wesentlicher Ausnahmetatbestand ist außerdem in Art. 9 Abs. 2 lit. j) DSGVO definiert. Demnach dürfen besondere Kategorien personenbezogener Daten verarbeitet werden, falls die Verarbeitung auf Grundlage des Unionsrechts oder des Rechts von entsprechendem Mitgliedstaat erfolgt und für [...] wissenschaftliche [...] Zwecke gemäß Art. 89 Abs. 1 erfolgt. Dabei muss die Datenverarbeitung in angemessenem Verhältnis zum verfolgten Ziel stehen, es muss „der Wesensgehalt des Rechts auf Datenschutz“ gewahrt werden und es müssen spezifische Maßnahmen zur Wahrung der Grundrechte und Interessen der betroffenen Person getroffen werden.²⁶

²⁵Vgl. o.V. (o.J.): BDSG, Intersoft Consulting, Abrufdatum: 10.05.2024.

²⁶Vgl. o.V. (o.J.): Art. 9 DSGVO, Intersoft Consulting, Abrufdatum: 13.05.2024

In Artikel 89 Abs. 1 ist dazu ergänzt, dass bei der Verarbeitung von personenbezogenen Daten zu wissenschaftlichen Forschungszwecken trotz Erlaubnistatbestand geeignete Garantien für die Rechte und Freiheiten der betroffenen Person getroffen werden müssen. Diese Garantien können durch technische und organisatorische Maßnahmen erfüllt werden. Dazu gehört insbesondere der Grundsatz der Datenminimierung. Laut Art. 5 Abs. 1 lit. c) DSGVO wird unter Datenminimierung verstanden, dass die Daten auf das für die Zwecke der Verarbeitung notwendige Maß beschränkt sind. Außerdem ist in Artikel 89 Abs. 2 DSGVO noch ergänzt, dass Bedingungen und Garantien aus Art. 89 Abs. 1 DSGVO für Forschungszwecke vorbehaltlich ausgesetzt werden können, falls eine Einhaltung dieser die Zwecke des Forschungsprojekts unmöglich machen oder ernsthaft beeinträchtigen würde.

Was genau der „Wesensgehalt des Rechts auf Datenschutz“ ist, ist in der DSGVO nicht beschrieben. Allerdings sind in Art. 5 DSGVO mehrere Schlüsselaspekte genannt, wie für die Datenverarbeitung Verantwortliche mit personenbezogenen Daten umgehen müssen. Dazu gehören die Rechtmäßigkeit und Transparenz bezüglich der Datenverarbeitung, Zweckbindung, Datenminimierung, Richtigkeit der verwendeten Daten, zeitbezogene Speicherbegrenzung, Integrität und Vertraulichkeit. Der für die Datenverarbeitung Verantwortliche muss die Einhaltung dieser Prinzipien nachweisen können (vgl. Art. 5 Abs. 2 DSGVO).

Die in Art. 9 Abs. 2 lit. j) DSGVO verlangten Maßnahmen bei Verarbeitung besonderer personenbezogener Daten sind in § 27 BDSG genauer beschrieben. Hier ist wieder angemerkt, dass Datenverarbeitung für Forschungszwecke zulässig ist, wenn die Verarbeitung für konkrete Zwecke erforderlich ist und die Interessen des Verantwortlichen an der Verarbeitung die Interessen der betroffenen Person, also dem Ausschluss von der Verarbeitung, erheblich überwiegen. Der Verantwortliche muss zudem vom konkreten Fall abhängige Maßnahmen zur Wahrung der Interessen der betroffenen Person gemäß § 22 Absatz 2 Satz 2 BDSG umsetzen. Die Auswahl der Maßnahmen soll demnach unter Berücksichtigung des Stands der Technik, der Implementierungskosten, des Umfangs, der Umstände und der Zwecke der Verarbeitung sowie der unterschiedlichen Eintrittswahrscheinlichkeit und Schwere der mit der Verarbeitung verbundenen Risiken für die Rechte und Freiheiten natürlicher Personen getroffen werden.

Für das ThWIC-Projekt kommen davon folgende Maßnahmen besonders in Betracht. Erstens können alle am ThWIC-Projekt Beteiligten besonders für das Thema Datenschutz im Hinblick auf personenbezogene Daten sensibilisiert werden (vgl. § 22 Abs. 2 Nr. 3). Außerdem kann der Zugang zu den personenbezogenen Daten auf die Personen beschränkt werden, die tatsächlich mit den Daten arbeiten (vgl. § 22 Abs. 2 Nr. 5). Auch die Pseudonymisierung kommt für viele Inhalte in Frage (vgl. § 22 Abs. 2 Nr. 6). Zudem kann beschlossen werden, dass die festgelegten Maßnahmen fortgeführt werden, sobald die Social Media Daten zu anderen als den in Kap. 4 definierten Use Cases verwendet oder an andere übermittelt werden (vgl. § 22 Abs. 2 Nr. 10). Zusätzlich dazu kann speziell im Kontext Recommendation System dafür gesorgt werden, dass von betroffener Person gelöschte Beiträge nicht bei Verwendung des Recommendation Systems angezeigt werden. Dadurch würde verhindert werden, dass gelöschte (besondere) personenbezogene Daten weiterhin öffentlich angezeigt werden. Dies würde also den Datenschutz und die Privatsphäre der betroffenen Person stärken. Auch bei den anderen Use Cases kann darauf geachtet werden, dass keine Informationen an die Öffentlichkeit gelangen, die eine Person identifizieren oder identifizierbar machen. So könnten beispielsweise lediglich die aus verschiedenen Beiträgen oder Accounts aggregierten Ergebnisse einiger Auswertungen, wie etwa Meinungsanalysen, veröffentlicht werden, ohne dabei beispielhafte Social Media Beiträge oder Accounts offenzulegen. Auch dies würde betroffene Personen hinsichtlich Privatsphäre und Datenschutz stärken. Zuletzt kann versichert werden, dass die Social Media Daten lediglich für den Zeitraum gespeichert werden, in dem das ThWIC-Projekt existiert.

Die erarbeiteten Maßnahmen wurden abschließend mit der Datenschutzbeauftragten der Universität Jena besprochen. In diesem Gespräch wurde auch die Rechtmäßigkeit der Datensammlung für das ThWIC-Projekt unter Einhaltung der Maßnahmen bestätigt. Es wurde aber auch darauf hingewiesen, dass die Weitergabe an Unternehmen, wie nach Kapitel 1.2 beschrieben, eine erneute Prüfung des Rechtsstands erfordert.

Für die Rechtmäßigkeit der Verarbeitung besonderer Kategorien personenbezogener Daten wird also Art. 9 Abs. 2 lit. j) herangezogen. Dafür werden Maßnahmen zur Wahrung der Grundrechte und Interessen der betroffenen Person umgesetzt, die mit den Zielen des ThWIC-Projekts vereinbar sind.

5.3 Zusammenfassung geeigneter Maßnahmen

Sowohl zur Verarbeitung von personenbezogenen als auch besonderen Kategorien personenbezogener Daten ist die Einholung einer Einwilligung der betroffenen Personen eine Möglichkeit, die Rechtmäßigkeit des Projektes sicherzustellen. Insbesondere auf Grund des hohen Aufwands, der wahrscheinlich stark reduzierten Datenmenge durch Nicht-Einwilligung einiger Betroffener sowie der daraus resultierenden Verzerrung der Daten ist die Einwilligung für das ThWIC-Projekt ungeeignet. Zur Sammlung und Verarbeitung personenbezogener Daten für das ThWIC-Projekt aus den Social Media Plattformen BlueSky und Mastodon wird deswegen von Art. 6 Abs. 1 lit. e) DSGVO Gebrauch gemacht. Dies ist möglich, da das ThWIC-Projekt im öffentlichen Interesse liegt und da es u.a. im Rahmen dieser Arbeit akademisch bearbeitet wird und die gespeicherten Daten letztlich von einer öffentlich-rechtlichen Universität verwendet werden. Die Rechtmäßigkeit zur Verarbeitung besonderer persönlicher Daten zu wissenschaftlichen Zwecken wird mit Art. 9 Abs. 2 lit. j) DSGVO begründet. Damit der Datenschutz der betroffenen Personen dabei bestmöglich gewährleistet werden kann, wurden einige Maßnahmen herausgearbeitet, die für das ThWIC-Projekt umgesetzt werden. Sie sind in der folgenden Tabelle zusammengefasst und wurden zudem mit der Datenschutzbeauftragten der Universität Jena abgesprochen:

Maßnahme	Umsetzung
Sensibilisierung der Beteiligten	Am ThWIC-SONAR Projekt Beteiligte die Zugriff auf die Daten erhalten werden besonders für das Thema Datenschutz bzgl. personenbezogener Daten sensibilisiert (vgl. § 22 Abs. 2 Nr. 3), z.B. durch das Lesen von Kap. 5 dieser Arbeit und Belehrung darüber, den Zugang zu den Daten nicht weiterzugeben und die Daten nicht für private Zwecke zu verwenden.
Zugangsbeschränkung	Der Zugang zu den Daten wird auf die Personen beschränkt, die tatsächlich mit ihnen arbeiten (vgl. § 22 Abs. 2 Nr. 5).
Pseudonymisierung	So viele personenbezogene Informationen wie für das Projekt möglich werden pseudonymisiert (vgl. § 22 Abs. 2 Nr. 6).
Fortführung festgelegter Maßnahmen	Die festgelegten Maßnahmen werden fortgeführt, falls die Social Media Daten zu anderen als den in Kap. X definierten Use Cases für wissenschaftliche Zwecke verwendet oder an andere übermittelt werden (vgl. § 22 Abs. 2 Nr. 10).
Ausschluss gelöschter Beiträge	Haben betroffene Personen ihre Inhalte auf der Social Media Plattform gelöscht, so werden diese auch keinen unbefugten Personen mehr über das Recommendation System angezeigt. Als unbefugte Person gilt in diesem Fall jeder, der keinen Zugang zur Datenbank hat.
Veröffentlichungen	Es werden keine Informationen veröffentlicht, die nicht (mehr) öffentlich auffindbar sind und eine Person identifizieren oder identifizierbar machen. Nur aggregierte Ergebnisse, wie etwa von Meinungsanalysen, werden veröffentlicht, ohne dabei Social Media Beiträge oder Accounts offenzulegen.

Maßnahme	Umsetzung
Löschung	Die Daten werden nur für die Dauer des ThWIC-Projektes gespeichert.

Tabelle 5.1: Maßnahmen und Möglichkeiten zur Umsetzung

6 Projekt: Datenbankentwurf

In diesem Kapitel wird ein Datenbankschema zur vereinheitlichten Speicherung von Mastodon- und BlueSky-Beiträgen erarbeitet. Dafür wird zunächst über die beiden Social Media Plattformen informiert. Außerdem werden die für die Suche nach Beiträgen verwendeten Endpunkte erläutert und es wird erklärt, welche Auswirkung die föderierte Netzwerkstruktur von Mastodon und BlueSky auf die Datensammlung hat. Anschließend werden die Response-Schemata für die verwendeten Endpunkte erläutert. Darauf aufbauend werden diese Schemata verglichen. Es wird für jede enthaltene Eigenschaft geprüft, ob sie im Response-Schema der anderen Plattform auch enthalten ist und ob sie für das ThWIC-Projekt von Relevanz ist und somit in die Datenbank aufgenommen wird. Darauf aufbauend wird schließlich das Datenbankschema als EER-Diagramm entworfen.

6.1 Verwendete Plattformen

Im Folgenden werden die Social Media Plattformen Mastodon und BlueSky vorgestellt. Es werden außerdem die für die Datensammlung verwendeten Such-Endpunkte aufgezeigt und es wird die Bedeutung der föderierten Netzwerkstruktur beider Plattformen erklärt.

6.1.1 Mastodon und BlueSky

Die Mastodon Software ist ein non-profit Microblogging-Netzwerk, das von der Mastodon gGmbH aus Deutschland entwickelt wird und im Oktober 2016 als Open-Source-Projekt veröffentlicht wurde. Ziel des Projektes ist es, die globale Kommunikation auf nicht kommerziellem Weg und unabhängig von einzelnen Organisationen oder Personen zu ermöglichen.¹ Dafür setzt das Mastodon-Team auf eine dezentrale Social Media Struktur, die auf dem ActivityPub-Protokoll aufgebaut ist² und aus mehreren Servern besteht. Jeder dieser Server wird dabei von einer unabhängigen Organisation oder Einzelperson betrieben und kann sich hinsichtlich „Moderationsstrategien“ unterscheiden. User müssen sich zur Verwendung von Mastodon dafür entscheiden, auf welchem der angebotenen Server ihr Konto erstellt werden soll. Unabhängig von der Wahl des Servers kann anschließend aber jeder anderen Person im Netzwerk gefolgt werden.³ Bereits im März 2024 hatte Mastodon mehr als zehn Millionen Registrierungen. Am 2.4.2024 zählt Mastodon 928.471 monatlich aktive Nutzer sowie 9623 laufende Server.⁴

Auch die Zielsetzung von Bluesky, das 2021 mit Sitz in Seattle (USA) gegründet wurde,⁵ ist es, eine von einzelnen Personen und Organisationen unabhängige, nicht-kommerzielle Social Media Plattform zu erschaffen.⁶ Dafür wird das vom Bluesky-Team selbst entwickelte AT Protocol verwendet.⁷ Seit Februar 2024 ist BlueSky für jeden zu-

¹Vgl. o.V. (o.J.): We develop Mastodon, Mastodon, Abrufdatum: 02.08.2024.

²Vgl. o.V. (o.J.): What is Mastodon, Mastodon, Abrufdatum: 02.08.2024.

³Vgl. o.V. (o.J.): Server, Mastodon, Abrufdatum: 02.08.2024.

⁴Vgl. o.V. (o.J.): We develop Mastodon, Mastodon, Abrufdatum: 02.08.2024.

⁵Vgl. o.V. (o.J.): Bluesky, Crunchbase, Abrufdatum: 02.08.2024.

⁶Vgl. o.V. (o.J.): Welcome to the social internet, Bluesky, Abrufdatum: 02.08.2024.

⁷Vgl. o.V. (o.J.): The AT Protocol, ATProtocol, Abrufdatum: 03.08.2024.

gänglich. Zuvor war ein Einladungscode nötig, um beitreten zu können.⁸ Seitdem gibt es einen rasanten Anstieg an Neuregistrierungen.⁹ Im Juli 2024 hat BlueSky über 6 Millionen Registrierungen. Es ist allerdings nicht angegeben, wie viele dieser Nutzer auch monatlich aktiv sind.¹⁰

6.1.2 Verwendete Such-Endpunkte

Der Mastodon Such-Endpunkt „/api/v2/search“ ermöglicht es, nach Beiträgen, Konten oder Hashtags zu suchen. Für die Datensammlung des ThWIC-Projekts wird die Suche nach Beiträgen vorgenommen. Dafür wird das gesuchte Schlüsselwort über den Parameter „q“ angegeben. Um dabei mehr als die aktuellsten 40 Beiträge zu erhalten, wird der „offset“-Parameter genutzt. Die Nutzung des offset-Parameters erfordert eine Autorisierung mittels eines Tokens.¹¹ Dieses kann durch die Erstellung einer Anwendung für einen registrierten Account erhalten werden.¹² Es ist dabei ein Rate Limit zu beachten, das i.d.R. 300 Anfragen aller fünf Minuten umfasst.¹³ Insgesamt gibt die Suchanfrage letztlich die Beiträge zurück, die die in „q“ angegebenen Schlüsselwörter enthalten. Dabei können bei einer Anfrage auch mehrere Wörter für „q“ angegeben werden. In diesem Fall wird nach Beiträgen gesucht, die alle der gesuchten Schlüsselwörter enthalten. Die Reihenfolge dieser im Beitrag und die Position der Wörter im Text spielen dabei keine Rolle.¹⁴ Die Möglichkeit zur Suche nach zusammengesetzten Schlüsselwörtern ist für die Datensammlung für das ThWIC-Projekt entscheidend, da für diese viele zusammengesetzte Schlüsselwörter ermittelt wurden (vgl. Anhang, Tab. 1).

Der BlueSky Such-Endpunkt „app.bsky.feed.searchPosts“ kann ähnlich verwendet werden. Auch hier können mit dem Parameter „q“ Schlüsselwörter angegeben werden, nach denen schließlich in den Beiträgen gesucht wird. Eine Autorisierung ist nicht erforderlich, auch dann nicht wenn man den „cursor“-Parameter (entspricht dem „offset“-Parameter in Mastodon) verwenden möchte. Die Reihenfolge der angegebenen Schlüsselwörter und deren Position im Beitrag beeinträchtigen nicht das Suchergebnis.¹⁵ Das Rate Limit liegt hierbei bei 3000 Anfragen aller fünf Minuten.¹⁶

6.1.3 Föderation

Sowohl Mastodon¹⁷ als auch BlueSky¹⁸ verwenden Protokolle, die eine sogenannte föderierte Netzwerkstruktur ermöglichen. Dies bedeutet, dass verschiedene Server („Instanzen“) unabhängig voneinander betrieben werden können, während sie dennoch miteinander kommunizieren und Daten austauschen können. Nutzer auf einer Instanz können also mit Nutzern auf anderen Instanzen interagieren.¹⁹

Hierbei ist allerdings zu beachten, dass die Föderation für die Nutzer beider Plattformen unterschiedliche Auswirkungen hat. Während die Wahl der Instanz für BlueSky Nutzer nicht beeinflusst, welche Inhalte sie im Sozialen Netzwerk sehen können,²⁰ können Mastodon Nutzer grundsätzlich nur auf Inhalte zugreifen, die auf ihrer eigenen Instanz veröffentlicht wurden. Beiträge anderer Instanzen werden nur angezeigt, wenn sie durch Aktionen wie das Folgen von Nutzern mit dieser Instanz verknüpft sind. Auch der in Mastodon verwendete Such-Endpunkt

⁸Vgl. Wilkens, A. (2024): Bluesky ist jetzt für alle offen, Heise, Abrufdatum: 02.08.2024.

⁹Vgl. Bunte, O. (2024): Bluesky wächst um 850.000 Nutzer am ersten Tag nach Öffnung, Heise, Abrufdatum: 02.08.2024.

¹⁰Vgl. o.V. (o.J.): Bluesky Post Count and Author Stats, Jaz Bluesky Index, Abrufdatum: 02.08.2024.

¹¹Vgl. o.V. (o.J.): search API methods, Mastodon, Abrufdatum: 07.07.2024.

¹²Vgl. o.V. (o.J.): Obtaining client app access, Mastodon, Abrufdatum: 07.07.2024.

¹³Vgl. o.V. (o.J.): Rate limits, Mastodon, Abrufdatum: 07.07.2024.

¹⁴Vgl. o.V. (o.J.): Using the network features, Mastodon, Abrufdatum: 07.07.2024.

¹⁵Vgl. o.V. (o.J.): app.bsky.feed.searchPosts, Bluesky, 07.07.2024.

¹⁶Vgl. o.V. (15.09.2024): Rate Limits, PDS Distribution v3, and More, BlueSky, Abrufdatum: 07.07.2024.

¹⁷Vgl. o.V. (o.J.): What is Mastodon, Mastodon, Abrufdatum: 07.07.2024.

¹⁸Vgl. o.V. (22.02.2024): An Open Social Web, BlueSky, Abrufdatum: 07.07.2024.

¹⁹Vgl. o.V. (o.J.): What is Mastodon, Mastodon, Abrufdatum: 07.07.2024.

²⁰Vgl. o.V. (22.02.2024): An Open Social Web, BlueSky, Abrufdatum: 07.07.2024.

(vgl. Kap. 6.1.2) gibt somit lediglich Beiträge zurück, die auf der Instanz gespeichert sind, auf der sich der für die Suchanfragen verwendete Account befindet. Deswegen kann es sinnvoll sein, Accounts auf unterschiedlichen Instanzen zu erstellen und auf diesen die Datensammlung vorzunehmen.²¹

Die Möglichkeit zur Föderation ist für BlueSky erst seit Februar 2024 gegeben, zuvor wurden die Inhalte zentralisiert auf den BlueSky Servern gespeichert. Vom BlueSky-Team wird zudem kommuniziert, dass derzeit noch technisches Know-How der Nutzer benötigt wird, um überhaupt einen BlueSky-Server für ihre Inhalte betreiben zu können.²² Ob sich die Föderation von BlueSky also weiterhin durchsetzt und die Anzahl neuer Instanzen tatsächlich zunimmt, bleibt abzuwarten. Auf die Menge an Beiträgen, die mittels der Suche nach Schlüsselwörtern von BlueSky gesammelt werden, wird sich die Föderation aber nicht auswirken, da die Wahl der Instanz nicht beeinflusst, auf welche Inhalte ein Nutzer zugreifen kann.²³

6.2 Response-Schemata

Im Folgenden werden die in den Response-Schemata der Such-Endpunkte (vgl. Kap. 6.1.2) enthaltenen Informationen der Plattformen Mastodon und BlueSky untersucht. Dies ist notwendig, um anschließend daraus ableiten zu können, welche dieser Informationen für das ThWIC-Projekt relevant sind und inwieweit sie mit den Daten der anderen Plattform zusammengeführt werden können.

6.2.1 Mastodon

Zuerst werden die Informationen über Mastodon-Beiträge untersucht, die über den verwendeten Such-Endpunkt erhalten werden. Ein beispielhafter Mastodon-Beitrag ist hierfür im Anhang (vgl. Anhang, Abb. 3) hinterlegt.

Informationen zum Beitrag

ID Identifiziert den Mastodon-Beitrag eindeutig.²⁴

Created_at Datum (ISO 8601 Datetime-Format), an dem der Mastodon-Beitrag erstellt wurde.²⁵

In_reply_to_id Ist nicht „null“, falls es sich bei dem Beitrag um eine Antwort auf einen Mastodon-Post handelt. Enthält in diesem Fall auch die ID des Posts auf den sich die Antwort bezieht.²⁶

In_reply_to_account_id Ist nicht „null“, falls es sich bei dem Beitrag um eine Antwort auf einen Mastodon-Post handelt. Enthält in diesem Fall auch die ID des Nutzers, dem mit dem jeweiligen Beitrag geantwortet wurde.²⁷

Sensitive Gibt in boolescher Form an, ob eine Markierung des Posts auf Grund von sensiblem Inhalt vorliegt.²⁸

Spoiler_text Gibt an, wieso der Beitrag auf Grund von sensiblem Inhalt²⁹ markiert wurde.³⁰

Visibility Gibt an, für welche Personen der Beitrag sichtbar ist. Es wird zwischen den visibility-Werten public, unlisted, private und direct unterschieden.³¹

Language Gibt die primäre Sprache des Beitrags an.³²

²¹Vgl. Wiegmann, M. et al. (2024): A Mastodon Corpus to Evaluate Federated Microblog Search, S. 37.

²²Vgl. o.V. (22.02.2024): An Open Social Web, BlueSky, Abrufdatum: 07.07.2024.

²³Vgl. o.V. (22.02.2024): An Open Social Web, BlueSky, Abrufdatum: 07.07.2024.

²⁴Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 05.04.2024.

²⁵Vgl. ebenda.

²⁶Vgl. ebenda.

²⁷Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 05.04.2024.

²⁸Vgl. ebenda.

²⁹Vgl. o.V. (o.J.): Translation, Mastodon, Abrufdatum: 02.08.2024.

³⁰Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 05.04.2024.

³¹Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 05.04.2024.

³²Vgl. ebenda.

URI Wird für die Föderation benötigt.³³

URL Enthält den Link zur HTML-Repräsentation des Beitrags.³⁴

Replies_count Integer-Wert, der die Anzahl an Antworten für den Beitrag angibt.³⁵

Reblogs_count Integer-Wert, der angibt, wie oft ein Beitrag „geboostet“ wurde³⁶, also wie oft er auf anderen Profilen geteilt wurde.³⁷

Favourites_count Integer Wert, der angibt, wie viele Favourites ein Beitrag bekommen hat.³⁸ Favourites sind dabei das gleiche wie Likes in Twitter oder BlueSky, sie geben also an, dass der Inhalt einem User gefällt.^{39 40 41}

Favourited (optional) Gibt in boolescher Form an, ob der Account, der den entsprechenden Beitrag betrachtet (also der für die API-Requests autorisierte User), diesen als Favorit markiert hat.⁴²

Reblogged (optional) Gibt in boolescher Form an, ob der anfragende (autorisierte) User den Beitrag geboostet⁴³, also auf dem eigenen Profil geteilt hat.⁴⁴

Muted (optional) Gibt in boolescher Form an, ob der anfragende (autorisierte) Account Meldungen zum Beitrag gemuted hat.⁴⁵

Bookmarked (optional) Gibt in boolescher Form an, ob der anfragende (autorisierte) Account für den Beitrag ein Lesezeichen gesetzt hat, um ihn besser auffinden zu können.⁴⁶

Content Beinhaltet den eigentlichen Inhalt in HTML-Format.⁴⁷

Reblog Ist nicht „null“, falls es sich um einen Beitrag handelt, der reposted wurde. Wurde der Beitrag reposted, ist hier der originale Status hinterlegt.⁴⁸

Application (optional) Gibt an, von welcher Anwendung aus der Beitrag veröffentlicht wurde.⁴⁹

Weitere Informationen über den Beitrag

Nach der Dokumentation kann es weitere Eigenschaften zu Mastodon-Beiträgen geben, die nicht im Beispielstatus enthalten sind:⁵⁰

Text Enthält den Inhalt („content“) eines Mastodon-Beitrags, falls dieser gelöscht wurde.⁵¹

Edited_at Enthält einen Zeitstempel (ISO 8601 Datetime), der angibt, wann der Beitrag das letzte Mal bearbeitet wurde.⁵²

pinned (optional) Gibt an, ob der anfragende (autorisierte) User den Beitrag angeheftet hat.⁵³

filtered (optional) Falls der den Beitrag anfragende User Filter definiert hat, zu denen er keine oder nur eingeschränkt Beiträge angezeigt bekommen möchte, sind diese hier hinterlegt. Diese Filter basieren insbesondere auf

³³Vgl. ebenda.

³⁴Vgl. ebenda.

³⁵Vgl. ebenda.

³⁶Vgl. ebenda.

³⁷Vgl. o.V. (o.J.): statuses API methods, Mastodon, Abrufdatum: 03.08.2024.

³⁸Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 05.04.2024.

³⁹Vgl. o.V. (o.J.): 4 key differences between Twitter and Mastodon, Opensource, Abrufdatum: 03.08.2024.

⁴⁰Vgl. o.V. (o.J.): Using the network features, Mastodon, Abrufdatum: 03.08.2024.

⁴¹Vgl. o.V. (o.J.): app.bsky.feed.getActorLikes, Bluesky, Abrufdatum: 03.08.2024.

⁴²Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 05.04.2024.

⁴³Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 05.04.2024.

⁴⁴Vgl. o.V. (o.J.): statuses API methods, Mastodon, Abrufdatum: 03.08.2024.

⁴⁵Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 05.04.2024.

⁴⁶Vgl. ebenda.

⁴⁷Vgl. ebenda.

⁴⁸Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 05.04.2024.

⁴⁹Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 05.04.2024.

⁵⁰Vgl. ebenda.

⁵¹Vgl. ebenda.

⁵²Vgl. ebenda.

⁵³Vgl. ebenda.

Schlüsselwörtern.⁵⁴

Account-Informationen

In dem **Account** Merkmal eines Mastodon-Beitrags geht es um den Account, der entsprechenden Beitrag verfasst hat. Über ihn werden folgende Informationen preisgegeben:⁵⁵

ID ID des Accounts.⁵⁶

Username Der vom User vergebene Name für den Account.⁵⁷

Acct WebFinger-URI des Accounts, entspricht dem Username bei lokalen Accounts, und Username@Domain für externe Accounts.⁵⁸

Display_name Name, der anderen Usern angezeigt wird.⁵⁹

Locked Gibt in boolescher Form an, ob der Account Folgeanfragen manuell oder automatisch genehmigt.⁶⁰

Bot Gibt in boolescher Form an, ob entsprechender Mastodon Account automatisierte Aktionen durchführt, nicht überwacht wird oder sich generell als Roboter identifiziert.⁶¹

Discoverable Gibt in boolescher Form an,⁶² ob der Account beim Durchstöbern von Accounts gefunden werden kann.⁶³

Noindex (optional) Gibt in boolescher Form an,⁶⁴ ob der User einverstanden ist, dass seine Beiträge von Suchmaschinen gefunden werden können.⁶⁵

Moved (optional) Gibt an, ob das Profil inaktiv ist und der User einen neuen Account (ggf. auf einer anderen Instanz) hat.⁶⁶

Suspended (optional) Gibt in boolescher Form an, ob der Account aufgelöst wurde.⁶⁷

Limited (optional) Gibt in boolescher Form an, ob der Account hinter einer Warnung angezeigt wird.⁶⁸

Group Gibt in boolescher Form an, ob der Account Mitglied einer Mastodon Gruppe ist.⁶⁹

Created_at Gibt den Zeitpunkt (ISO 8601 Datetime) an, zu dem der Account erstellt wurde.⁷⁰

Note Enthält die Beschreibung des Mastodon Accounts.⁷¹

Url Enthält die Adresse der Profilseite des Users.⁷²

Avatar Gibt die URL zu dem Profilbild an, das für den jeweiligen Account verwendet wird.⁷³

Avatar_static Gibt für das Profilbild an, ob es sich um ein statisches Bild oder eines mit Animationen handelt.⁷⁴

Header Gibt die URL für das Banner-Bild eines Accounts an, welches z.B. oberhalb des Profils angezeigt wird.⁷⁵

⁵⁴Vgl. o.V. (o.J.): Filter, Mastodon, Abrufdatum: 02.08.2024.

⁵⁵Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 05.04.2024.

⁵⁶Vgl. o.V. (o.J.): Account, Mastodon, Abrufdatum: 05.04.2024.

⁵⁷Vgl. ebenda.

⁵⁸Vgl. ebenda.

⁵⁹Vgl. o.V. (o.J.): Setting up your profile, Mastodon, Abrufdatum: 05.08.2024.

⁶⁰Vgl. o.V. (o.J.): Account, Mastodon, Abrufdatum: 05.04.2024.

⁶¹Vgl. ebenda.

⁶²Vgl. ebenda.

⁶³Vgl. o.V. (o.J.): Setting up your profile, Mastodon, Abrufdatum: 05.08.2024.

⁶⁴Vgl. o.V. (o.J.): Account, Mastodon, Abrufdatum: 05.04.2024.

⁶⁵Vgl. o.V. (o.J.): Set your preferences, Mastodon, Abrufdatum: 05.08.2024.

⁶⁶Vgl. o.V. (o.J.): Account, Mastodon, Abrufdatum: 05.04.2024.

⁶⁷Vgl. o.V. (o.J.): Account, Mastodon, Abrufdatum: 05.04.2024.

⁶⁸Vgl. o.V. (o.J.): Account, Mastodon, Abrufdatum: 05.04.2024.

⁶⁹Vgl. o.V. (o.J.): Account, Mastodon, Abrufdatum: 06.04.2024.

⁷⁰Vgl. ebenda.

⁷¹Vgl. ebenda.

⁷²Vgl. ebenda.

⁷³Vgl. ebenda.

⁷⁴Vgl. ebenda.

⁷⁵Vgl. ebenda.

Header_static Gibt für Banner-Bilder in Mastodon an, ob es sich um ein statisches oder animiertes Bild handelt.⁷⁶

Followers_count Integer-Wert, der die Anzahl an Followern für das Mastodon Profil angibt.⁷⁷

Following_count Integer-Wert, der angibt, wie vielen Accounts der Mastodon Nutzer folgt.⁷⁸

Statuses_count Integer-Wert, der angibt, wie viele Beiträge dem Account zugeordnet sind.⁷⁹

Last_status_at Gibt für Mastodon Accounts den Zeitstempel (ISO 8601 Date) an, zu dem der letzte Beitrag veröffentlicht wurde.⁸⁰

Emojis Sind vom User selbst ausgewählte Emojis, die die Ansicht eines Profils ergänzen können.⁸¹

Fields Enthält zusätzliche Metadaten, die der Nutzer seinem Profil als Name-Wert-Paare angefügt werden können.⁸² Dies soll dazu dienen, dass Profilbesucher bis zu vier wesentliche Informationen, wie das Alter oder das Heimatland des Users, schnell überfliegen können.⁸³

Medienanhänge

Unter **media_attachments** können zusätzliche Informationen zu Medien enthalten sein, die mit dem Mastodon-Beitrag angezeigt werden.⁸⁴ Dabei kann es sich um ein Bild, ein Video, eine Animation oder eine Audio-Datei handeln. Ansonsten fällt das Medium in die Kategorie „unknown“.⁸⁵

Erwähnungen anderer Nutzer

Falls das **mentions**-Merkmal nicht leer ist, ist dort hinterlegt, welche anderen Mastodon User in entsprechendem Beitrag markiert, bzw. „erwähnt“ wurden.⁸⁶ Für jede Erwähnung sind folgende Informationen gegeben:⁸⁷

ID Account-ID des erwähnten Users.

Username Benutzername des erwähnten Users.

Url Adresse der Profilseite des Users.

Acct Die Webfinger-Account-URI des erwähnten Users. Entspricht für lokale Nutzer dem Benutzernamen, für externe Benutzer hat sie hingegen das Schema Benutzername@Domain.⁸⁸

Hashtags

Falls im Beitrag Hashtags verwendet wurden, so sind diese in der **tags** Eigenschaft hinterlegt.⁸⁹ Für jeden Hashtag sind folgende Informationen gegeben:

Name Die Bezeichnung des Hashtags.

Url Ein Link zum Hashtag auf jeweiliger Instanz.⁹⁰

Emojis

⁷⁶Vgl. ebenda.

⁷⁷Vgl. ebenda.

⁷⁸Vgl. ebenda.

⁷⁹Vgl. ebenda.

⁸⁰Vgl. ebenda.

⁸¹Vgl. ebenda.

⁸²Vgl. ebenda.

⁸³Vgl. o.V. (o.J.): Setting up your profile, Mastodon, Abrufdatum: 05.08.2024.

⁸⁴Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 05.04.2024.

⁸⁵Vgl. o.V. (o.J.): MediaAttachment, Mastodon, Abrufdatum: 07.04.2024.

⁸⁶Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 05.04.2024.

⁸⁷Vgl. ebenda.

⁸⁸Vgl. ebenda.

⁸⁹Vgl. ebenda.

⁹⁰Vgl. ebenda.

Unter „emojis“ können vom Autor individuell erstellte oder andere extern auffindbare Emojis enthalten sein, die an den Beitrag angehängt wurden.⁹¹ Sie können statisch oder animiert sein und es muss eine URL zu entsprechender Ressource hinterlegt werden.⁹² Da sie für das ThWIC-Projekt nicht von Relevanz sind, werden zusätzliche Informationen zu ihnen hier nicht weiter aufgeführt.

Voransichten von Webseiten

Im **card** Merkmal können Voransichten für im Mastodon Beitrag enthaltene Links hinterlegt sein.⁹³ Diese sind für das ThWIC-Projekt ebenso nicht relevant, sodass auf sie nicht weiter eingegangen wird.

Umfrage

Falls dem Mastodon-Beitrag eine Umfrage beigelegt wurde, so sind in der **Poll**-Eigenschaft Informationen über diese gespeichert:⁹⁴

ID Die ID der Umfrage in der Mastodon-Datenbank.

Expires_at Zeitstempel (ISO 8601 Datetime) der angibt, wann die Umfrage endet.

Expired Boolean, die angibt, ob die Umfrage bereits abgelaufen ist.

Multiple Boolean, die angibt, ob in der Umfrage Multiple-Choice-Antworten erlaubt sind.

Votes_count Anzahl an insgesamt abgegeben Stimmen.

Voters_count Falls „multiple“ true ist, wird hier angegeben, wie viele Accounts insgesamt abgestimmt haben.

Voted Boolean, die angibt, ob der den Beitrag anfragende Account in der Umfrage abgestimmt hat.

Own_votes Falls „voted“ true ist, ist hier hinterlegt, für welche Optionen abgestimmt wurde.

Options Enthält Informationen zu den einzelnen Auswahlmöglichkeiten der Umfrage. Zu jeder Option sind dabei folgende Angaben hinterlegt:

„title“: Der Text der entsprechenden Wahlmöglichkeit.

„votes_count“: Die Anzahl aller Stimmen für diese Option.

Emojis Hier können vom Autor individuell erstellte oder andere extern auffindbare Emojis hinterlegt sein, die der Umfrage angehängt wurden.⁹⁵

6.2.2 BlueSky

Im Folgenden sind alle obligatorischen sowie optionalen Bestandteile eines Posts gemäß AT Protocol⁹⁶ erklärt. Dazu findet sich ein beispielhafter Post in JSON-Format zu dem Schlüsselwort „Wasserknappheit“ im Anhang (vgl. Abb. 7).

Informationen zum Beitrag in der Voransicht

URI URIs dienen der eindeutigen Adressierung von Ressourcen im Internet und ermöglichen so die Interaktion mit dieser.⁹⁷ In diesem Fall wird also der jeweilige Post adressiert. Die in der URI enthaltene **DID** („**Decentralized Identifier**“) identifiziert zudem den BlueSky Account, von dem der Post getätigt wurde.⁹⁸ Weiterhin enthält die URI den Record Key („**rkey**“) des Beitrags,⁹⁹ der diesen identifiziert.¹⁰⁰

⁹¹Vgl. ebenda.

⁹²Vgl. o.V. (o.J.): CustomEmoji, Mastodon, Abrufdatum: 06.04.2024.

⁹³Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 05.04.2024.

⁹⁴Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 05.04.2024.

⁹⁵Vgl. o.V. (o.J.): Poll, Mastodon, Abrufdatum: 09.04.2024.

⁹⁶Vgl. o.V. (o.J.): app.bsky.feed.defs, The AT Protocol SDK, Abrufdatum: 01.05.2024.

⁹⁷Vgl. o.V. (2019): URI: der Uniform Resource Identifier erklärt, IONIOS, Abrufdatum: 10.05.2024.

⁹⁸Vgl. o.V. (o.J.): AT Protocol DIDs, ATProtocol, Abrufdatum: 10.05.2024.

⁹⁹Vgl. o.V. (o.J.): AT URI Scheme, ATProtocol, Abrufdatum: 11.05.2024.

¹⁰⁰Vgl. o.V. (o.J.): Record Keys, ATProtocol, Abrufdatum: 11.05.2024.

CID („Content Identifier“) CIDs sind kryptographische Hashes, die basierend auf dem Inhalt einer Ressource berechnet werden. Sie dienen der eindeutigen Identifizierung von Ressourcen, ohne dabei den Speicherort des Inhalts preiszugeben.^{101 102}

Account-Informationen

Hier sind einige Informationen über den Account („**Autor**“) hinterlegt, von dem der Beitrag veröffentlicht wurde: **DID („Decentralized Identifiers“)** Identifiziert den Account, also den „Autor“ des Posts. Ist auch der URI zu entnehmen (vgl. Abschnitt „URI“).

Handle Dient ebenfalls der Identifikation des Accounts. Handles sind für Menschen i.d.R. besser lesbar als DIDs, allerdings sind sie im Gegensatz zu DIDs nicht unbedingt dauerhaft.¹⁰³ Bei einem BlueSky-Handle handelt es sich um die Domain des Accounts. Normalerweise wird die Domain vom Server automatisch nach dem Schema `username.bsky.social` erstellt. Diese kann aber auch durch eine eigene Domain ersetzt werden.¹⁰⁴

Display Name Kann als Ersatz für lange und für Menschen schlecht lesbare Handles wirken.¹⁰⁵

Avatar Profilbild des Accounts bzw. des Autors.^{106 107}

Viewer Beinhaltet Informationen über die Beziehung zwischen dem Request-Account und dem betroffenen Account, bspw. ob der Account geblockt („`blocked_by`“) oder gemuted („`muted`“) wurde.¹⁰⁸

Labels Hier können Labels hinterlegt sein. Labels dienen in BlueSky der Moderation und können jedem Account sowie jedem Inhalt angehängt werden.¹⁰⁹ So können z.B. Inhalte für entsprechenden Account mit einer Warnung überdeckt werden, falls sie mit einem kritischen Label, wie „Pornographie“ oder „Gewalt“ gelabelt wurden.¹¹⁰

Created_at Gibt an, wann der Account erstellt wurde (Datetime-Format).¹¹¹

Informationen über den Inhalt des Beitrags

In BlueSky werden unterschiedliche Arten von Nutzerbeiträgen, z.B. Posts, Kommentare und Likes, als **Records** bezeichnet.¹¹² Zu Records gehören folgende Informationen:

Type Gibt die Art des Records an. Bei API-Anfragen die lediglich Posts zurückgeben sollen, wie im Rahmen dieses Projektes, wird es sich hierbei also stets um den Post-Typ, also „`app.bsky.feed.post`“, handeln.¹¹³

Created_at Ist der vom Herausgeber des Posts angehängte Zeitstempel (Datetime-Format¹¹⁴), wann der Record (hier: Beitrag) erstellt wurde.¹¹⁵

Facets Sind optionale Vermerke zum Text, die z.B. angeben, ob URLs, Links, Hashtags,¹¹⁶ Erwähnungen oder „rich text“ für die Text-Dekoration enthalten ist.¹¹⁷ Ein **Feature** enthält die Art des Vermerks (z.B. rich text) sowie ggf. weitere Informationen, wie die URI bei Links.¹¹⁸ Außerdem muss für jedes Feature ein **Index** Bereich

¹⁰¹Vgl. o.V. (o.J.): Data Model, ATProtocol, Abrufdatum: 11.05.2024.

¹⁰²Vgl. o.V. (o.J.): What is a CID, IPFS, Abrufdatum: 11.05.2024.

¹⁰³Vgl. o.V. (o.J.): Handle, ATProtocol, Abrufdatum: 11.05.2024.

¹⁰⁴Vgl. Liu, E. (2023): How to set your domain as your handle, Bluesky, Abrufdatum: 11.05.2024.

¹⁰⁵Vgl. o.V. (o.J.): Handle, ATProtocol, Abrufdatum: 11.05.2024.

¹⁰⁶Vgl. o.V. (o.J.): profile.json, GitHub, Abrufdatum: 11.05.2024.

¹⁰⁷Vgl. o.V. (o.J.): defs.json, GitHub, Abrufdatum: 11.05.2024.

¹⁰⁸Vgl. o.V. (o.J.): app.bsky.actor.defs, The AT Protocol SDK, Abrufdatum: 11.05.2024.

¹⁰⁹Vgl. o.V. (o.J.): Labels, ATProtocol, Abrufdatum: 11.05.2024.

¹¹⁰Vgl. o.V. (2024): Bluesky's Moderation Architecture, Bluesky, Abrufdatum: 11.05.2024.

¹¹¹Vgl. o.V. (o.J.): app.bsky.feed.searchPosts, Bluesky, Abrufdatum: 10.05.2024.

¹¹²Vgl. o.V. (o.J.): Protocol Overview, ATProtocol, Abrufdatum: 10.05.2024.

¹¹³Vgl. o.V. (o.J.): app.bsky.feed.post, The AT Protocol SDK, Abrufdatum: 10.05.2024.

¹¹⁴Vgl. o.V. (o.J.): Timestamps, Bluesky, Abrufdatum: 10.05.2024.

¹¹⁵Vgl. o.V. (o.J.): app.bsky.feed.post, The AT Protocol SDK, Abrufdatum: 10.05.2024.

¹¹⁶Vgl. ebenda.

¹¹⁷Vgl. o.V. (o.J.): Links, mentions, and rich text, Bluesky, Abrufdatum: 10.05.2024.

¹¹⁸Vgl. o.V. (o.J.): app.bsky.richtext.facet, The AT Protocol SDK, Abrufdatum: 13.05.2024.

mit dem für das jeweilige Feature relevanten Teilbereich der Daten angegeben sein.¹¹⁹ Durch rich text können Links, Erwähnungen und Hashtags hervorgehoben werden.¹²⁰

Text Enthält den Inhalt eines Posts.¹²¹

Embed Ein BlueSky-Beitrag kann verschiedene Arten eingebetteter Medienanhänge haben, nämlich Bilder, andere BlueSky-Beiträge, andere BlueSky-Beiträge mit Medienanhang und externe Inhalte¹²² wie Links oder Webpage Cards (also Vorschauansichten von Webseiten).¹²³ Je nach Art des Medien-Anhangs werden unterschiedliche Response-Schemata verwendet.¹²⁴

Langs Gibt die Sprache des Beitrags an.¹²⁵

Reply Falls es sich bei dem Beitrag um eine Antwort handelt, ist hier sowohl der direkt beantwortete Beitrag („parent“) als auch der ursprüngliche Beitrag („root“),¹²⁶ jw. durch Angabe der **CID** und **URI** hinterlegt.¹²⁷

Weitere Informationen zum Beitrag in der Voransicht

Embed Falls der eigentliche Beitrag („record“) einen Mediananhang hat, kann hier die Voransicht für diesen gegeben sein.¹²⁸

Reply Count Integer-Wert, gibt die Anzahl der Antworten auf den Beitrag an.

Repost Count Integer-Wert, gibt die Anzahl an Reposts des Beitrags an.

Like Count: Integer-Wert, gibt die Anzahl an Likes für den Post an.¹²⁹

Indexed_at Zeitstempel, wann der Post das erste Mal vom API-Server registriert wurde. Falls der Post nachträglich verändert wird, ändert er sich ggf.¹³⁰

Viewer Unter diesem Viewer-Merkmal werden Informationen über die Beziehung zwischen dem Request-Account und entsprechendem Inhalt angezeigt. Hier ist hinterlegt, ob der anfragende User den Beitrag geliked hat, ob er ihn reposted hat und ob er darauf antworten darf.¹³¹

Labels Vgl. „labels“ unter Abschnitt Account-Informationen.¹³²

6.3 Vereinheitlichung der Response-Schemata

In diesem Kapitel wird überprüft, inwieweit sich die zuvor beschriebenen Informationen aus Mastodon-Beiträgen (vgl. Kap. 6.2.1) in BlueSky-Beiträgen (vgl. Kap. 6.2.2) wiederfinden. Außerdem wird diskutiert, ob jeweilige Informationen beider Social Media Plattformen für das ThWIC Projekt relevant sind und ob sie somit in die Datenbank aufgenommen werden. Es wird dabei in allen Unterkapiteln nach der in Mastodon-Posts gegebenen Reihenfolge (vgl. Anhang, Abb. 3 und Kap. 6.2.1) vorgegangen. Es stellte sich heraus, dass dadurch bereits alle für BlueSky-Beiträge zurückgegebenen Informationen mit abgedeckt werden, sodass diese anschließend nicht separat betrachtet werden müssen. Das Ergebnis über die benötigten Daten beider Plattformen wird abschließend in

¹¹⁹Vgl. o.V. (o.J.): app.bsky.richtext.facet, The AT Protocol SDK, Abrufdatum: 13.05.2024.

¹²⁰Vgl. o.V. (o.J.): Links, mentions, and rich text, Bluesky, Abrufdatum: 10.05.2024.

¹²¹Vgl. o.V. (o.J.): app.bsky.feed.post, The AT Protocol SDK, Abrufdatum: 15.05.2024.

¹²²Vgl. o.V. (o.J.): app.bsky.feed.defs, The AT Protocol SDK, Abrufdatum: 11.05.2024.

¹²³Vgl. o.V. (o.J.): Posts, Bluesky, Abrufdatum: 21.05.2024.

¹²⁴Vgl. o.V. (o.J.): app.bsky.feed.post, The AT Protocol SDK, Abrufdatum: 15.05.2024.

¹²⁵Vgl. ebenda.

¹²⁶Vgl. ebenda.

¹²⁷Vgl. o.V. (o.J.): com.atproto.repo.strong_ref, The AT Protocol SDK, Abrufdatum: 15.05.2024.

¹²⁸Vgl. o.V. (o.J.): app.bsky.feed.defs, The AT Protocol SDK, Abrufdatum: 11.05.2024.

¹²⁹Vgl. ebenda.

¹³⁰Vgl. o.V. (o.J.): Timestamps, Bluesky, Abrufdatum: 10.05.2024.

¹³¹Vgl. o.V. (o.J.): app.bsky.feed.defs, The AT Protocol SDK, Abrufdatum: 11.05.2024.

¹³²Vgl. o.V. (o.J.): com.atproto.label.defs, The AT Protocol SDK, Abrufdatum: 12.05.2024.

Kapitel 6.3.10 für jedes Unterkapitel übersichtlich als Tabelle dargestellt. Außerdem werden zusätzliche Merkmale erläutert, die aus unterschiedlichen Gründen mit in die Datenbank aufgenommen werden sollen.

6.3.1 Informationen zum Beitrag

„**id**“ In Mastodon ist ein einzelner Status mittels des Endpunktes `GET /api/v1/statuses/:id HTTP/1.1` auffindbar, sofern die ID des Beitrags und die Mastodon-Instanz, auf der er veröffentlicht wurde, bekannt ist.¹³³ Ein Beispiel für einen HTTP-Request an diesen Endpunkt ist: `https://mastodon.social/api/v1/statuses/112463731738026471`. In BlueSky kann ein Post mittels des `getRecord` Endpunktes bei Bekanntheit der Instanz, des „r-keys“, des Handles oder der DID sowie der NSID der record collection gefunden werden.¹³⁴ Die NSID der record collection ist dabei stets `app.bsky.feed.post`.¹³⁵ Dabei ist zu beachten, dass handles sich ändern können, falls der User sie ändert. Es sollte unter anderem deswegen die DID statt dem handle verwendet werden.¹³⁶ Der r-key kann aus der URI extrahiert werden (vgl. Kap. 6.2.2). Ein Beispiel-Request für den `getRecord` Endpunkt ist: `https://bsky.social/xrpc/com.atproto.repo.getRecord?repo=jubo.bsky.social&collection=app.bsky.feed.post&rkey=3ky463jlx7x2e`. Um einen einzelnen Post für das ThWIC-Projekt auffinden zu können, wird also für Mastodon-Beiträge die ID und für BlueSky-Beiträge stattdessen der „r-key“ gespeichert. Dafür wird in der SQL-Datenbank die Spalte „`post_id`“ eingeführt. Die DID von BlueSky-Posts wird später ebenso gespeichert, um einen Post finden zu können. Da sie aber den Autor identifiziert, und nicht dessen Beitrag, ist sie eher mit der ID des Autors in Mastodon vergleichbar (vgl. Kap. 6.3.3, Abschnitt „ID“).

„**created_at**“ Sowohl Mastodon-Posts als auch BlueSky-Posts haben stets die `created-at` Eigenschaft. Für beide Plattformen beinhaltet sie den Zeitstempel als ISO 8601 Datetime-Format als String, der angibt, wann der Beitrag erstellt wurde.^{137 138}

Für die herausgearbeiteten Use Cases (vgl. Kap. 4) ist der Zeitstempel z.B. relevant, um Beiträge einem zu untersuchenden Ereignis, wie einer Überschwemmung, zuordnen zu können.

Der Unterschied zwischen beiden Plattformen ist hierbei, dass Mastodon den Zeitstempel erst serverseitig erstellt, also sobald der Post an die API gesendet wurde.¹³⁹ In BlueSky muss der Zeitstempel direkt bei Erstellung eines Posts durch den Beiträgersteller, also clientseitig, festgelegt werden.¹⁴⁰ Dadurch könnte sich also eine geringe zeitliche Differenz ergeben. Außerdem könnte der Zeitstempel für BlueSky-Posts prinzipiell leichter verfälscht werden.¹⁴¹

Allerdings wird davon ausgegangen, dass normalerweise das GUI der jeweiligen Plattform verwendet wird, um einen Post zu erstellen, sodass kein inkorrekt angegebener Zeitstempel zustande kommt.

Zudem ist die zeitliche Verzögerung zwischen dem clientseitigen Herausgeben des Beitrags und dem serverseitigen Empfang minimal, da die Übertragung des Postes vom Client zum Server i.d.R. nur wenige (Milli-)Sekunden in Anspruch nimmt.

Zudem ist es für das ThWIC-Projekt bzw. für die in Kapitel 4 herausgearbeiteten Use Cases irrelevant, ob ein Beitrag wenige Sekunden früher oder später erstellt wurde.

Somit wird die `created_at` Eigenschaft als Spalte in die Datenbank aufgenommen. Als Inhalte dafür dienen die `created-at` Informationen der jeweiligen Posts beider Plattformen. Auch wenn die tatsächlichen Zeitstempel unter-

¹³³Vgl. o.V. (o.J.): `statuses API methods`, Mastodon, Abrufdatum: 24.08.2024.

¹³⁴Vgl. o.V. (o.J.): `com.atproto.repo.getRecord`, Bluesky, Abrufdatum: 29.06.2024.

¹³⁵Vgl. o.V. (o.J.): `app.bsky.feed.post`, The AT Protocol SDK, Abrufdatum: 15.05.2024.

¹³⁶Vgl. o.V. (o.J.): `AT URI Scheme`, ATProtocol, Abrufdatum: 17.05.2024.

¹³⁷Vgl. o.V. (o.J.): `Status`, Mastodon, Abrufdatum: 25.04.2024.

¹³⁸Vgl. o.V. (o.J.): `Creating a post`, Bluesky, Abrufdatum: 14.06.2024.

¹³⁹Vgl. o.V. (o.J.): `statuses API methods`, Mastodon, Abrufdatum: 03.08.2024.

¹⁴⁰Vgl. o.V. (o.J.): `Creating a post`, Bluesky, Abrufdatum: 14.06.2024.

¹⁴¹Vgl. o.V. (o.J.): `Timestamps`, Bluesky, Abrufdatum: 30.05.2024.

schiedlich vergeben werden, kann von einer guten Vergleichbarkeit zwischen den Plattformen ausgegangen werden, da die tatsächlichen Unterschiede beider Erfassungsvarianten sehr gering ausfallen sollten.

Falls zukünftig weitere Use Cases bearbeitet werden sollen und dafür Vergleichbarkeit im Sekundenbereich der `created_at` Spalte vorausgesetzt wird, können weitere Maßnahmen wie Aufrunden der BlueSky-Zeitstempel oder Addition weniger Millisekunden bei den Zeitstempeln der BlueSky-Posts in Betracht gezogen werden.

„in_reply_to_id“: Auch bei BlueSky-Beiträgen ist ersichtlich, auf welchen Beitrag geantwortet wird bzw. ob es sich um eine Antwort handelt. Im Gegensatz zu Mastodon-Beiträgen wird hier zusätzlich zwischen dem ursprünglichen Beitrag und dem direkten Beitrag, auf den geantwortet wird (welcher selbst ebenfalls eine Antwort auf einen anderen Beitrag sein kann), unterschieden (vgl. Kap. 6.2.2).

In den in Kap. 4 definierten Use Cases geht es u.a. darum, die Meinungen zu bestimmten Themen im Bereich „Wasser“ zu analysieren. Es ist naheliegend, dass Antworten auf Beiträge für diese Aufgabe gut geeignet sein können. Außerdem kann es sinnvoll sein, die ursprünglichen Beiträge zu kennen. Denn dadurch können z.B. diejenigen Beiträge identifiziert werden, auf die besonders häufig u.a. mit für das ThWIC-Projekt relevanten Schlüsselwörtern geantwortet wurde.

Mastodon-Antworten werden deswegen in die Datenbank für das ThWIC-Projekt aufgenommen, indem der Eintrag von `in_reply_to_id` unter dem selben Merkmal in die Datenbank eingefügt wird. Für BlueSky-Beiträge, auf die sich die Antwort direkt bezieht, wird unter `in_reply_to_id` der r-key gespeichert. Für die ursprünglichen Beiträge einer BlueSky-Antwort wird der r-key hingegen unter der Eigenschaft `related_to_post_id` in die Datenbank aufgenommen.

„in_reply_to_account_id“: Für BlueSky-Antworten ist sowohl für Beiträge auf die direkt geantwortet wird, als auch für die ursprünglichen Beiträge, die URI angegeben. Aus dieser kann die DID extrahiert werden (vgl. Kap. 6.2.2), die mit der ID eines Accounts in Mastodon vergleichbar ist (vgl. Kap. 6.2.1).

Die DIDs von BlueSky-Beiträgen werden benötigt, um sie aufzufinden (vgl. Abschnitt „ID“). Generell kann durch Kenntnis der eindeutigen Kennungen von Accounts nach denjenigen gefiltert werden, die häufig Beiträge oder Antworten mit den enthaltenen relevanten Schlüsselwörtern veröffentlicht haben.

Deswegen werden sowohl die IDs der Mastodon-Accounts als auch die DIDs der BlueSky-Profile unter `in_reply_to_account_id` in der Datenbank für das ThWIC-Projekt gespeichert. Die DIDs der ursprünglichen BlueSky-Beiträge werden unter dem Merkmal `related_to_account_id` erfasst.

„sensitive“: Die sensitive Eigenschaft gibt in Mastodon in boolescher Form an, ob eine Markierung des Posts auf Grund von sensiblem Inhalt vorliegt.¹⁴² In BlueSky-Posts ist zur Markierung von sensiblem Inhalt die `labels` Eigenschaft gegeben, die nicht in boolescher Form angibt, ob der Beitrag markiert ist, sondern stattdessen den Grund bzw. mehrere Gründe dafür enthält. So sind bspw. Stichworte wie „Gewalt“ hinterlegt (vgl. Kap. 6.2.2, Abschnitt labels). Die Gründe zur Markierung von sensiblem Inhalt finden sich für Mastodon-Beiträge im `spoiler_text`-Merkmal.

Solche Markierungen werden in BlueSky sowie in Mastodon hauptsächlich zur Moderation verwendet, sie sind also z.B. entscheidend dafür, ob bestimmten Usern die Beiträge angezeigt werden oder lediglich verdeckt angezeigt werden. Daraus lässt sich schließen, dass eine Kennzeichnung von sensiblen Inhalten auch in Recommendation Systemen verwendet werden kann, um das Ranking der Beiträge mitzubestimmen. Auch falls z.B. extreme Meinungen der User zum Thema Wasserversorgung preisgegeben werden und deswegen markiert werden, kann diese Information für Analysen von Interesse sein.

Somit kann die Information, ob und wieso es sich um sensible Inhalte handelt, auch für das ThWIC-Projekt relevant sein. Deswegen wird der Grund für die Markierung für Beiträge von beiden Plattformen als `sensitive` Merkmal in die Datenbank aufgenommen. Die boolesche Information, ob ein Beitrag markiert wurde, wird damit

¹⁴²Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 25.04.2024.

überflüssig. Denn es kann einfach geprüft werden, ob ein Grund zur Markierung hinterlegt ist. Falls ja, gilt der Inhalt als sensibel, ansonsten nicht.

„spoiler_text“: s. Abschnitt „sensitive“

„visibility“: BlueSky-Beiträge sind stets öffentlich und somit beliebigen Personen im Internet zugänglich. Deswegen kann bei ihnen nicht festgelegt werden, für welche Personen ein Beitrag sichtbar bzw. nicht sichtbar ist.¹⁴³ Dementsprechend haben BlueSky-Beiträge auch kein mit „visibility“ vergleichbares Merkmal.

Die default-visibility für Mastodon-Beiträge ist „public“, was bedeutet, dass der Beitrag auch von nicht auf Mastodon registrierten Usern auffindbar ist.¹⁴⁴ Außerdem kann er beim Scrollen nach neuen, potenziell interessanten Inhalten angezeigt werden. Dabei können nämlich alle Beiträge mit der visibility public des Servers sowie Beiträge, die anderweitig etwas mit dem Server zu tun haben (z.B. über User auf dem eigenen Server, die Usern auf einem anderen Server folgen), angezeigt werden.¹⁴⁵

Ist der Wert stattdessen auf „unlisted“ gesetzt, so ist der Beitrag weiterhin für alle User sichtbar. Allerdings kann er nicht mehr durchs Scrollen nach neuen Inhalten entdeckt werden.¹⁴⁶ Ob Beiträge mit der unlisted Markierung trotzdem in den Suchergebnissen des in dieser Arbeit verwendeten Such-Endpunktes auffindbar sind, geht aus der Dokumentation nicht hervor.¹⁴⁷ Deswegen wurde ein Experiment durchgeführt. Hierfür wurde ein solcher Post veröffentlicht (vgl. Anhang, Abb. 1) und anschließend über einen HTTP-Request¹⁴⁸ mit den Schlüsselwörtern „strive“ und „combat“, für den keine Authentifizierung verwendet wurde, wieder aufgefunden (vgl. Anhang, Abb. 2). Somit werden also sowohl Beiträge mit der public-visibility, als auch mit der unlisted-visibility über den verwendeten Endpunkt zurückgegeben.

Weiterhin kann die visibility-Eigenschaft den Wert private oder direct annehmen. Dadurch ist der Beitrag lediglich für Follower des Herausgebers sowie im Beitrag erwähnte User oder einzig für im Beitrag erwähnte User sichtbar.¹⁴⁹ Da der für die API-Anfragen verwendete Endpunkt Beiträge mit diesen Sichtbarkeitseinstellungen also generell nicht zurückgeben sollte, wird davon ausgegangen, dass Beiträge mit diesen visibility Einträgen im Rahmen des ThWIC-Projektes gar nicht gehandhabt werden müssen.

Es muss also lediglich zwischen public und unlisted differenziert werden. Wenn ein Post von anderen nicht durch Scrollen durch Inhalte entdeckt werden soll, kann dies bedeuten, dass der User andere User nicht mit für sie wahrscheinlich irrelevanten Beiträgen oder Kommentaren zu Posts belasten möchte. Dies kann auch fürs Recommendation System sinnvoll sein, um unlisted-Beiträge mit geringerer Präferenz als public-Beiträge auszugeben.

Deswegen wird die visibility-Eigenschaft in die Datenbank fürs ThWIC-Projekt aufgenommen. Da aber lediglich zwischen public und unlisted differenziert werden muss, wird die Information als boolescher Wert erfasst, um weniger Speicherplatz zu benötigen. Ist der Beitrag public, so wird „visibility“ auf den Wert „1“ gesetzt, andernfalls auf „0“.

„language“: Die Sprache des Inhalts wird von den Herausgebern des Mastodon-Beitrags eigenständig festgelegt und vom System nicht kontrolliert. So wurde bspw. ein Post in deutscher Sprache erstellt, ohne dabei die Default-Einstellung, nämlich dass der Post auf Englisch geschrieben ist, zu ändern (vgl. Anhang, Abb. 4). Bei einer Abfrage dieses Posts wird trotzdem weiterhin Englisch als Sprache angegeben (vgl. Anhang, Abb. 5). Dies zeigt, dass die Sprach-Information häufig falsch sein kann.

Bei der Erstellung von BlueSky Beiträgen kann man ebenfalls die Sprache einstellen, wobei Englisch wieder als Default-Sprache festgelegt ist. Auch in BlueSky wurde ein Beitrag in deutscher Sprache erstellt und die Default-

¹⁴³Vgl. o.V. (o.J.): Data Privacy, Bluesky, Abrufdatum: 14.07.2024.

¹⁴⁴Vgl. o.V. (o.J.): Posting to your profile, Mastodon, Abrufdatum: 17.07.2024.

¹⁴⁵Vgl. o.V. (o.J.): Using the network features, Mastodon, Abrufdatum: 16.07.2024.

¹⁴⁶Vgl. o.V. (o.J.): Posting to your profile, Mastodon, Abrufdatum: 17.07.2024.

¹⁴⁷Vgl. o.V. (o.J.): search API methods, Mastodon, Abrufdatum: 18.07.2024.

¹⁴⁸Vgl. o.V. (o.J.): search API methods, Mastodon, Abrufdatum: 18.07.2024.

¹⁴⁹Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 26.06.2024.

Spracheinstellung dabei unverändert gelassen (vgl. Anhang, Abb. 6). Anschließend wurde dieser Beitrag über den verwendeten Such-Endpunkt mit dem Schlüsselwort „Wasserknappheit“ wieder aufgefunden. Hier wurde die Sprache also ebenso nicht vom System überprüft und ist dementsprechend falsch hinterlegt (vgl. Anhang, Abb. 7). Bei Betrachtung der Tabellen mit den in den Beiträgen zu suchenden Schlüsselwörtern fällt auf, dass es sich bei diesen lediglich um englische Wörter handelt (vgl. Tab. 1). Das bedeutet, dass auf jeden Fall in allen über die Endpunkte erhaltenen Beiträgen Wörter in englischer Sprache enthalten sein müssen.

Aufgrund dieses bedingten Vorhandenseins englischer Wörter in allen über den Endpunkt erhaltenen Beiträgen und der Unverlässlichkeit bezüglich Korrektheit der Sprachangabe, wird die language-Eigenschaft nicht in die Datenbank für das ThWIC-Projekt aufgenommen.

„uri:“ Die URI eines Mastodon-Beitrags enthält die Mastodon-Instanz, den Namen des Beitrag-Herausgebers sowie die ID des Beitrags.¹⁵⁰

Die Kenntnis über den Namen des Autors bringt für das ThWIC-Projekt keinen erkennbaren Nutzen und soll zudem aus datenschutzrechtlichen Gründen nicht gespeichert werden (vgl. Kap. 5). Die ID des Beitrags wurde bereits in die Datenbank aufgenommen (vgl. Abschnitt „ID“). Der Name der Mastodon-Instanz auf der entsprechender Beitrag veröffentlicht wurde, wird hingegen für die Auffindbarkeit des Posts benötigt (vgl. auch Abschnitt „ID“).¹⁵¹ Deswegen wird er aus der URI der Beiträge extrahiert und in die Datenbank unter dem Merkmal „instance_name“ eingefügt.

Auch für BlueSky-Beiträge muss der Instanz-Name bekannt sein, um einen Beitrag aufrufen zu können.¹⁵² Dieser lässt sich lediglich aus dem handle extrahieren (vgl. Kap. 6.2.2). Handelt es sich bei den Beiträgen um Beiträge der bsky.social Instanz, so gelingt dies durch Extraktion des Strings „bsky.social“ aus dem handle. Sind die Beiträge auf einer anderen Instanz gespeichert, dann wird das gesamte handle als Instanz-Name gespeichert.

„url:“ Der URL eines Mastodon-Beitrags sind die selben Informationen wie der URI zu entnehmen,¹⁵³ sie enthält also keine weiteren brauchbaren Inhalte. Auch für BlueSky-Beiträge wurden bereits alle relevanten Informationen herausgesucht, die es ermöglichen, einen Beitrag aufzufinden (vgl. Abschnitte „ID“ und „URI“). In der Datenbank für das ThWIC-Projekt wird die URL deswegen nicht benötigt.

„replies_count:“ Auch für BlueSky-Beiträge gibt es die Eigenschaft „replyCount“, die angibt, wie viele Antworten für den Beitrag verfasst wurden (vgl. Kap. 6.2.2).

Die Anzahl der Antworten kann in einem Recommendation System als Indikator für die Relevanz eines Beitrags dienen, da eine hohe Anzahl an Antworten oft ein starkes Interesse der Community an den im Beitrag behandelten Themen signalisiert. Aus diesem Grund wird diese Information als „replies_count“ in die Datenbank für das ThWIC-Projekt aufgenommen und für jeden Beitrag erfasst. Da sich die Anzahl an Antworten auf einen Beitrag im Zeitverlauf ändern kann, beispielsweise weil die im Beitrag behandelte Thematik an Relevanz gewinnt, könnten hierfür regelmäßige Updates der ThWIC-Datenbank durchgeführt werden. Dadurch könnte das Recommendation System mit aktuelleren Zahlen arbeiten und somit ein präziseres Ranking vornehmen.

„reblogs_count:“ Die Häufigkeit, mit der ein Beitrag auf anderen Profilen geteilt wurde, wird in Mastodon-Beiträgen durch das Merkmal reblogs_count und in BlueSky-Beiträgen durch die Eigenschaft repostCount angegeben.^{154 155}

Wenn ein Beitrag häufig geteilt wurde, kann dies ebenfalls auf ein Interesse der Community an entsprechendem Inhalt hinweisen und somit für ein Recommendation System nützlich sein. Deswegen werden die Werte als reposts_count in die Datenbank aufgenommen. Auch bei diesem Wert können regelmäßige Aktualisierungen der

¹⁵⁰Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 26.06.2024.

¹⁵¹Vgl. o.V. (o.J.): statuses API methods, Mastodon, Abrufdatum: 13.08.2024.

¹⁵²Vgl. o.V. (o.J.): com.atproto.repo.getRecord, Bluesky, Abrufdatum: 29.06.2024.

¹⁵³Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 26.06.2024.

¹⁵⁴Vgl. o.V. (o.J.): app.bsky.feed.defs, The AT Protocol SDK, Abrufdatum: 23.06.2024.

¹⁵⁵Vgl. o.V. (o.J.): Applications model, ATProtocol, Abrufdatum: 23.06.2024.

Datenbank sinnvoll sein, damit das Recommendation System mit aktuellen Daten die Relevanz von Beiträgen beurteilen kann.

„favourites _count:“ In BlueSky-Beiträgen wird die Anzahl der Likes durch die Eigenschaft likeCount gespeichert, während in Mastodon-Beiträgen dafür das Merkmal favourites _count verwendet wird.

Falls ein Beitrag von vielen Usern geliked wurde, so kann dies auch das Ranking eines Recommendation Systems beeinflussen. Die Anzahl an Likes wird somit in die Datenbank unter der Spalte likes _count aufgenommen. Hierbei gilt ebenso, dass Aktualisierungen der Datenbank vorgenommen werden sollten, um mit zeitgemäßen Werten arbeiten zu können.

„favourited (optional):“

In BlueSky-Posts wird unter der Eigenschaft „viewer“ eine Information bereitgestellt, die wie in Mastodon-Beiträgen angibt, ob der anfragende (autorisierte) Account den Beitrag geliked hat (vgl. Kap. 6.2.2).¹⁵⁶

Da die Requests aber mit Accounts ausgeführt werden, die lediglich der Informationsbeschaffung für das ThWIC-Projekt dienen, ist nicht davon auszugehen, dass von diesen Accounts aus Beiträge geliked werden. Die favourited Information wird deswegen verworfen und nicht in die Datenbank erfasst.

„reblogged (optional):“ Für BlueSky-Beiträge findet sich die Information, ob der den Beitrag anfragende Account den Beitrag „reposted“ hat unter der „viewer“-Eigenschaft.¹⁵⁷

Sie wird aus dem selben Grund wie die favourited Information aber nicht in die Datenbank aufgenommen (vgl. Abschnitt „favourited“).

„muted (optional):“ Eine vergleichbare Information dazu, ob der anfragende (autorisierte) Account Meldungen zum entsprechenden Beitrag gemuted hat, wird für BlueSky-Beiträge nicht bereitgestellt¹⁵⁸ (vgl. Kap. 6.2.2).

Sie wird aus dem selben Grund wie die favourited Information nicht in die Datenbank aufgenommen (vgl. Abschnitt „favourited“).

„bookmarked (optional):“ Auch hier gibt es für BlueSky-Beiträge keine vergleichbare Information dazu, ob der anfragende (autorisierte) Account für entsprechenden Beitrag ein Lesezeichen gesetzt hat (vgl. Kap. 6.2.2).

Aus im favourited-Abschnitt erwähntem Grund ist nicht davon auszugehen, dass der für die API-Anfragen verwendete Account auf Beiträge reagiert. Die bookmarked-Information wird deswegen ebenso nicht in die Datenbank aufgenommen.

„content:“ In BlueSky ist der eigentliche Inhalt von Beiträgen unter der text-Eigenschaft gegeben (vgl. Kap. 6.2.2). Allerdings wird statt HTML eine andere Logik („rich text“) verwendet, um Text, Links, Erwähnungen von Usern und dekorierten Text darzustellen.¹⁵⁹

Da es nach Kap. 4 zu den für dieses Projekt definierten Hauptaufgaben gehört, die Inhalte von Beiträgen zu erhalten und zu speichern, wird die Information für Beiträge beider Plattformen als String in der Spalte „content“ in die ThWIC-Datenbank eingefügt. Dabei bleiben die unterschiedlichen Repräsentationen zunächst unberücksichtigt. Bei Bedarf können sie während des Preprocessings der Daten, das je nach zu bearbeitendem Use Case unterschiedlich ausfallen kann (vgl. Kap. 4), weiter vereinheitlicht werden.

„reblog:“ Für BlueSky-Beiträge wird nicht angegeben, ob es sich bei entsprechendem Beitrag um einen Repost handelt bzw. wo der originale Beitrag auffindbar ist (vgl. Kap. 6.2.2).

In der Dokumentation des verwendeten Endpunktes für die Suche nach Beiträgen in Mastodon steht lediglich, dass nach Beiträgen, Accounts und Hashtags gesucht wird.¹⁶⁰ Reposts werden also scheinbar nicht direkt über diesen Endpunkt gefunden.

¹⁵⁶Vgl. o.V. (o.J.): app.bsky.feed.defs, The AT Protocol SDK, Abrufdatum: 23.06.2024.

¹⁵⁷Vgl. o.V. (o.J.): app.bsky.feed.defs, The AT Protocol SDK, Abrufdatum: 27.06.2024.

¹⁵⁸Vgl. o.V. (o.J.): app.bsky.feed.defs, The AT Protocol SDK, Abrufdatum: 27.06.2024.

¹⁵⁹Vgl. o.V. (o.J.): Links, mentions, and rich text, Bluesky, Abrufdatum: 18.07.2024.

¹⁶⁰Vgl. o.V. (o.J.): Search, Mastodon, Abrufdatum: 29.07.2024.

Ein Experiment dazu zeigt, dass Reposts von dem verwendeten Endpunkt tatsächlich nicht zurückgegeben werden. Für dieses Experiment wurde ein eigener Post erstellt und geboostet (vgl. Anhang, Abb. 8). Anschließend wurde eine Suchanfrage mittels des verwendeten Such-Endpunktes durchgeführt, und zwar ohne Autorisierung¹⁶¹ und mit den im Post verwendeten Schlüsselwörtern „strive combat“, also <https://mastodon.social/api/v2/search?q=strive%20combat>. Alle 20 dadurch erhaltenen Beiträge wurden in Notepad++ nach dem String „strive to combat“, der im originalen Post enthalten ist, durchsucht. So wurde lediglich ein Ergebnis angezeigt, und zwar nicht der Repost, sondern der originale Beitrag, der vorher veröffentlicht wurde (vgl. Anhang, Abb. 9). Das selbe Experiment wurde mit Beiträgen wiederholt, die von anderen Accounts stammen, mit gleichem Ergebnis.

Demnach wird die reblog-Information bei Verwendung dieses Endpunktes stets den Wert „null“ annehmen. Für eine Datenanalyse oder Recommendation Systeme ist sie also nicht brauchbar und wird nicht in die Datenbank aufgenommen.

„application (optional):“ Für BlueSky-Beiträge gibt es keine Information darüber, von welcher Anwendung aus der Beitrag veröffentlicht wurde (vgl. Kap. 6.2.2).

In den in Kapitel 4 definierten Use Cases fürs ThWIC-Projekt geht es stets um den Inhalt von Beiträgen oder die Reaktionen der User auf die Beiträge. Dahingehend ist die Information, von welcher Anwendung aus etwas veröffentlicht wurde, irrelevant. Deswegen wird sie auch nicht in der Datenbank benötigt.

6.3.2 Weitere Informationen über den Beitrag

„text:“ Falls BlueSky-Beiträge gelöscht wurden, gibt es bei ihnen keine Information über den ursprünglichen Inhalt (vgl. Kap. 6.2.2). Ob gelöschte Mastodon-Beiträge überhaupt mittels verwendetem Such-Endpunkt aufgefunden werden und ob dieses Merkmal somit von Relevanz für diese Arbeit ist, geht aus der Dokumentation nicht hervor.¹⁶²

Es wurde ein Experiment durchgeführt, um dies zu überprüfen. Dafür wurde zuerst ein Mastodon-Beitrag erstellt (vgl. Anhang, Abb. 11). Wie erwartet, wurde dieser auch über den Such-Endpunkt aufgefunden (vgl. Anhang, Abb. 12). Nun wurde der Beitrag über das GUI gelöscht. Dabei fiel auf, dass es zwei Möglichkeiten gibt, einen Beitrag zu löschen. Nämlich die Option „Delete“ sowie die Option „Delete & redraft“ (vgl. Anhang, Abb. 13). Zunächst wurde die „normale“ Delete-Option ausgewählt. Anschließend wurde der Beitrag mit der Such-Anfrage nicht mehr aufgefunden (vgl. Anhang, Abb. 14). Das selbe Experiment wurde mit der „Delete & redraft“-Möglichkeit wiederholt. Es wurde also ein Beitrag erstellt (vgl. Anhang, Abb. 15). Dieser wurde auch mit dem Such-Endpunkt aufgefunden (vgl. Anhang, Abb. 16). Nach Auswahl der „Delete & redraft“-Möglichkeit (vgl. Anhang, Abb. 17) wurde eine Warnung angezeigt, die darüber informiert, dass Likes, Antworten und Reposts dabei verloren gehen (vgl. Anhang, Abb. 18). Die Option wurde trotzdem ausgewählt. Dadurch konnte ein weiterer Mastodon-Beitrag erstellt werden, der sich inhaltlich gänzlich von dem ursprünglichen Beitrag unterscheidet (vgl. Anhang, Abb. 19). Anschließend wurde dieser neue Beitrag über die Schlüsselwort-Suche angezeigt (vgl. Anhang, Abb. 21). Der ursprüngliche Beitrag ist über den Such-Endpunkt allerdings nicht mehr auffindbar (vgl. Anhang, Abb. 20). Auch bei der Suche nach dem konkreten Beitrag mittels seiner ID (vgl. Kap. 6.3.1, Abschnitt „ID“), wird er nicht mehr zurückgegeben (vgl. Anhang, Abb. 22).

Es kann also davon ausgegangen werden, dass die „text“-Eigenschaft bei dem verwendeten Such-Endpunkt stets leer ist und somit auch keinen Nutzen für das ThWIC-Projekt hat. Sie wird also nicht in die Datenbank aufgenommen.

„edited_at:“ Einen Zeitstempel der angibt, wann ein Beitrag das letzte Mal bearbeitet wurde, ist für BlueSky-Beiträge durch das „indexedAt“-Merkmal hinterlegt (vgl. Kap. 6.2.2). Im Gegensatz zu Mastodon ist hier allerdings entweder die Information gegeben, wann der Beitrag zuerst von der BlueSky-API registriert wurde, oder, falls er

¹⁶¹Vgl. o.V. (o.J.): search API methods, Mastodon, Abrufdatum: 18.07.2024.

¹⁶²Vgl. o.V. (o.J.): search API methods, Mastodon, Abrufdatum: 14.07.2024.

nachträglich bearbeitet wurde, entsprechend dieser Zeitpunkt.¹⁶³

Die Kenntnis darüber, wann ein Beitrag das letzte Mal bearbeitet wurde, kann für einige der in Kapitel 4 definierten Use Cases relevant sein, beispielsweise für die Reaktionsanalyse auf einen bestimmten Beitrag bzw. eine Nachricht. Dieser Beitrag könnte z.B. vor der Bearbeitung eher kontrovers hinsichtlich eines spezifischen Themas ausgerichtet gewesen sein und dadurch viele negative Kommentare erhalten haben. Nach Bearbeitung könnten sich diese Reaktionen ändern oder zahlenmäßig abnehmen. Ohne die Kenntnis darüber, dass der Beitrag nachträglich bearbeitet wurde, wäre das Ergebnis einer Reaktionsanalyse in so einem Fall also verfälscht.

Deswegen wird der Zeitstempel zum Bearbeitungszeitpunkt beider Plattformen als „`edited_at`“-Eigenschaft in die Datenbank für das ThWIC-Projekt aufgenommen. Bei Verwendung dieser Information ist zu beachten, dass der Wert für Mastodon-Beiträge leer ist, falls der Beitrag nicht bearbeitet wurde.¹⁶⁴ Für nicht bearbeitete BlueSky-Beiträge gilt in diesem Fall hingegen, dass das Erstellungsdatum des Beitrags eingetragen ist.¹⁶⁵

„pinned (optional):“ Für BlueSky-Beiträge gibt es keine vergleichbare Information darüber, ob der anfragende User den Beitrag angeheftet hat (vgl. Kap. 6.2.2, v.a. Abschnitt „viewer“).

Da der Request-Account lediglich der Informationsbeschaffung für das ThWIC-Projekt dient, wird nicht davon ausgegangen, dass von ihm aus ein Beitrag angeheftet wird. Das „pinned“-Merkmal wird somit nicht in die Datenbank aufgenommen.

„filtered (optional):“ Für BlueSky-User gibt es keine Möglichkeit, Schlüsselwörter zu definieren, zu denen keine Beiträge angezeigt werden sollen (vgl. Kap. 6.2.2).

Da der die Beiträge anfragende Account keine Filter definiert, ist diese Information auch nicht relevant für das ThWIC-Projekt und wird somit nicht in der Datenbank gespeichert.

6.3.3 Account-Informationen

Sowohl in Mastodon- als auch in BlueSky-Beiträgen sind Informationen über den **Account** bzw. den User gegeben, der den Beitrag veröffentlicht hat. Einige Kenntnisse über diesen können für das Recommendation System oder einen der definierten Use Cases von Vorteil sein.

„id:“ Als BlueSky-Äquivalent wird hierfür die DID innerhalb der URI zurückgegeben, die ebenso einen Account eindeutig identifiziert (vgl. Kap. 6.2.2). Für einige in Kapitel 4 definierte Use Cases kann die ID bzw. die DID sinnvoll verwendet werden, bspw. um zu analysieren, ob ein bestimmter Account mehrere Beiträge im selben Themenbereich herausgegeben hat. Denn so kann dieser als Experte in diesem Bereich identifiziert werden und ggf. als Ansprechpartner o.ä. im ThWIC-Projekt unterstützen. Somit wird die Mastodon-Account-ID sowie die DID eines BlueSky-Accounts als „`account_id`“ in die Datenbank aufgenommen.

„username:“ Für BlueSky Accounts kann das handle mit dem username von Mastodon-Accounts verglichen werden. Hierzu wurde bereits erläutert, dass lediglich der Instanzname extrahiert und gespeichert werden soll (vgl. z.B. Abschnitt „URI“).

Für ein Recommendation System oder für in Kapitel 4 definierte Use Cases bringt die Bekanntheit des Mastodon-username keinen Vorteil. Auch aus datenschutzrechtlichen Gründen (vgl. Kap. 5) soll dieser Name nicht in die Datenbank aufgenommen werden, insbesondere da der User hier seinen richtigen Namen angegeben haben könnte.

„acct:“ Für BlueSky-Beiträge gibt es dieses Merkmal nicht, obwohl BlueSky-„handels“ hier wieder vergleichbar sind (vgl. Kap. 6.2.2).

Da der Benutzername aber nicht gespeichert werden soll (vgl. Kap. 5) und die Domain bereits aus der URI extrahiert wird (vgl. Abschnitt „URI“), wird die „acct“-Eigenschaft für das ThWIC-Projekt nicht benötigt. Auch

¹⁶³Vgl. o.V. (o.J.): Timestamps, Bluesky, Abrufdatum: 29.05.2024.

¹⁶⁴Vgl. o.V. (o.J.): Status, Mastodon, Abrufdatum: 26.07.2024.

¹⁶⁵Vgl. o.V. (o.J.): Timestamps, Bluesky, Abrufdatum: 29.05.2024

die Verwendung von BlueSky-„handels“ wurde bereits erläutert (vgl. Abschnitt „URI“) und wird deswegen an dieser Stelle nicht weiter ausgeführt.

„display_name“: Aus den selben Gründen wie der username, wird er nicht in der Datenbank gespeichert (vgl. Abschnitt „username“). Selbiges gilt für die äquivalente Information „displayName“ (vgl. Kap. 6.2.2) aus BlueSky-Beiträgen.

„locked“: Für BlueSky-Accounts gibt es kein vergleichbares Merkmal im Response-Schema des verwendeten Such-Endpunktes darüber, ob Folgeanfragen erst manuell bestätigt werden müssen (vgl. Kap. 6.2.2). Einen Vorteil für einen der in Kapitel 4 beschriebenen Use Cases oder das Recommendation System bringt die Kenntnis über diese Information auch nicht. Sie wird deswegen nicht in die Datenbank aufgenommen.

„bot“: Eine vergleichbare Information darüber, ob es sich beim jeweiligen Account um einen automatisierten Account („Bot“) handelt, existiert für BlueSky Accounts derzeit nicht.¹⁶⁶ Diskussionen über die Implementierung einer solchen gibt es allerdings bereits, sodass es ggf. möglich ist, dass BlueSky Accounts zukünftig auch als Bots markiert werden können.¹⁶⁷

Die Unterscheidung zwischen Bot-Konten und regulären Benutzerkonten könnte fürs ThWIC-Projekt relevant sein, z.B. könnten Beiträge von Menschen eher als verlässlicher angesehen werden und dadurch bevorzugt vom Recommendation System zurückgegeben werden. Besonders für Meinungsanalysen kann es zudem sinnvoll sein, Bots von diesen auszuschließen.

Deswegen wird die bot-Information als boolesche Variable in die Datenbank aufgenommen. Für BlueSky-Beiträge bleiben die jeweiligen Einträge zunächst leer. Sollte es zukünftig tatsächlich relevant werden, auch über BlueSky Beiträge zu erfahren, ob sie von Menschen verfasst wurden, so kann nochmals geprüft werden, ob die Information bis dahin eingeführt wurde. Falls ja, kann sie nachträglich extrahiert und in der Datenbank gespeichert werden.

„discoverable“: Für BlueSky-Accounts gibt es keine Information darüber, ob ein Account über Entdeckungsverfahren für Profile gefunden werden kann.¹⁶⁸ Ein Nutzen der discoverable-Eigenschaft für das ThWIC-Projekt besteht nach den definierten Use Cases in Kapitel 4 nicht. Sie wird somit auch nicht in der Datenbank erfasst.

„noindex“: Für BlueSky-User ist kein Merkmal hinterlegt, das angibt, ob ihre Beiträge von Suchmaschinen gefunden werden können (vgl. Kap. 6.2.2). Das liegt u.a. daran, dass in BlueSky grundsätzlich alle Inhalte öffentlich sind.¹⁶⁹

Für das ThWIC-Projekt kann diese Information sinnvoll sein. Denn falls der User tatsächlich gegen das Auffinden seiner Beiträge ist, sollten entsprechende Beiträge aus datenschutzrechtlichen Gründen auch nicht in einem Recommendation Systems ausgegeben werden. Gegebenenfalls könnte ein solcher Beitrag allerdings trotzdem für einige in Kapitel 4 definierten Analysen eingesetzt werden.

Das „noindex“-Merkmal wird also unter dem selben Namen in die Datenbank aufgenommen. Einträge dazu können aber nur für Mastodon Accounts vorgenommen werden.

„moved“: Falls ein BlueSky-Account den Server wechselt, ist dies nicht im Response-Schema angegeben (vgl. Kap. 6.2.2).

Für das ThWIC-Projekt wäre es relevant zu wissen, ob sich durch die Migration auf einen anderen Server etwas an der Auffindbarkeit der Mastodon-Beiträge oder Accounts ändert. Dies ist der Dokumentation allerdings nicht zu entnehmen.¹⁷⁰ Um dieser Frage nachgehen zu können, wurde ein Experiment durchgeführt. Dafür wurde zunächst ein Mastodon-Account auf der „mstdn.social“-Instanz erstellt (vgl. Anhang, Abb. 23), der auf einen bereits bestehenden Account wechseln soll. Von diesem aus wurde ein Beitrag gepostet (vgl. Anhang, Abb. 24). Dieser Beitrag wurde auch über den verwendeten Such-Endpunkt (vgl. Kap. 6.1.2) aufgefunden (vgl. Anhang,

¹⁶⁶Vgl. o.V. (o.J.): app.bsky.actor, The ATProtocol, Abrufdatum: 26.07.2024.

¹⁶⁷Vgl. o.V. (o.J.): I would like you to implement a flag for bot accounts, GitHub, Abrufdatum: 25.07.2024.

¹⁶⁸Vgl. o.V. (o.J.): app.bsky.actor, The ATProtocol, Abrufdatum: 26.07.2024.

¹⁶⁹Vgl. o.V. (o.J.): Bluesky App Privacy Policy, Bluesky, Abrufdatum: 09.07.2024.

¹⁷⁰Vgl. o.V. (o.J.): Moving or leaving accounts, Mastodon, Abrufdatum: 10.07.2024.

Abb. 25). Um den Account nun auf einen anderen Server zu migrieren, muss zuerst ein „Alias“ für den neuen Account gewählt werden. Dieses sollte dem Namen des alten Accounts entsprechen.¹⁷¹ Also wurde ein solches Alias von dem neuen Account aus erstellt (vgl. Anhang, Abb. 26). Von dem alten Account aus wurde nun zu einem anderen Account, der auf einer anderen Instanz (nämlich „mastodon.social“) gehostet ist, verwiesen (vgl. Anhang, Abb. 27). Dies entspricht bereits einer Account-Migration.¹⁷² Bei erneuter Anfrage des Such-Endpunktes mit dem alten Instanz-Namen wird nun nach wie vor der erstellte Beitrag angezeigt. Dabei sind die Account-Informationen sowohl für den neuen als auch für den alten Account angegeben. Die neuen Account-Daten sind aber unter der „moved“-Eigenschaft hinterlegt (vgl. Anhang, Abb. 28). Der neue Account lässt sich mittels neuem Instanz-Namen und neuer ID allerdings nicht auffinden (vgl. Anhang, Abb. 29). Außerdem fällt auf, dass die neue ID des Accounts weder mit der ID des alten Accounts übereinstimmt, noch mit der ID des Accounts, auf den verwiesen wurde (vgl. Anhang, Abb. 30). Der Beitrag selbst kann auch weiterhin mit seiner ursprünglichen ID und dem ursprünglichen Instanz-Namen aufgerufen werden (vgl. Anhang, Abb. 31). Der alte Account kann aufgefunden werden, indem der ursprüngliche Instanz-Name sowie die durch die Migration neu vergebene ID verwendet wird (vgl. Anhang, Abb. 32). Informationen über den Account vor der Migration können nach wie vor über die alte Instanz sowie die alte Account-ID aufgefunden werden (vgl. Anhang, Abb. 33).

Für das ThWIC-Projekt kann es sinnvoll sein, Account-Migrationen zu kennen. So können z.B. als interessant identifizierte Accounts weiterhin verfolgt werden.

Deswegen wird die Information, ob ein Nutzer den Account gewechselt hat, in die Datenbank aufgenommen. Dabei ist es zunächst ausreichend, die neue ID als „new_account_id“ zu speichern. Denn der Nutzer kann mit ihr sowie dem alten Instanz-Namen, der ja bereits aus der URI extrahiert wird (vgl. Abschnitt „uri“), aufgefunden werden. **„suspended“:** Mittels des verwendeten BlueSky Such-Endpunktes wird über für Accounts nicht preisgegeben, ob sie suspendiert sind (vgl. Kap. 6.2.2). Bei einer Auflösung eines Mastodon-Accounts gilt u.a., dass alle Beiträge und weitere hochgeladene Inhalte nicht mehr aufgefunden werden können.¹⁷³ Somit kann davon ausgegangen werden, dass über die Mastodon-Suche nach Schlüsselwörtern stets lediglich Beiträge von aktiven, also nicht-suspendierten Usern, angezeigt werden.

Deswegen wird dieses Merkmal auch nicht in die Datenbank für das ThWIC-Projekt aufgenommen.

„limited“: Auch BlueSky-Accounts können mit einer Warnung verdeckt angezeigt werden. Hier wird diese Information aber nicht in boolescher Form angegeben, sondern es sind die Gründe für die Warnung in der „labels“-Eigenschaft hinterlegt (vgl. Kap. 6.2.2, Abschnitt „labels“).

Für ein Recommendation-System kann die Kenntnis darüber, ob ein Account mit einer Warnung versehen ist, z.B. dafür verwendet werden, Account mit Warnung entsprechend bevorzugt oder benachteiligt auszugeben. Der Grund für die Warnung kann bei dem Ranking prinzipiell auch berücksichtigt werden. Allerdings sollen durch das Recommendation System primär Beiträge, und keine Accounts, gerankt werden (vgl. Kap. 1.2). Für Beiträge wurde der Grund für eine Markierung bereits in die Datenbank aufgenommen (vgl. Abschnitte „sensitive“ und „spoiler_text“). Es wird deswegen davon ausgegangen, dass die Gründe für Warnungen vor einem Account nicht mehr benötigt werden.

Um bei Bedarf trotzdem diejenigen Accounts auffinden zu können, die markiert wurden, wird das Merkmal „sensitive“ auch für Accounts in die Datenbank eingeführt. In diesem wird lediglich in boolescher Form angegeben, ob ein Mastodon- oder BlueSky-Account markiert wurde. Sollten die Gründe für die Markierung von BlueSky-Accounts relevant werden, können diese nachträglich noch geprüft und eingefügt werden.

„group“: Für BlueSky Accounts gibt es keine Information darüber, ob er ein Akteur einer BlueSky-Gruppe ist (vgl. Kapitel 6.2.2). Zwar wäre es für das Recommendation System und ggf. auch für einige in Kapitel 4 definierten Use

¹⁷¹Vgl. o.V. (o.J.): Moving or leaving accounts, Mastodon, Abrufdatum: 10.07.2024.

¹⁷²Vgl. o.V. (o.J.): Moving or leaving accounts, Mastodon, Abrufdatum: 10.07.2024.

¹⁷³Vgl. o.V. (o.J.): Moderation actions, Mastodon, Abrufdatum: 15.07.2024.

Cases sinnvoll zu erfassen, bei welcher Gruppe ein Account Mitglied ist. So könnte ein Recommendation System beispielsweise Gruppen mit vielen Mitgliedern als relevanter einstufen und so auch Beiträge von deren Mitgliedern höher im Ranking platzieren.

Da hier allerdings lediglich preisgegeben wird, ob der Account zu einer Gruppe gehört, und nicht zu welcher, wird die Information fürs ThWIC-Projekt nicht benötigt und dementsprechend nicht in der Datenbank erfasst.

„created_at:“ Mittels des zur Suche von BlueSky-Beiträgen verwendeten Endpunktes wird über Accounts ebenso zurückgegeben, wann sie erstellt wurden (vgl. Kap. 6.2.2).

Im ThWIC-Projekt kann das Wissen über das Erstellungsdatum eines Accounts z.B. für das Recommendation System sinnvoll sein, um die Aktivität und damit auch die Seriosität des Nutzers einzuschätzen. Wurde beispielsweise seit einem bereits Jahre zurückliegenden Erstellungsdatum lediglich ein Beitrag veröffentlicht, kann daraus geschlossen werden, dass der User mittlerweile wahrscheinlich inaktiv ist, was wiederum das Ranking im Recommendation System beeinflussen kann. Deswegen wird das Erstellungsdatum als „created-at“-Merkmal in die Datenbank eingefügt.

„note:“ In der für BlueSky-Beiträge verwendeten Suchfunktion ist eine solche Account Beschreibung nicht in der API-Response enthalten (vgl. Kap. 6.2.2). Allerdings ist prinzipiell für jeden BlueSky Account¹⁷⁴ eine Beschreibung gespeichert.¹⁷⁵ Unter Angabe der DID des Accounts, die ja bereits in die ThWIC-Datenbank aufgenommen wurde (vgl. z.B. Abschnitt „URI“), können die Account-Beschreibungen für jeden BlueSky Account über den `getProfile` Endpunkt separat angefragt und extrahiert werden.¹⁷⁶

Für das Recommendation System können Account Beschreibungen sinnvoll eingesetzt werden. Beispielsweise kann überprüft werden, ob der Text für das ThWIC-Projekt relevante Wörter wie „science“ oder „water“ enthält. Falls ja, können von entsprechendem Account herausgegebenen Beiträgen höhere Relevanz-Werte zugeschrieben werden. Deswegen wurde entschieden, die Profilbeschreibungen unter „description“ im String Format in die Datenbank aufzunehmen. Dafür werden zunächst lediglich die Mastodon Einträge erfasst. Sollten die Account-Beschreibungen zukünftig tatsächlich auch für BlueSky Accounts benötigt werden, können sie mittels des `getProfile` Endpunktes nachträglich noch extrahiert und gespeichert werden.¹⁷⁷

„url:“ Für BlueSky Accounts ist keine URL im Response-Schema des Such-Endpunktes enthalten (vgl. Kap. 6.2.2). Da sowohl BlueSky¹⁷⁸ als auch Mastodon Accounts¹⁷⁹ ohne Kenntnis der direkten Adresse auffindbar sind, wird die URL in der Datenbank fürs ThWIC-Projekt nicht benötigt.

„avatar:“ Für BlueSky Accounts wird die URL zum Profilbild ebenfalls als „avatar“ Eigenschaft gespeichert (vgl. Kap. 6.2.2).

Es wird kein Vorteil darin gesehen, in das Recommendation System oder einen anderen in Kapitel 4 definierten Use Case Profilbilder einzubringen. Deswegen wird es nicht in der Datenbank gespeichert.

„avatar_static:“ Für BlueSky-Accounts gibt es keine vergleichbare Information, die angibt, ob das Profilbild animiert oder statisch ist (vgl. Kap. 6.2.2). Da das Profilbild nicht in die Datenbank des ThWIC-Projekts aufgenommen wird, ist diese Information auch nicht relevant. Daher wird sie nicht in die Datenbank aufgenommen.

„header:“ Für BlueSky Accounts wird über die verwendete Suchabfrage kein solches Banner-Bild bzw. dessen URL zurückgegeben (vgl. Kap. 6.2.2).

Ein Vorteil durch Kenntnis des Banner-Bildes wird für das ThWIC-Projekt nicht gesehen, die URL wird also nicht in der Datenbank gespeichert.

¹⁷⁴Vgl. o.V. (o.J.): `app.bsky.actor`, The ATProtocol, Abrufdatum: 22.07.2024.

¹⁷⁵Vgl. o.V. (o.J.): `app.bsky.actor.defs`, The AT Protocol SDK, Abrufdatum: 19.07.2024.

¹⁷⁶Vgl. o.V. (o.J.): `app.bsky.actor.getProfile`, Bluesky, Abrufdatum: 23.07.2024.

¹⁷⁷Vgl. o.V. (o.J.): `app.bsky.actor.getProfile`, Bluesky, Abrufdatum: 23.07.2024.

¹⁷⁸Vgl. o.V. (o.J.): `app.bsky.actor.getProfile`, Bluesky, Abrufdatum: 23.07.2024.

¹⁷⁹Vgl. o.V. (o.J.): `accounts API methods`, Mastodon, Abrufdatum: 25.07.2024.

„header_static“: Gibt für Banner-Bilder in Mastodon an, ob es sich um ein statisches oder animiertes Bild handelt.¹⁸⁰ Für BlueSky-Accounts gibt es keine vergleichbare Information (vgl. Kap. 6.2.2). Da die URLs von Banner-Bildern nicht für das ThWIC-Projekt erfasst werden, wird auch diese Information nicht benötigt und somit nicht in der Datenbank gespeichert.

„followers_count“: Über den verwendeten Endpunkt für die BlueSky-Suche wird nicht zurückgegeben, wie viele Follower der jeweilige Account hat (vgl. Kap. 6.2.2). Allerdings ist im Response Schema der getProfile Methode der Integer-Wert „followersCount“ enthalten,¹⁸¹ der ebenso für die Anzahl an Accounts steht, die betroffenem Account folgen.¹⁸²

In einem Recommendation System kann die Kenntnis über die Anzahl an Followern nützlich sein, da eine größere Anzahl von Followern oft auf eine höhere Bekanntheit und Beliebtheit des Profils hinweist. Somit können Beiträge dieser Accounts bevorzugt angezeigt werden.

Deswegen wird das Merkmal „followers_count“ in die Datenbank fürs ThWIC-Projekt aufgenommen. Allerdings werden dafür zunächst lediglich die Mastodon Accounts erfasst. Bei Bedarf kann die getProfile Methode für BlueSky Accounts angewandt werden, um die Anzahl an Followern auch für diese Profile zu extrahieren. Da sich die Anzahl an Followern mit der Zeit ändern kann, können hier regelmäßige Aktualisierungen vorgenommen werden, um die Datenbank auf einem aktuellen Stand zu halten.

„following_count“: Auch die Information darüber, wie vielen Profilen der Account folgt, ist für BlueSky-Accounts nicht im Response-Schema des verwendeten Such-Endpunktes enthalten (vgl. Kap. 6.2.2). Dies lässt sich aber ebenso über die getProfile Methode in Erfahrung bringen („followsCount“-Merkmal).¹⁸³

Folgt ein User vielen anderen Accounts, kann dadurch z.B. häufig auf eine höhere Aktivität geschlossen werden. Beiträge des jeweiligen Accounts könnten dadurch eher vom Recommendation System empfohlen werden.

Somit wird die Eigenschaft „following_count“ mit in die Datenbank aufgenommen, wobei zunächst lediglich die Einträge für Mastodon Accounts vorgenommen werden. Sollte die Information später tatsächlich auch für Bluesky-Profiles benötigt werden, so kann nachträglich die getProfile Methode angewandt werden und gewünschte Information extrahiert und in der Datenbank gespeichert werden. Auch hier gilt, dass es ggf. notwendig ist, die Einträge regelmäßig zu aktualisieren.

„statuses_count“: Für BlueSky Profile ist die Anzahl aller veröffentlichten Beiträge eines Accounts (in BlueSky: „postsCount“) wieder nur einsehbar, wenn man dafür statt dem Suchendpunkt (vgl. Kap. 6.2.2) andere Endpunkte wie getProfile¹⁸⁴ verwendet.¹⁸⁵

Eine hohe Anzahl an Beiträgen kann bedeuten, dass es sich insgesamt um einen seriösen und engagierten User handelt, dessen Beiträge in einem Recommendation System bevorzugt empfohlen werden können.

Aus diesem Grund wird das Account-Merkmal als „posts_count“ in die Datenbank fürs ThWIC-Projekt aufgenommen. Auch in diesem Fall werden aber zunächst lediglich für Mastodon Accounts die Anzahl an Posts extrahiert und gespeichert. Für BlueSky Accounts kann dies bei Bedarf vorgenommen werden. Die Anzahl an Beiträgen eines Nutzers kann sich ständig ändern, sodass an dieser Stelle ebenso Datenbank Updates relevant werden können.

„last_status_at“: Wann der letzte Beitrag vom jeweiligen Account veröffentlicht wurde, ist für BlueSky Accounts nicht hinterlegt.¹⁸⁶ Allerdings bietet BlueSky einen Endpunkt, der es ermöglicht, alle Posts eines Users zu erhalten.¹⁸⁷ Da für jeden Post auch angegeben ist, wann er erstellt wurde,¹⁸⁸ könnte also das letzte Erstellungsdatum

¹⁸⁰Vgl. o.V. (o.J.): Account, Mastodon, Abrufdatum: 20.07.2024.

¹⁸¹Vgl. o.V. (o.J.): app.bsky.actor.getProfile, Bluesky, Abrufdatum: 23.07.2024.

¹⁸²Vgl. o.V. (o.J.): app.bsky.actor.defs, The AT Protocol SDK, Abrufdatum: 19.07.2024.

¹⁸³Vgl. o.V. (o.J.): app.bsky.actor.getProfile, Bluesky, Abrufdatum: 30.07.2024.

¹⁸⁴Vgl. o.V. (o.J.): app.bsky.actor.getProfile, Bluesky, Abrufdatum: 30.07.2024.

¹⁸⁵Vgl. o.V. (o.J.): app.bsky.actor.defs, The AT Protocol SDK, Abrufdatum: 29.07.2024.

¹⁸⁶Vgl. o.V. (o.J.): app.bsky.actor.defs, The AT Protocol SDK, Abrufdatum: 29.07.2024.

¹⁸⁷Vgl. o.V. (o.J.): com.atproto.repo.listRecords, Bluesky, Abrufdatum: 30.07.2024.

¹⁸⁸Vgl. o.V. (o.J.): app.bsky.feed.post, The AT Protocol SDK, Abrufdatum: 26.07.2024.

herausgefiltert werden. Dadurch hätte man das Merkmal „last_status_at“ auch für BlueSky Accounts. Durch Kenntnis dieses Merkmals könnten Recommendation Systeme beispielsweise vermeiden, Beiträge von inaktiven Konten vorzuschlagen.

Deswegen wird das Merkmal „last_status_at“ in die Datenbank aufgenommen. Auch hier werden aber zunächst nur Einträge für Mastodon Konten vorgenommen. Bei tatsächlichem Bedarf dieser Information auch für BlueSky-Accounts kann für jedes Profil, wie oben beschrieben, das Datum des aktuellsten Beitrags herausgefiltert werden. Auch hier gilt aber, dass die Verwendung dieses Merkmals evtl. eine Aktualisierung der Datenbank erfordert.

„emojis:“ Vom User selbst erstellte Emojis sind BlueSky-Accounts nicht angehängt.¹⁸⁹

Ein Nutzen solcher Emojis fürs Recommendation System oder einen anderen in Kapitel 4 definierten Use Case ist nicht erkennbar. Die Information über individuelle Emojis wird also nicht in die Datenbank aufgenommen.

„fields:“ Für BlueSky-Accounts werden keine gut strukturierten und übersichtlichen Metadaten als Name-Wert-Paare gespeichert und angezeigt¹⁹⁰ (vgl. auch Kap. 6.2.2). Falls für Mastodon-Accounts als Wert eine URL angegeben ist, die zu einer anderen Online-Präsenz des Autors führt, so ist zusätzlich zum Name-Werte-Paar noch ein Zeitstempel, unter „verified_at“ enthalten. Dieser gibt an, wann entsprechender Link vom Server überprüft wurde.¹⁹¹

Zusätzliche Kenntnisse über den User, wie sein Alter oder Heimatland, kann für das Recommendation System relevant sein. So können beispielsweise Beiträge einer ausgewählten Altersgruppe oder Wohngegend bevorzugt empfohlen werden. Die Kenntnis von „verified_at“ bietet hingegen keinen erkennbaren Vorteil fürs Recommendation System oder einen der Use Cases (vgl. Kap. 4). Somit werden nur die Name-Werte-Paare als „name“ und „value“ Merkmale in die Datenbank aufgenommen.

6.3.4 Medienanhänge

Während Mastodon-Beiträgen unter **media_attachments** ein Bild, ein Video, eine Animation oder eine Audio-Datei angehängt sein kann (vgl. Kap. 6.2.1), können BlueSky-Beiträge Bilder, andere BlueSky-Beiträge, andere BlueSky-Beiträge mit eingebetteten Medieninhalten oder „externe Inhalte“ enthalten.¹⁹² Unter externen Inhalten wird beispielsweise eine URL oder eine Webseiten Vorschau verstanden.¹⁹³ Informationen zu Medienanhängen von BlueSky-Beiträgen finden sich in der „embed“-Eigenschaft (vgl. Kap. 6.2.2).

Für ein Recommendation System können Medienanhänge an Beiträge z.B. nützlich sein, um Beiträge mit Bildern oder anderen vom Benutzer festgelegten medialen Inhalten bevorzugt anzuzeigen. Außerdem können in Medienanhängen wesentliche Informationen, wie weitere Beiträge zur gesuchten Thematik, enthalten sein (vgl. dazu Kap. 4 oder Kap. 1.1).

Die gegebenen Eigenschaften zu unterschiedlichen Medienanhängen sind allerdings sowohl in Mastodon als auch in BlueSky wesentlich von der Art des Mediums abhängig (vgl. Kap. 6.2.1 und 6.2.2). Würde jedes dieser Merkmale in die Datenbank aufgenommen werden, kann es durch viele leere Einträge schnell zu Unübersichtlichkeiten und Verständnisschwierigkeiten bei Verwendung der Datenbank kommen. Deswegen wird davon abgesehen, alle dieser zusätzlichen Informationen und Meta-Informationen, wie die URL, die Voransicht oder die Größe der Anhänge zu extrahieren und dauerhaft zu speichern.

Die Datenbank fürs ThWIC-Projekt soll es trotzdem ermöglichen, den zum Beitrag gehörenden Medienanhang aufzufinden, damit dieser bei Interesse separat analysiert werden kann. Außerdem soll nach Beiträgen mit bestimmten Arten von Anhängen gefiltert werden können. Dafür werden folgende Eigenschaften benötigt:

¹⁸⁹Vgl. o.V. (o.J.): app.bsky.actor, The ATProtocol, Abrufdatum: 22.07.2024.

¹⁹⁰Vgl. o.V. (o.J.): app.bsky.actor.defs, The AT Protocol SDK, Abrufdatum: 29.07.2024

¹⁹¹Vgl. o.V. (o.J.): Account, Mastodon, Abrufdatum: 27.07.2024.

¹⁹²Vgl. o.V. (o.J.): app.bsky.embed, The AT Protocol SDK, Abrufdatum: 27.07.2024.

¹⁹³Vgl. o.V. (o.J.): app.bsky.embed.external, The AT Protocol SDK, Abrufdatum: 25.07.2024.

„id:“ Alleine durch Kenntnis der ID des Mastodon-Medienanhangs kann dieser über einen GET-Request aufgefunden werden.¹⁹⁴ Eine ID existiert für Anhänge an BlueSky-Beiträge nicht im Response-Schema des Such-Endpunktes. Allerdings sind, je nach Art des Medienanhangs, ähnliche Informationen zum Zweck der Auffindbarkeit des entsprechenden Mediums gegeben (vgl. Kap. 6.2.2):

Für an BlueSky-Beiträge angehängte Bilder ist innerhalb der „image“-Eigenschaft das „ref“-Merkmal hinterlegt. Dieses enthält den CID des Bildes. Anhänge von BlueSky-Beiträgen können mittels CID sowie der DID des Herausgebers identifiziert und aufgefunden werden.¹⁹⁵ Für externe Inhalte, die an BlueSky-Beiträge angehängt wurden, befindet sich der CID innerhalb des „thumb“-Merkmals als „ref“-Eigenschaft. Auch ein externer Inhalt kann durch Kenntnis des CIDs sowie der DID aufgefunden werden.¹⁹⁶ Die benötigten DIDs dazu wurden bereits unter dem Merkmal „account_id“ in die Datenbank aufgenommen.

Für andere BlueSky-Beiträge, die in einen BlueSky-Beitrag eingebettet sind, ist innerhalb der „record“-Eigenschaft die URI, als „uri“-Merkmal, hinterlegt. Sie, bzw. die in ihr enthaltene DID sowie der „r-key“ wird benötigt, um den Beitrag eindeutig identifizieren zu können (vgl. Abschnitt „id“). Selbiges gilt für BlueSky-Beiträge, in die ein anderer BlueSky-Beitrag mit Medieninhalt eingebettet ist. Auch hier ist innerhalb des „record“-Merkmals die URI des eingebetteten Beitrags angegeben (vgl. Kap. 6.2.2).

Um Medienanhänge für das ThWIC-Projekt auffinden zu können, wird für Mastodon-Beiträge also die ID des Anhangs unter „id_attachment“ gespeichert. Unter der selben Eigenschaft werden auch die CIDs für an BlueSky-Beiträge angehängte Bilder und externe Inhalte in die Datenbank aufgenommen. Enthält ein BlueSky-Beitrag eingebettete BlueSky-Beiträge, wird zusätzlich zum r-key auch die DID des jeweiligen Herausgebers als „from_id“ gespeichert.

„type:“ Auch für BlueSky-Beiträge ist die Art des angehängten Mediums stets im „type“-Merkmal des Response-Schemas hinterlegt. Dabei handelt es sich allerdings nicht wie in Mastodon um ein Bild („image“), eine Animation („gifv“), ein Video („video“), ein Audio („audio“) oder eine unbekannte Art („unknown“), sondern entweder um „app.bsky.embed.image“, also ein angehängtes Bild, um „app.bsky.embed.external“, das für einen anderen Beitrag steht, um „app.bsky.embed.record“, also einen anderen BlueSky-Beitrag oder um „app.bsky.embed.recordWithMedia“, also einen anderen Beitrag mit Medienanhang (vgl. Kap. 6.2.2).

Aus oben genanntem Grund soll die Art des Medienanhangs in die Datenbank aufgenommen werden. Sowohl für Mastodon- als auch für BlueSky-Beiträge wird sie deswegen unter „attachment_type“ gespeichert.

6.3.5 Erwähnungen anderer Nutzer

Für BlueSky-Beiträge findet sich die Information über im Beitrag erwähnte User wie bei Mastodon-Beiträgen („mentions“) im Response-Schema des Such-Endpunkts, da rich text zur Markierung von Erwähnungen verwendet wird. Eine Erwähnung enthält dabei jeweils die Art des rich texts sowie die DID des erwähnten Users.¹⁹⁷

Für ein Recommendation System kann die Kenntnis über markierte Nutzer bspw. sinnvoll sein, um Beiträge mit bestimmten erwähnten Accounts, z.B. deren Follower-Anzahl einen bestimmten Wert überschreitet, bevorzugt anzuzeigen.

Deswegen werden die Erwähnungen in die Datenbank fürs ThWIC-Projekt aufgenommen. Zur Identifikation eines erwähnten Mastodon Users wird nur die ID sowie die Domain benötigt, deswegen sollen auch lediglich diese als „mentioned_account_id“ und „from_instance“ gespeichert bzw. aus „acct“ extrahiert werden. Für BlueSky User wird stattdessen nur die DID des Accounts extrahiert und ebenso in „mentioned_account_id“ gespeichert.

¹⁹⁴Vgl. o.V. (o.J.): media API methods, Mastodon, Abrufdatum: 30.07.2024.

¹⁹⁵Vgl. o.V. (o.J.): com.atproto.sync.get_blob, The AT Protocol SDK, Abrufdatum: 01.08.2024.

¹⁹⁶Vgl. o.V. (o.J.): com.atproto.sync.get_blob, The AT Protocol SDK, Abrufdatum: 01.08.2024.

¹⁹⁷Vgl. o.V. (o.J.): app.bsky.richtext.facet, The AT Protocol SDK, Abrufdatum: 28.07.2024.

6.3.6 Hashtags

Auch Hashtags (in Mastodon: „tags“) können BlueSky-Beiträgen durch die Verwendung von rich text im „facets“-Merkmal entnommen werden (vgl. Kap. 6.2.2). Für jeden Hashtag („tag“) ist dabei die Art des rich texts, sowie der Hashtag selbst gegeben.¹⁹⁸ Ein Mastodon Hashtag besteht hingegen aus der Bezeichnung des Hashtags sowie einem Link zum Hashtag auf jeweiliger Instanz (vgl. Kap. 6.2.1).

Hashtags können als Schlüsselwörter verstanden werden, die den eigentlichen Inhalt des Beitrags andeuten bzw. zusammenfassen.¹⁹⁹ Für Recommendation Systeme können sie also bspw. verwendet werden, um nach zum Hashtag passenden Beiträgen zu filtern. Die Kenntnis der URL ist hingegen für das ThWIC-Projekt nicht relevant. Somit werden Hashtags aus BlueSky- und Mastodon Beiträgen als „hashtag“-Merkmal in die Datenbank für das ThWIC-Projekt aufgenommen. Dabei werden lediglich die Namen der Hashtags gespeichert.

6.3.7 Emojis

„emojis:“ Für BlueSky-Beiträge existieren keine mit den Mastodon-Emojis vergleichbare Informationen (vgl. Kap. 6.2.2).

Ein Vorteil durch Kenntnis solcher Emojis für das Recommendation System oder einen der in Kapitel 4 definierten Use Cases besteht nicht. Die individuellen Emojis werden also nicht in der Datenbank gespeichert.

6.3.8 Voransichten von Webseiten

„card:“ Voransichten für im Beitrag enthaltene Links können für BlueSky-Beiträge in der „embed“-Eigenschaft hinterlegt sein (vgl. Kap. 6.2.2).

Eine sinnvolle Verwendungsmöglichkeit von Voransichten für das Recommendation System oder einen anderen in Kapitel 4 definierten Use Case wurde nicht identifiziert. Deswegen wird diese Information nicht in die Datenbank aufgenommen.

6.3.9 Umfrage

In BlueSky kann mittels Beitrag derzeit keine Umfrage (in Mastodon-Beiträgen: „poll“) gestartet werden. Es gibt aber Diskussionen darüber, diese Möglichkeit zukünftig zu implementieren.²⁰⁰

Da Umfragen insbesondere für Meinungsanalysen, die gemäß Kapitel 4 für das ThWIC-Projekt relevant sind, zielführend sein können, werden einige der folgenden Informationen²⁰¹ zu Mastodon Umfragen in die Datenbank aufgenommen.

„id:“ Die ID der Umfrage ermöglicht es, die Umfrage mittels GET-Request wieder aufzufinden.²⁰² Sie wird deswegen in die Datenbank fürs ThWIC-Projekt als „poll_id“ aufgenommen.

„expires_at:“ Falls eine Umfrage zum Zeitpunkt der Datensammlung noch offen ist, kann in Erwägung gezogen werden, sie zum Abschlusszeitpunkt auf weitere abgegebene Stimmen zu überprüfen. Der Zeitstempel wird deswegen als „poll_expires_at“-Merkmal in die Datenbank aufgenommen.

„expired:“ Die Information darüber, ob die Umfrage bereits abgelaufen ist, wird in der Datenbank nicht benötigt, da der Zustand der Beiträge in der Datensammlung für das ThWIC-Projekt ja nicht mit verändert wird, sobald

¹⁹⁸Vgl. o.V. (o.J.): app.bsky.richtext.facet, The AT Protocol SDK, Abrufdatum: 28.07.2024.

¹⁹⁹Vgl. O'Brien, C. (2023): How to Use Hashtags Effectively on Social Media, Digital Marketing Institute, Abrufdatum: 02.08.2024.

²⁰⁰Vgl. o.V. (10.07.2023): Voting/Polls support, GitHub, Abrufdatum: 03.08.2024.

²⁰¹Vgl. o.V. (o.J.): Poll, Mastodon, Abrufdatum: 03.08.2024.

²⁰²Vgl. o.V. (o.J.): polls API methods, Mastodon, Abrufdatum: 03.08.2024.

sich der Zustand des Beitrags in der Datenbank von Mastodon ändert. Stattdessen kann durch einen Vergleich des aktuellen Zeitpunkts und der „expires_at“ Eigenschaft herausgefunden werden, ob noch abgestimmt werden kann.

„multiple:“ Ob in der Umfrage Multiple-Choice-Antworten erlaubt sind, ist für die korrekte Interpretation der Umfrageergebnisse entscheidend. Sie wird deswegen als „multiple_choice“-Eigenschaft in die Datenbank eingefügt.

„votes_count:“ Ist eine vergleichsweise hohe Anzahl an Stimmen abgegeben worden, so deutet dies auf eine hohe Reichweite und damit evtl. auch eine erhöhte Relevanz der Umfrage für Datenanalysen hin. Deswegen wird die Eigenschaft als „votes_count“ in die Datensammlung für das ThWIC-Projekt aufgenommen.

„voters_count:“ Die Information darüber, wie viele Accounts abgestimmt haben dient u.a. dazu, die Relevanz der Umfrage einzuschätzen und sie richtig zu interpretieren. Sie wird deswegen als „voters_count“-Merkmal in die Datenbank aufgenommen.

„voted:“ Da der Account mit dem die Requests zur Datensammlung durchgeführt werden lediglich der Informationsbeschaffung dient, ist nicht davon auszugehen, dass er sich an Umfragen beteiligt. Die Information wird somit auch nicht in der Datenbank fürs ThWIC-Projekt benötigt.

„own_votes:“ Da von dem Request-Account aus keine Stimmen zu Umfragen abgegeben werden, wird diese Information fürs ThWIC-Projekt ebenso verworfen.

„options:“ Informationen über die einzelnen Umfrage-Optionen werden benötigt, um die Umfrage korrekt interpretieren zu können:

„title:“ Der Text/Name einer Option ist wesentlich zum Verständnis des Inhalts der Umfrage. Deswegen werden die Titel der einzelnen Wahlmöglichkeiten unter „option_titles“ in die Datenbank aufgenommen. Sie werden mittels Komma separiert.

„votes_count:“ Die Anzahl aller Stimmen für eine Option ist für die Auswertung der Umfrage unerlässlich. Sie wird deswegen als „votes_for_options“-Eigenschaft in die Datenbank aufgenommen. Genau wie die einzelnen Wahlmöglichkeiten, werden auch die Anzahl an Stimmen je Option mittels Komma separiert.

„emojis:“ Ein Nutzen individueller Emojis bei Umfragen ist fürs ThWIC-Projekt nicht erkennbar. Sie werden deswegen nicht in die Datenbank aufgenommen.

6.3.10 Zusammenfassung: für das ThWIC-Projekt verwendete Merkmale

In diesem Kapitel sind die Merkmale, die nach den Ausarbeitungen in den Kapiteln 6.3.1 bis 6.3.9 in der ThWIC-Datenbank erfasst werden, übersichtlich in Tabellenform dargestellt. Für jedes dieser Unterkapitel wurde eine separate Tabelle erstellt. Nur die Kapitel „Informationen zum Beitrag“ (also Kap. 6.3.1) und „Weitere Informationen über den Beitrag“ (also Kap. 6.3.2) wurden zusammengefasst, da sie sich inhaltlich sehr ähnlich sind und da sich in letzterem sowieso nur ein einziges Merkmal befindet, das in die Datenbank aufgenommen wird. Dabei beinhaltet die erste Spalte jwl. den Namen des Abschnitts in dem Kapitel, in dem das Merkmal erläutert und dessen Aufnahme in die ThWIC-Datenbank begründet wurde. Außerdem sind die Namen der verwendeten Merkmale in Mastodon, BlueSky sowie der ThWIC-Datenbank zusammengefasst. In der letzten Spalte ist zudem eine kurze Beschreibung der Eigenschaft hinterlegt.

Informationen zum Beitrag:

Abschnitt	Name in ThWIC-Datenbank	Name in Mastodon	Name in BlueSky	Beschreibung
id	post_id	id	rkey (Extraktion aus: URI)	Eindeutige Identifikation des Beitrags
created_at	created_at	created_at	createdAt	Zeitstempel, wann der Beitrag erstellt wurde
in_reply_to_id	in_reply_to_id	in_reply_to_id	rkey (Extraktion aus: reply)	ID des Beitrags, dem geantwortet wird
in_reply_to_id	related_to_-_post_id	-	rkey (Extraktion aus: reply)	ID des ursprünglichen Beitrags
in_reply_to_-_account_id	in_reply_to_-_account_id	in_reply_to_-_account_id	did (Extraktion aus: reply)	ID des Accounts, dem geantwortet wird
in_reply_to_-_account_id	related_to_-_account_id	-	did (Extraktion aus: reply)	ID des Accounts, der die Diskussion gestartet hat
sensitive	sensitive	spoiler_text	labels	Grund für die Markierung des Beitrags als sensibel
visibility	visibility	visibility	-	Sichtbarkeitsstufe des Beitrags
uri	instance_name	(Extraktion aus: uri)	(Extraktion aus: handle)	Instanz, auf der der Beitrag veröffentlicht wurde
replies_count	replies_count	replies_count	replyCount	Anzahl an Antworten auf den Beitrag
reblogs_count	reposts_count	reblogs_count	repostCount	Häufigkeit, mit der ein Beitrag von anderen Profilen geteilt wurde
favourites_count	likes_count	favourites_count	likeCount	Anzahl an Likes für den Beitrag
content	content	content	text	Inhalt des Beitrags
edited_at	edited_at	edited_at	indexedAt	Zeitstempel, wann der Beitrag das letzte Mal bearbeitet wurde

Fortsetzung auf der nächsten Seite

Fortsetzung von vorheriger Seite

Abschnitt	Name in ThWIC-Datenbank	Name in Mastodon	Name in BlueSky	Beschreibung
-----------	-------------------------	------------------	-----------------	--------------

Tabelle 6.1: Informationen zum Beitrag: ausgewählte Merkmale für die Datenbank

Account-Informationen:

Abschnitt	Name in ThWIC-Datenbank	Name in Mastodon	Name in BlueSky	Beschreibung
id	account_id	id	did (Extraktion aus: uri)	ID des Autors, der den Beitrag veröffentlicht hat
bot	bot	bot	-	Gibt an, ob der Account ein Bot ist
noindex	noindex	noindex	-	Gibt an, ob Beiträge des Accounts von Suchmaschinen gefunden werden können
moved	new_account_id	id (Extraktion aus: moved)	-	ID des migrierten Accounts
limited	sensitive	limited	labels	Gibt an, ob der Account mit einer Warnung angezeigt wird
created_at	created_at	created_at	createdAt	Zeitstempel, wann der Account erstellt wurde
note	description	note	-	Account-Beschreibung
followers_count	followers_count	followers_count	-	Anzahl Follower des Accounts
following_count	following_count	following_count	-	Anzahl an Accounts, denen der Account folgt
statuses_count	posts_count	statuses_count	-	Anzahl an Beiträgen, die von dem Account veröffentlicht wurden

Fortsetzung auf der nächsten Seite

Fortsetzung von vorheriger Seite

Abschnitt	Name in ThWIC-Datenbank	Name in Mastodon	Name in BlueSky	Beschreibung
last_status_at	last_status_at	last_status_at	-	Zeitstempel, wann der Account den letzten Beitrag veröffentlicht hat
fields	name	name (Extraktion aus: fields)	-	Name einer gut strukturierten Account-Information
fields	value	value (Extraktion aus: fields)	-	Wert einer gut strukturierten Account-Information

Tabelle 6.2: Account-Informationen: ausgewählte Merkmale für die Datenbank

Medienanhänge:

Abschnitt	Name in ThWIC-Datenbank	Name in Mastodon	Name in BlueSky	Beschreibung
id	id_attachment	id	cid bei Bildern & externen Inhalten (Extraktion aus: ref), rkey bei angehängten Beiträgen (Extraktion aus: record)	Kennung des Mediananhangs
id	from_id	-	did (Extraktion aus: record)	DID des BlueSky Accounts, der den Medienanhang veröffentlicht hat
type	attachment_type	type	type	Art des Anhangs

Tabelle 6.3: Medienanhänge: ausgewählte Merkmale für die Datenbank

Erwähnungen anderer Nutzer:

Abschnitt	Name in ThWIC-Datenbank	Name in Mastodon	Name in BlueSky	Beschreibung
mentions	mentioned_- account_id	id	did (Extraktion aus: facets)	Kennung des erwähnten Accounts
mentions	from_instance	domain (Extraktion aus: acct)	-	Instanz-Name des erwähnten Accounts

Tabelle 6.4: Erwähnungen anderer Nutzer: ausgewählte Merkmale für die Datenbank

Hashtags:

Abschnitt	Name in ThWIC-Datenbank	Name in Mastodon	Name in BlueSky	Beschreibung
tags	hashtag	tags	tag (Extraktion aus: facets)	Verwendeter Hashtag

Tabelle 6.5: Hashtags: ausgewählte Merkmale für die Datenbank

Umfrage:

Abschnitt	Name in ThWIC-Datenbank	Name in Mastodon	Name in BlueSky	Beschreibung
id	poll_id	id	-	ID der Umfrage
expires_at	poll_expires_at	expires_at	-	Zeitstempel, wann die Umfrage geschlossen wird
multiple	multiple_choice	multiple	-	Gibt an, ob Multiple-Choice- Antworten erlaubt sind
votes_count	votes_count	votes_count	-	Anzahl abgegebener Stimmen
voters_count	voters_count	voters_count	-	Anzahl Umfragen- Teilnehmer
title	option_titles	title (Extraktion aus: options)	-	Alle Wahlmöglichkeiten
votes_count	votes_for_- options	votes_count (Extraktion aus: options)	-	Anzahl abgegebener Stimmen je Wahlmöglichkeit

Fortsetzung auf der nächsten Seite

Fortsetzung von vorheriger Seite

Abschnitt	Name in ThWIC-Datenbank	Name in Mastodon	Name in BlueSky	Beschreibung
-----------	-------------------------	------------------	-----------------	--------------

Tabelle 6.6: Umfrage: ausgewählte Merkmale für die Datenbank

6.3.11 Zusätzliche Informationen für die ThWIC-Datenbank

Zusätzlich zu den in den Kapitel 6.3.1 bis 6.3.9 erläuterten Merkmalen wurde entschieden, weitere Eigenschaften in die Datenbank aufzunehmen, die nicht in den Response-Schemata der Suchendpunkte enthalten sind.

Um zwischen den Social Media Plattformen differenzieren zu können, was bspw. nötig ist, um einen in der Datenbank gespeicherten Beitrag mittels Endpunkten der jeweiligen Plattform auffinden zu können (vgl. Kap. 6.3.1, Abschnitt „ID“), wird der Name der Plattform durch die Eigenschaft „from_platform“ erfasst. Außerdem wird der Instanz Name benötigt, um einen Beitrag auffinden zu können. Dieser geht aus der URI hervor und wird ebenso in die Datenbank integriert (vgl. Kap. 6.3.1).

Außerdem wird das Datum gespeichert, an dem der Eintrag eines Beitrags in die ThWIC-Datenbank vorgenommen wurde. Dies kann eine genauere Einschätzung über die Aktualität einiger erfasster Merkmale ermöglichen. Insbesondere für die Merkmale, die sich mit der Zeit ändern können, wie die Anzahl an Likes für einen Beitrag (vgl. Kap. 6.3.1, Abschnitt „favourites_count“), kann dies sinnvoll sein. Denn falls ein Beitrag bspw. direkt gespeichert wurde, nachdem er veröffentlicht wurde, ist eine geringe Anzahl an Likes kaum aussagekräftig, da der Beitrag ggf. noch nicht von allen Personen angesehen werden konnte, die ihn liken würden.

Weiterhin werden die einzelnen Schlüsselwörter, mit denen die Beiträge gesucht werden, mitsamt ihrer zugeordneten Kategorien und Themengebiete (vgl. Anhang, Tab. 1), in die Datenbank aufgenommen. Dies ermöglicht es, gespeicherte Beiträge nach diesen Schlüsselwörtern, Kategorien und Themen filtern zu können.

6.4 Vereinheitlichtes Datenbankschema

Im Folgenden wird zunächst erläutert, wie das Datenbankschema mit den für das ThWIC-Projekt relevanten Informationen aus Mastodon- und BlueSky-Beiträgen erstellt wurde. Anschließend werden einige Punkte erläutert, auf die während der Verwendung der Datenbank geachtet werden sollte.

6.4.1 Entwurf des Datenbankschemas

Basierend auf den in die Datenbank für das ThWIC-Projekt aufzunehmenden Eigenschaften aus den Kapiteln 6.3.1 bis 6.3.9 wurde schließlich ein geeignetes Datenbankschema als EER-Diagramm entworfen.

Ein intuitiver erster Entwurf des Datenbankschemas bestand darin, die Tabellen aus den genannten Kapiteln auch als Tabellen (bzw. Entitäten) für die Datenbank zu verwenden. Nach dieser Möglichkeit hätte die Datenbank also eine Tabelle mit den Informationen über die einzelnen Beiträge (vgl. Tabelle 6.1), eine Tabelle mit Informationen über die gespeicherten Accounts (vgl. Tabelle 6.2), eine Tabelle für die Medienanhänge eines Beitrags (vgl. Tabelle 6.3), eine Tabelle über die Erwähnungen anderer Nutzer in einem Beitrag (vgl. Tabelle 6.4), eine Tabelle über im Beitrag verwendete Hashtags (vgl. Tabelle 6.5) sowie eine Tabelle für Beiträgen angehängte Umfragen (vgl. Tabelle 6.6). Es fällt allerdings auf, dass nach dieser Methode viele leere Zellen in der Datenbank entstehen würden. Der Grund hierfür ist, dass einige Eigenschaften, die von dem verwendeten Mastodon Such-Endpunkt zurückgegeben werden, nicht in dem Response Schema des BlueSky Such-Endpunkts, oder seltener anders herum,

enthalten sind. Dies betrifft insbesondere die Tabelle mit den Account-Informationen. Von insgesamt 13 Eigenschaften, die in die Datenbank aufgenommen werden sollen, werden für BlueSky Accounts lediglich drei von dem Endpunkt zurückgegeben (Vgl. Tabelle 6.2). Für jeden einzelnen BlueSky Account würden also zehn leere Zellen entstehen. Leere Zellen können die Datenbank nicht nur weniger übersichtlich machen, sondern sie benötigen auch unnötigen Speicherplatz. Um dieses Problem zu vermeiden, wurden die einzelnen Tabellen weiter unterteilt. Die daraus entstehende Tabellenstruktur ist im folgenden erklärt.

Es wurde beschlossen, die Account-Informationen auf vier Tabellen aufzuteilen.

Dafür wurde zunächst eine Tabelle für dynamische Account-Informationen hinzugefügt. Als dynamisch wurden hierfür Informationen definiert, die sich im Zeitverlauf ändern können. Dazu gehören die Merkmale, die von anderen Nutzern des Social Media Netzwerks abhängig sind, nämlich die Anzahl an Followern eines Nutzers und die Anzahl an Profilen, denen der Account folgt. Auch Merkmale, die mit der Aktivität des Nutzers zusammenhängen, nämlich die Anzahl seiner veröffentlichten Beiträge und das Datum des letzten Beitrags, wurden den dynamischen Informationen zugeordnet.

In dieser Tabelle werden demnach nur Einträge von Mastodon Accounts vorgenommen, wodurch für jeden BlueSky Account bereits vier leere Zellen weniger entstehen. Dynamische Account Informationen sind auch diejenigen, die besonders beim Anlegen einer Historie der Datenbank, also der Speicherung derselben Eigenschaften zu verschiedenen Zeitpunkten, benötigt werden. Insbesondere wenn der Account beispielsweise für das Ranking eines Empfehlungssystems herangezogen wird, sollten diese dynamischen Informationen wie die Anzahl der Follower und das Datum des letzten Beitrags berücksichtigt und möglichst aktuell gehalten werden (vgl. Kap. 6.3.3).

Weiterhin wurden die Metainformationen, die ebenfalls nur über einen Mastodon Account vorliegen können (vgl. Tabelle 6.2, Abschnitt „fields“), in eine separate Tabelle ausgelagert. Auch in dieser Tabelle können deswegen keine Einträge für BlueSky Accounts vorgenommen werden, was weitere zwei leere Zellen pro BlueSky Account vermeidet. Dies bietet zudem den Vorteil, dass ein Account-Eintrag nicht mehrfach in der Tabelle gespeichert werden muss, falls mehrere Schlüssel-Wert-Paare vorhanden sind. Dies spart nicht nur Speicherplatz, sondern reduziert auch die Datenredundanz.

Auch die Informationen über Account-Migrationen wurden in eine separate Tabelle überführt. Somit müssen wieder zwei leere Zellen weniger für jeden BlueSky Account gespeichert werden. Weiterhin werden dadurch keine leeren Zellen für Mastodon Accounts eingetragen, die den Account noch nie gewechselt haben. Falls Mastodon Accounts häufiger den Account gewechselt haben, wird zudem durch Verhinderung des mehrfachen Eintrags dieser Accounts Datenredundanz verhindert.

Die Informationen über die Beiträge wurden in drei Tabellen aufgeteilt.

Eine Tabelle enthält die wesentlichen Informationen über den Beitrag selbst, die sich ab der Veröffentlichung nicht mehr ändern, also z.B. den Inhalt und den Zeitpunkt der Veröffentlichung.

Für Antworten auf Beiträge wurde eine separate Tabelle angelegt. Dies hat den Vorteil, dass keine leeren Zellen entstehen, falls es sich bei einem Beitrag nicht um eine Antwort handelt.

Zusätzlich wurde auch für Beiträge eine Tabelle mit dynamischen Informationen erstellt. Im Fall von Beiträgen wurden dynamische Informationen als diejenigen definiert, die von anderen Nutzern des Social Media Netzwerks beeinflusst werden. Zu diesen zählen also die Anzahl der Antworten auf einen Beitrag, die Anzahl an Likes, die Anzahl an Reposts sowie die Information, ob der Beitrag als empfindlich bewertet wurde. Auch diese Informationen sind nützlich, um das Ranking des Recommendation System zu beeinflussen (vgl. Kap. 6.3.1). Aus diesem Grund ist es sinnvoll, auch hier eine Historie anzulegen.

Weiterhin wurden die Tabellen für Erwähnungen anderer Nutzer, für Hashtags und für an Mastodon Beiträge angehängte Medien und Umfragen in die Datenbank eingefügt. Diese basieren jeweils gänzlich auf den Ausarbeitungen der jeweiligen Kapitel. Sie wurden also nicht in weitere Tabellen unterteilt.

Die in Kapitel 6.3.11 erklärten zusätzlichen Informationen, die in die Datenbank für das ThWIC-Projekt aufgenommen werden, wurden wie folgt in das Datenbankschema integriert:

Die einzelnen Schlüsselwörter, mit denen nach den Beiträgen gesucht wird, wurden mitsamt ihrer zugehörigen Themenbereiche und Kategorien in einer separaten Tabelle gespeichert.

Die Social Media Plattform sowie die Instanz eines Accounts wurden in die Account-Tabelle übernommen. Obwohl diese Informationen auch für die Auffindbarkeit einzelner Beiträge relevant sind (vgl. Kap. 6.3.1), ist es sinnvoll, sie in der Account-Tabelle zu speichern, da insbesondere das Instanz-Merkmal über Account-Einstellungen beeinflusst werden kann (vgl. Kap. 6.3.3, Abschnitt „moved“). Durch die Beziehung zwischen Beiträgen und zugehörigen Accounts können die Informationen über Plattform und die Instanz aber auch für Beiträge ermittelt werden.

Der Zeitpunkt, zu dem ein Beitrag in die Datenbank aufgenommen wird, wurde in die Tabelle mit den Informationen über die Beiträge eingefügt, da er sich ja auf diese bezieht.

Basierend auf den eben vorgenommen Erklärungen wurde das folgende als EER-Diagramm dargestellte Datenbankschema entwickelt. Die SQL-Befehle zum Erstellen dieser Datenbank sind im Anhang hinterlegt (vgl. Anhang, Abb. 34).




Abbildung 6.1: Datenbankschema als EER-Diagramm

Die gelben Schlüssel bedeuten, dass es sich bei der jeweiligen Eigenschaft um einen Primärschlüssel der Tabelle handelt. Fremdschlüssel sind durch rote Rauten markiert. Gehören sie aber zu einem zusammengesetzten Primärschlüssel, sind sie als rote Schlüssel dargestellt.

Die eingefügten orangenen Punkte wurden hinter Merkmale eingefügt, die mit den verwendeten Such-Endpunkten lediglich für von Mastodon stammende Informationen erfasst werden können, da sie nicht in dem Response-Schema von BlueSky enthalten sind. Können Informationen hingegen nur von BlueSky und nicht von Mastodon gespeichert werden, dann sind diese durch die blauen Punkte markiert.

Dadurch ist ersichtlich, dass es nach der oben erklärten Aufteilung der einzelnen Informationen in mehrere Tabellen nur zu wenigen leeren Zellen kommt. Denn da in den Tabellen mit den meisten Markierungen, also in der Umfrage Tabelle, der Tabelle über dynamische Account-Informationen, der Tabelle über die Account-Migrationen und die Tabelle mit den Name-Wert-Paaren, ausschließlich Mastodon Einträge vorgenommen werden können, entstehen hier auch keine leeren Zellen wegen nicht erfasster BlueSky Daten. Insgesamt können also nur noch an lediglich fünf Stellen in der Datenbank leere Zellen vorkommen.

Die Datentypen, um die Informationen zu speichern, wurden wie folgt ausgewählt: TINYINT wird verwendet, um

Boolean-Werte wie die Anzahl an Likes zu speichern. Dies ist der kleinstmögliche Datentyp in MySQL²⁰³ und wurde ausgewählt, um Speicherplatz zu sparen.

Kurze Texte wie Plattformnamen werden mittels des VARCHAR(20)-Datentyps, der 20 Zeichen umfasst,²⁰⁴ gespeichert. Die verwendeten Plattformen Mastodon und BlueSky haben jeweils nur acht bzw. sieben Zeichen. Sollten aber zukünftig andere Plattformen zur Datensammlung herangezogen werden, werden 20 Zeichen als flexibel genug eingeschätzt, um auch längere Plattformnamen vollständig erfassen zu können. Selbiges gilt für andere im Datenbankschema dargestellte Eigenschaften, die mittels diesem Datentyp gespeichert werden.

VARCHAR(255) wird für Daten verwendet, deren Länge variieren kann, z.B. bei IDs oder den einzelnen Optionsmöglichkeiten bei Umfragen. Diese maximale Länge von 255 Zeichen²⁰⁵ bietet eine hohe Flexibilität, ohne dabei zu viel Speicherplatz zu beanspruchen.

Der TEXT-Datentyp wird für längere Texte²⁰⁶ wie Beitragsinhalte und Account-Beschreibungen verwendet, um bei diesen bis zu 500 Zeichen langen Merkmalen (s. Kap. 6.4.2) trotzdem alle Informationen speichern zu können. Das DATETIME-Format²⁰⁷ wurde für Informationen ausgewählt, bei denen es sich um Zeitstempel handelt. In Mastodon und BlueSky erfolgen Zeitangaben i.d.R. mit Datum und Uhrzeit (vgl. z.B. Kap. 6.3). Es wurde davon abgesehen, die Zeitstempel auf das Datum zu reduzieren, da z.B. aus Kapitel 4 hervorgeht, dass Echtzeit-Daten für Social Media Analysen häufig besonders relevant sind.

Ansonsten basiert die Datenbank auf identifizierenden sowie nicht-identifizierenden 1:n-Beziehungen zwischen den Tabellen. Mehrere in separaten Tabellen gespeicherte Informationen (wie oben erklärt) sind dabei jeweils mit den Beiträgen oder Accounts verknüpft. Außerdem können zu einem Account mehrere Beiträge gehören, wodurch insgesamt eine klare Zuordnung aller erfassten Daten ermöglicht wird.

Für die Verknüpfungen zwischen Beiträgen und in ihnen enthaltenen Erwähnungen, Hashtags, antwortsbezogene Informationen sowie dynamischen Informationen wurden identifizierende 1:n-Beziehungen gewählt. Denn Einträge in diesen Tabelle könnten ohne die Existenz eines zugehörigen Beitrags kaum sinnvoll existieren. Beispielsweise macht es keinen Sinn, die Anzahl an Likes für einen Beitrag zu speichern, wenn nichts über den Rest des Beitrags bekannt ist. Auch die Speicherung über Erwähnungen eines Nutzers ist nicht sinnvoll, wenn nicht zusätzlich dazu erkenntlich ist, in welchem Beitrag bzw. Kontext er markiert wurde. Über die identifizierende Beziehung zwischen Beiträgen und Hashtags wird in Kapitel 6.5 noch diskutiert und es werden mögliche Verbesserungsvorschläge gegeben.

Auch für die Verknüpfungen zwischen Accounts mit den AccountMigrationen, den dynamischen Account Informationen und den als Schlüssel-Wert-Paare gespeicherten Informationen wurden identifizierende 1:n-Beziehungen verwendet. Denn ohne eindeutige Identität eines Accounts in der Datenbank macht es auch keinen Sinn, weitere Daten über ihn, wie die Anzahl seiner Follower, zu speichern.

Für die Verbindungen zwischen Beiträgen mit angehängten Umfragen und Medienanhängen wurden hingegen nicht-identifizierende 1:n-Beziehungen gewählt, da es für das ThWIC-Projekt sinnvoll sein kann, ein Medienanhang oder eine Umfrage zu speichern, obwohl der zugehörige Beitrag in der Datenbank nicht existiert oder durch Löschen dieses Beitrags nicht mehr existiert. Denn bei den in Kapitel 4 herausgearbeiteten Use Cases stellten sich Meinungsanalysen als besonders relevant heraus. Da ein Umfragen-Eintrag auch Informationen wie die einzelnen Wahlmöglichkeiten sowie die Anzahl an Stimmen für jede dieser Optionen beinhaltet (vgl. z.B. Tab. 6.6), kann sie ggf. trotz fehlendem zugehörigen Beitrag in einen Kontext eingeordnet werden und für Analysen verwendet werden. Aus den Kapiteln 1.1 und 4 geht hervor, dass auch Bilder aus Social Media Beiträgen verwendet werden

²⁰³Vgl. o.V. (o.J.): Integer Types, MySQL, Abrufdatum: 02.08.2024.

²⁰⁴Vgl. o.V. (o.J.): The CHAR and VARCHAR Types, MySQL, Abrufdatum: 02.08.2024.

²⁰⁵Vgl. o.V. (o.J.): The CHAR and VARCHAR Types, MySQL, Abrufdatum: 02.08.2024.

²⁰⁶Vgl. o.V. (o.J.): The BLOB and TEXT Types, MySQL, Abrufdatum: 02.08.2024.

²⁰⁷Vgl. o.V. (o.J.): The DATE, DATETIME, and TIMESTAMP Types, MySQL, Abrufdatum: 02.08.2024.

können, um beispielsweise vergangene Geschehnisse beurteilen und zusammenfassen zu können. In Kapitel 6.3.4 ist erklärt, dass für Medienanhänge wie Bilder stets die Informationen gespeichert werden, durch die der Anhang aufgefunden werden kann. Somit können auch weitere Informationen über den Medienanhang gesammelt werden, die evtl. wertvoll für das ThWIC-Projekt sind.

Weiterhin ist die Tabelle über die einzelnen Schlüsselwörter über eine nicht-identifizierende 1:n-Beziehung mit den Beiträgen verknüpft. Diese Beziehung ist sinnvoll, da die „categories“-Tabelle Schlüsselwörter und zugehörige Kategorien enthält, nach denen Beiträge gesucht und ihnen zugeordnet werden können. Sollte ein Beitrag jedoch keines der eingetragenen Schlüsselwörter enthalten, kann er dennoch in einen Kontext eingeordnet werden, beispielsweise durch die Bewertung seines Inhalts oder die Anzahl der Likes. Zudem existieren die Schlüsselwörter unabhängig davon, ob es in der Datenbank dazugehörige Beiträge gibt, da sie losgelöst von spezifischen Beiträgen definiert wurden (vgl. Kap. 1.2).

6.4.2 Kritik: Vergleichbarkeit von Mastodon- und BlueSky-Beiträgen

Dieses Kapitel gibt anhand einiger ausgewählter Merkmale Aufschluss darüber, inwieweit Mastodon- und BlueSky-Beiträge in einem wie eben dargestellten vereinheitlichten Datenbankschema tatsächlich miteinander vergleichbar sind. Es wird außerdem herausgestellt, wie Unterschiede zwischen den Plattformen und deren Beiträgen bei den möglichen Anwendungsfällen aus Kapitel 4 oder dem Recommendation System berücksichtigt werden sollten. Die hier betrachteten Unterschiede sind in folgender Tabelle übersichtlich dargestellt:

Unterschied	Mastodon	BlueSky
Gründungsjahr	2016	2021
Beitragslänge	Maximal 500 Zeichen	Maximal 300 Zeichen
Text-Repräsentation	HTML-Format	Rich Text Format
Privatsphäreinstellungen	Können vorgenommen werden	Alle Informationen sind öffentlich
Netzwerkstruktur	Föderation	(De-)Zentralisierung

Tabelle 6.7: Vergleich von Mastodon- und Bluesky-Beiträgen

Dazu wurde bereits erwähnt, dass beide Social Media Plattformen in unterschiedlichen Jahren gegründet wurden. Mastodon existiert bereits seit 2016, während BlueSky erst 2021 auf den Markt gebracht wurde (vgl. Kap. 6.1.1). Es muss also bedacht werden, dass keine BlueSky-Beiträge vor dem Jahr 2021 existieren können. Für Analysen über vergangene Ereignisse aus dem Zeitraum 2016 bis 2021 liegen also nur Informationen aus Mastodon vor und es muss insgesamt mit einer geringeren Datenmenge gerechnet werden. Das Problem mit der Datenmenge wird zusätzlich dadurch verschärft, dass die Nutzerzahlen von Mastodon damals geringer waren. Im Jahr 2021 hatte Mastodon erst ca. 2,7 Millionen Registrierungen.²⁰⁸ Im Jahr 2024 zählt Mastodon hingegen über 10 Millionen Registrierungen (vgl. Kap. 6.1.1).

Weiterhin haben die Beiträge beider Plattformen unterschiedliche maximale Längen. Mastodon-Beiträge können bis zu 500 Zeichen umfassen. Dies geht beispielsweise aus Abbildung 1 im Anhang hervor. Der dort verfasste Beitrag beinhaltet 42 Zeichen. Unten rechts ist angemerkt, dass noch weitere 458 Zeichen hinzugefügt werden könnten. Der BlueSky-Beitrag in Abbildung 6, ebenfalls im Anhang, hat hingegen eine Zeichenlänge von 37. Auch hier ist unten rechts die Anzahl an möglichen verbleibenden Zeichen angezeigt, die in diesem Fall 263 beträgt. Dieser Unterschied sollte bspw. berücksichtigt werden, wenn die absolute Textlänge als Indikator für die Wichtigkeit in Meinungsanalysen oder bei dem Ranking des Empfehlungssystems herangezogen wird. Andernfalls könnten BlueSky-Beiträge nicht die gleichen Ranking-Ergebnisse wie Mastodon-Beiträge erzielen, selbst dann nicht, wenn

²⁰⁸Vgl. Rochko, E. (2021): Mastodon Recap 2021, Mastodon, Abrufdatum: 04.08.2024.

sie eigentlich eine ähnliche oder sogar höhere Relevanz hätten.

Ein weiterer Unterschied bezüglich der Beiträge sind die für die Textdarstellung verwendeten Formate. Zur Darstellung von Mastodon-Beiträgen wird HTML verwendet. Die HTML-Elemente sind dabei direkt in den Text eingebunden. Dies geht beispielsweise aus Abbildung 2 im Anhang hervor. Hier ist der Inhalt des Beitrags durch die Eigenschaft „content“ gegeben (vgl. auch Kap. 6.2.1). Der Text wird direkt von den HTML-Elementen `<p>` und `</p>` umschlossen. Text in BlueSky-Beiträgen wird hingegen in Rich Text Format dargestellt. In dem „text“-Merkmal ist hier lediglich der reine Text hinterlegt (vgl. dazu auch Kap. 6.2.2). Dies ist beispielsweise in Abbildung 7 erkenntlich. Zur Darstellung des im Beitrag enthaltenen Links mittels Rich Text sind hier zusätzliche Informationen im „facets“-Merkmal enthalten. Falls der Inhalt der Beiträge also für Analysen verwendet werden soll, muss je nach in der Analyse anzuwendenden Methode überprüft werden, inwieweit die Inhalte vorverarbeitet werden müssen. Beispielsweise sollten die HTML-Elemente entfernt werden, wenn die Textlänge ermittelt und als Indikator für das Recommendation System herangezogen werden soll.

Es wurde bereits erklärt, dass in Mastodon Privatsphäreinstellungen vorgenommen werden können, was in BlueSky nicht der Fall ist. Dies sollte vor allem im Recommendation System berücksichtigt werden. Insbesondere falls bei einem Mastodon Account die „noindex“-Einstellung aktiviert ist, möchte dessen Nutzer nicht, dass seine Beiträge über Suchmaschinen aufgefunden werden können (vgl. z.B. Kap. 6.3.3, Abschnitt „noindex“). Also sollten Beiträge von diesem Account zum Schutz der Privatsphäre des Nutzers auch keinen weiteren Personen angezeigt werden und somit nicht von dem Recommendation System empfohlen bzw. ausgegeben werden.

Zuletzt muss angemerkt werden, dass der verwendete Mastodon Such-Endpunkt lediglich Beiträge zurückgibt, die auf der jeweiligen Instanz des anfragenden Accounts gespeichert sind. Dazu zählen Beiträge, die direkt auf dieser Instanz veröffentlicht wurden. Beiträge von anderen Instanzen werden nur zurückgegeben, wenn sie durch Aktionen wie das Folgen von Nutzern mit dieser Instanz verbunden sind. Der Grund dafür ist die föderierte Netzwerkstruktur von Mastodon (vgl. Kap. 6.1.3). Ziel der Entwickler von BlueSky ist es hingegen, eine dezentrale Netzwerkstruktur zu ermöglichen. Sie gilt derzeit allerdings noch als zentralisiert. Während von dem BlueSky Such-Endpunkt deswegen alle Beiträge zurückgegeben werden, die in dem Netzwerk veröffentlicht wurden, ist der Mastodon Such-Endpunkt auf die Beiträge der jeweiligen Instanz beschränkt. (vgl. Kap. 6.1.3) Insbesondere für Meinungsanalysen muss dahingehend berücksichtigt werden, dass die einzelnen Instanzen häufig bestimmte Themenbereiche abdecken, z.B. „Business“²⁰⁹ und somit teilweise bestimmte Bevölkerungsgruppen mit jeweils ähnlichen Meinungen anziehen.²¹⁰ Wird in Mastodon also lediglich eine Instanz zur Datengewinnung für Meinungsanalysen verwendet, kann es zu einer verzerrten Darstellung der Ergebnisse kommen.

6.5 Ausblick: Weiterentwicklungsmöglichkeiten

In diesem Kapitel wird dargelegt, wie die Datensammlung sowie das eben vorgestellte Datenbankschema (vgl. Kap. 6.4.1) weiterentwickelt werden kann. Dabei wird erst die Datensammlung betrachtet, anschließend werden konkrete Verbesserungsvorschläge für das Datenbankschema gegeben, die sich auf mögliche Anwendungen der Daten beziehen.

Ergänzende Möglichkeiten für die Datensammlung

Um zu vermeiden, Informationen lediglich einer Mastodon-Instanz von dem Such-Endpunkt zu erhalten, kann in Erwägung gezogen werden, weitere Accounts auf anderen Instanzen zu erstellen und auch von diesen aus die

²⁰⁹Vgl. o.V. (o.J.): Servers, Mastodon, Abrufdatum: 01.08.2024.

²¹⁰Vgl. o.V. (o.J.): Let me help you choose an instance, Mastodon instances, Abrufdatum: 01.08.2024.

Suchanfragen vorzunehmen. Obwohl die Suche nach Mastodon-Beiträgen mit Schlüsselwörtern erst seit September 2023 möglich ist,²¹¹ wurden bereits Forschungsbeiträge dazu veröffentlicht, mittels der Suchfunktionalität die Daten mehrerer Instanzen zu erfassen. Von Wiegmann, M. et al. (2024) wurden insgesamt 1.015 Mastodon-Instanzen verwendet. Von diesen sammelten sie innerhalb von 61 Tagen Informationen über 733 Millionen öffentliche Beiträge.²¹²

Außerdem wurde in Kapitel 6.3 an mehreren Stellen darauf hingewiesen, dass weitere BlueSky Endpunkte zur Datensammlung herangezogen werden können. Aus diesen könnten weitere Informationen über BlueSky-Beiträge erfasst werden, die ansonsten lediglich für Mastodon-Beiträge aus den verwendeten Such-Endpunkten hervorgehen. Dies kann beispielsweise für die Daten erfolgen, die im Datenbankschema als dynamische Account-Informationen zusammengefasst sind, wie etwa die Anzahl der Beiträge, die von einem Account veröffentlicht wurden (vgl. Abb. 6.1 und Kap. 6.3.3).

Um die in der ThWIC-Datenbank gespeicherten Informationen auf einem möglichst aktuellen Stand zu halten, wurde in den Kapiteln 6.3.1, 6.3.3 und 6.4.1 bereits vorgeschlagen, besonders die dynamischen Informationen über Beiträge und Accounts, also bspw. die Anzahl an Likes eines Beitrags oder die Anzahl an Followern eines Accounts, zu passenden Zeitpunkten zu aktualisieren. Geeignete Endpunkte hierfür wurden in den Kapiteln 6.3.1 und 6.3.3 bereits insbesondere zwecks der Auffindbarkeit einzelner Beiträge bzw. Accounts thematisiert. In Kapitel 6.4.1 wurde zusätzlich dazu angemerkt, dass es hierbei sinnvoll sein kann, die veralteten dynamischen Informationen nicht zu verwerfen, sondern weiterhin in der Datenbank zu speichern. Durch die Aufnahme eines Zeitstempels, der den jeweiligen Zeitpunkt enthält, zu dem die Daten jeweils aktualisiert wurden, würde eine Historie aus den aktualisierten Daten entstehen. Dadurch könnten also zusätzlich die Änderungen von für das ThWIC-Projekt relevanten Informationen analysiert werden. Dies würde auch einige in Kapitel 4 erklärten Anwendungsfälle, wie z.B. die Meinungsanalyse im Zeitverlauf, ermöglichen.

Verbesserungsmöglichkeiten des Datenbankschemas

Um das Datenbankschema effizienter zu gestalten und Speicherplatz zu sparen, können einige weitere Anpassungen vorgenommen werden. Wie genau diese Anpassungen letztlich aber umgesetzt werden sollten, hängt wesentlich von den Anwendungsfällen ab, für die die gesammelten Daten tatsächlich verwendet werden sollen. Einige Beispiele für solche möglichen Verbesserung bei der Wahl verschiedener Anwendungsfälle werden im Folgenden kurz erläutert. Unter anderem können die Hashtags sinnvoller gespeichert werden. Eine Möglichkeit wäre es, sie in die categories-Tabelle zu integrieren. Dadurch könnten Hashtags bestimmten Themen, Kategorien oder Schlüsselwörtern zugeordnet werden, was ggf. neue Assoziationen zwischen Inhalten ermöglicht. Beiträge könnten dadurch sowohl nach Themengebieten, Kategorien, Hashtags und Schlüsselwörtern effizient gefiltert werden. Eine weitere Option wäre es, Hashtags zur Identifizierung neuer Schlüsselwörter oder Hashtags zu nutzen, die speziell im Themengebiet Wasser in den Sozialen Medien verwendet werden. Denn wie in Kapitel 1.2 erwähnt, sind die bisher verwendeten Schlüsselwörter eher auf andere Quellen wie wissenschaftliche Artikel ausgerichtet. Für diesen Fall wäre es sinnvoll, für Hashtags eine „Koinzidenz-Tabelle“ anzulegen. In dieser könnten dann alle in einem Beitrag gemeinsam vorkommenden Hashtags als Einträge gespeichert werden.

Auch die Plattform- und Instanznamen der Account-Tabelle könnten in eine separate Tabelle ausgelagert werden, um Speicherplatz zu sparen und eine übersichtliche Darstellung aller verwendeten Plattformen und Instanzen zu ermöglichen. Besonders wegen der zurzeit noch zentralisierten Netzwerkstruktur von BlueSky wurde entschieden, vorerst keine separate Tabelle anzulegen, bis klar ist, ob diese Plattform zukünftig dezentrale Instanzen (besser) unterstützt (vgl. Kap. 6.1.3) und ob die Instanznamen somit überhaupt gespeichert werden müssen. Falls diese lediglich für Mastodon Accounts benötigt werden, kann in Erwägung gezogen werden, die Instanznamen mit in

²¹¹Vgl. Wiegmann, M. et al. (2024): A Mastodon Corpus to Evaluate Federated Microblog Search, S. 38.

²¹²Vgl. Wiegmann, M. et al. (2024): A Mastodon Corpus to Evaluate Federated Microblog Search, S. 37.

die Tabelle über die dynamischen Account-Informationen zu integrieren, da Mastodon Accounts ja ihre Instanzen wechseln können (vgl. Kap. 6.3.3, Abschnitt „moved“).

Je nach den Einträgen für die Schlüsselwerte in der Tabelle mit den Schlüssel-Wert-Paaren (vgl. 6.1, Tabelle „indexable_account_info“), können diese mit ihren zugehörigen Werten in separate Tabellen ausgelagert werden. Beispielsweise könnten Schlüsselwerte bezüglich geografischer Herkunft, wie „country“, „city“ oder „from“ identifiziert und in einer weiteren Tabelle gespeichert werden. Es wurde unter anderem herausgestellt, dass solche Informationen verwendet werden können, um zu analysieren, inwieweit sie die Meinungsbildung eines Nutzers beeinflussen (vgl. z.B. Kap. 4.1.2).

Die Datenbank kann also flexibel an zukünftige Anforderungen angepasst werden. Dahingehend bleibt abzuwarten, welche Anwendungsfälle letztlich tatsächlich bearbeitet werden sollen.

7 Schlussbetrachtung

Ziel der vorliegenden Arbeit war es, die Sammlung der Daten aus den Social Media Plattformen Mastodon und BlueSky umfassend vorzubereiten und aus unterschiedlichen Perspektiven zu betrachten.

Dafür wurde zunächst das Potenzial der Verwendung von Social Media Daten analysiert. Basierend darauf wurden Verwendungsmöglichkeiten für das ThWIC-Projekt vorgeschlagen. Mittels Literaturrecherche wurden hierfür Studien aus den Bereichen Landwirtschaft, Ethik, Regierung und Gesundheitsversorgung sowie Bildung untersucht. Aus diesen konnte abgeleitet werden, dass insbesondere Meinungsanalysen im Themenbereich Wasser für das ThWIC-Projekt nützlich sein können. So kann beispielsweise die Meinung von Social Media Nutzern über bestimmte Regierungsentscheidungen zum Thema Wasser analysiert werden. Im Rahmen von Meinungsanalysen können auch zusätzliche Informationen über den Verfasser des Beitrags, wie dessen Alter oder Wohnort, berücksichtigt werden. Dadurch kann nämlich auch analysiert werden, in welchem Umfang diese Informationen die Meinungsbildung ggf. beeinflussen.

Ebenso kann es sinnvoll sein, einige im Themenbereich Wasser relevante Persönlichkeiten zu identifizieren, die soziale Netzwerke nutzen, und speziell deren Ansichten zu untersuchen. Eventuell kann hierbei sogar ein Einfluss der Meinungen dieser Personen auf die allgemeine Bevölkerung beobachtet werden. Auch die Betrachtung dieser ausgewählten Nutzer über einen längeren Zeitraum kann von Interesse sein, um eventuelle Meinungsänderungen nach bestimmten Ereignissen nachvollziehen zu können.

Weiterhin können Stimmungsanalysen von Echtzeit-Daten dabei helfen, den Schweregrad von Katastrophen einzuschätzen und ggf. betroffene Gebiete zu identifizieren oder stark gefährdete Personen zu erreichen. In der Vergangenheit veröffentlichte Beiträge können zudem verwendet werden, um bestimmte Ereignisse im Kontext Wasser zusammenzufassen. Auch der Erfolg bzw. Misserfolg von Werbekampagnen im Bereich Wasser kann analysiert werden, um zukünftige Kampagnen gezielter gestalten zu können.

Als wesentliche Herausforderung bei der Verwendung von Social Media Daten gilt der aktuelle Rechtsstand zum Schutz personenbezogener Daten, der nach der DSGVO gewährleistet werden muss. Entsprechende Verordnungen und Gesetze wurden dahingehend analysiert. Dabei stellte sich heraus, dass die Datensammlung aus Mastodon und BlueSky trotzdem vorgenommen werden kann. Der Grund hierfür ist insbesondere, dass es sich bei dem ThWIC-Projekt um ein Forschungsprojekt handelt, das unter anderem von der Universität bearbeitet wird. Für Forschungsprojekte gelten einige weniger restriktive Ausnahmeregelungen. Trotzdem mussten geeignete Maßnahmen definiert werden, die bei Verwendung der Daten beachtet werden müssen, um einen guten Schutz von personenbezogenen Informationen gewährleisten zu können. Dazu gehört beispielsweise die Pseudonymisierung aller personenbezogenen Informationen, solange dies das Projekt nicht wesentlich beeinträchtigt. Die Sinnhaftigkeit der herausgearbeiteten Maßnahmen wurde auch in einem Gespräch mit der Datenschutzbeauftragten der Universität Jena bestätigt. Sollten die Daten aber für Zwecke außerhalb der Universität, wie der Weiterverarbeitung innerhalb eines Unternehmens, verwendet werden, so muss die rechtliche Lage dazu vorab erneut eingeschätzt werden und mit Datenschutzbeauftragten besprochen werden.

Anschließend wurden die Sozialen Netzwerke Mastodon und BlueSky als Twitter-Alternativen herausgestellt und

kurz erläutert. Insbesondere wurden auch die im praktischen Teil der Arbeit verwendeten Such-Endpunkte dieser beiden Plattformen hinsichtlich der Suche nach Schlüsselwörtern in öffentlichen Beiträgen erklärt. Hierbei muss insbesondere berücksichtigt werden, dass sich die Suche in Mastodon stets nur auf die jeweilige Instanz bezieht, von der aus die Suchanfrage durchgeführt wird.

Dann wurden die in den Response-Schemata beider Endpunkte enthaltenen Informationen über Beiträge erläutert. Für diese Daten wurde jeweils geprüft, ob sie für das ThWIC-Projekt von Relevanz sind und ob sich entsprechende Informationen mit Daten der anderen Plattform vergleichen und vereinheitlicht speichern lassen. Aus den relevanten Informationen wurde letztlich ein MySQL-Datenbankschema entworfen. Außerdem wurden die Einträge in die Datenbank vorgenommen. Das Vorgehen hierbei ist durch den der Arbeit beiliegenden Code ersichtlich.

Abschließend wurde ein kurzer Überblick über Unterschiede zwischen Mastodon und BlueSky gegeben, die bei Verwendung der gesammelten Daten beachtet werden sollten. Hierbei wurde auf die unterschiedlichen Gründungsjahre der Plattformen, unterschiedliche Beitragslängen, Text-Repräsentationen, Privatsphäreinstellungen sowie die Netzwerkstruktur hingewiesen. Es wurden Vorschläge für weiterführende Arbeiten gegeben, die eine umfangreichere Nutzung der Daten ermöglichen können.

Im Rahmen der Arbeit ist es somit gelungen, die wesentlichen Kriterien zur Zusammenführung von Social Media Daten unterschiedlicher Quellen aus mehreren Perspektiven zu analysieren und es wurden erste Schritte zur Realisierung der Datenbank erfolgreich durchgeführt.

Literaturverzeichnis

Ahmad, H./Alnsour, Y. (2018) Using social media analytics: The effect of President Trump's tweets on companies performance. CIG. Zu finden im Internet: https://cig.ase.ro/jcig/art/17_1_5.pdf (Abrufdatum: 08.06.2024)

Brooker, P. et al. (03.04.2018) Researching with Twitter timeline data. Sage Journals. Zu finden im Internet: <https://journals.sagepub.com/doi/full/10.1177/2053951718766624> (Abrufdatum: 06.06.2024)

Bünthe, O. (08.02.2024) Bluesky wächst um 850.000 Nutzer am ersten Tag nach Öffnung. Heise. Online: <https://www.heise.de/news/Bluesky-waechst-auf-ueber-4-Millionen-Nutzer-9622211.html> (Abrufdatum: 02.08.2024)

Chapekis, A./Smith, A. (17.05.2023) How U.S. adults on Twitter use the site in the Elon Musk era. Policy Commons. Zu finden im Internet: <https://policycommons.net/artifacts/3834920/how-us/4640766/> (Abrufdatum: 07.06.2024)

Dampz, N. (27.10.2023) Was von Twitter übrigblieb. tagesschau. Online: <https://www.tagesschau.de/wirtschaft/digitales/x-twitter-uebernahme-elon-musk-100.html> (Abrufdatum: 26.06.2024)

Dollarhide, M. (31.07.2024) Social Media. Investopedia. Online: <https://www.investopedia.com/terms/s/social-media.asp> (Abrufdatum: 05.08.2024)

Fathi, R. et al. (Juli 2020) VOST: A case study in voluntary digital participation for collaborative emergency management. ScienceDirect. Zu finden im Internet: <https://www.sciencedirect.com/science/article/abs/pii/S0306457319302316?via%3Dihub> (Abrufdatum: 05.06.2024)

Felt, M. (29.04.2016) Social media and the social sciences: How researchers employ Big Data analytics. Sage Journals. Zu finden im Internet: <https://journals.sagepub.com/doi/full/10.1177/2053951716645828> (Abrufdatum: 25.06.2024)

Golla, S./Hofmann, H./Bäcker, M. (28.01.2018): Connecting the Dots. Springer Link. Zu finden im Internet: <https://link.springer.com/article/10.1007/s11623-018-0900-x> (Abrufdatum: 12.06.2024)

Haric, P./Grüblbauer, J. (12.03.2016) Geopolitische Herausforderungen digitaler Souveränität im neo-imperialen Zeitalter und die Bedeutung von Qualitätsmedien. Springer Link. Zu finden im Internet: https://link.springer.com/chapter/10.1007/978-3-658-07349-7_15 (Abrufdatum: 25.06.2024)

Hemphill, L./Hedstrom, M./Leonard, S. (6.5.2019) How can we save social media data? University of Michigan

Library. Zu finden im Internet: <https://deepblue.lib.umich.edu/handle/2027.42/149013> (Abrufdatum: 02.08.2024)

Jäckle, A./Burton, J. (Dezember 2022) How and why does the mode of data collection affect consent to data linkage. ResearchGate. Zu finden im Internet: https://www.researchgate.net/publication/366290243_How_and_why_does_the_mode_of_data_collection_affect_consent_to_data_linkage

Kang, Y. et al. (Juli 2017) The public's opinions on a new school meals policy for childhood obesity prevention. ScienceDirect. Zu finden im Internet: <https://www.sciencedirect.com/science/article/pii/S1386505617300898?via%3Dihub> (Abrufdatum: 06.06.2024)

Kankanamge, N. et al. (Januar 2020) Determining disaster severity through social media analysis: Testing the methodology with South East Queensland Flood tweets. ScienceDirect. Zu finden im Internet: <https://www.sciencedirect.com/science/article/abs/pii/S2212420919307940?via%3Dihub> (Abrufdatum: 03.08.2024)

Kemp, S. (31.01.2024) Digital 2024: Global Overview Report. Datareportal. Online: <https://datareportal.com/reports/digital-2024-global-overview-report> (Abrufdatum: 23.07.2024)

Kim, H./Chae, B./Park, S. (21.08.2017) Exploring public space through social media. Springer Link. Zu finden im Internet: <https://link.springer.com/article/10.1057/s41289-017-0050-z> (Abrufdatum: 07.06.2024)

Liu, E. (28.04.2023) How to set your domain as your handle. Bluesky. Online: <https://bsky.social/about/blog/4-28-2023-domain-handle-tutorial> (Abrufdatum: 11.05.2024)

Maynard, D. et al. (Mai 2017) A framework for real-time semantic social media analysis. ScienceDirect. Zu finden im Internet: <https://www.sciencedirect.com/science/article/pii/S1570826817300240?via%3Dihub> (Abrufdatum: 06.06.2024)

Mehmet, M. et al. (01.01.2018) The public reaction to the carp control herpes virus in Australia. ScienceDirect. Zu finden im Internet: <https://www.sciencedirect.com/science/article/pii/S0301479718309708?via%3Dihub> (Abrufdatum: 06.06.2024)

Michaelidou, M./Micevski, M. (November 2019) Consumers ethical perceptions of social media analytics practices: Risks, benefits and potential outcomes. ScienceDirect. Zu finden im Internet: <https://www.sciencedirect.com/science/article/abs/pii/S0148296318306180?via%3Dihub> (Abrufdatum: 06.06.2024)

Murtefeldt, R. et al. (10.04.2024) RIP Twitter API. Semantic Scholar. Zu finden im Internet: <https://www.semanticscholar.org/paper/RIP-Twitter-API%3A-A-eulogy-to-its-vast-research-Murtefeldt-Alterman/70f43eba8f664d1d1fb8e17adc13b3317927c34c> (Abrufdatum: 07.06.2024)

O'Brien, C. (28.12.2023) How to Use Hashtags Effectively on Social Media. Digital Marketing Institute. Online: <https://digitalmarketinginstitute.com/blog/how-to-use-hashtags-in-social-media> (Abrufdatum: 02.08.2024)

o.V. (25.10.2019) URI: der Uniform Resource Identifier erklärt. IONIOS. Online: <https://www.ionos.de/digitalguide/websites/web-entwicklung/uniform-resource-identifier/> (Abrufdatum: 10.05.2024)

o.V. (10.07.2023) Voting/Polls support. GitHub. Online: <https://github.com/bluesky-social/atproto/discussions/1310> (Abrufdatum: 03.08.2024)

o.V. (22.02.2024) An Open Social Web. BlueSky. Online: <https://bsky.social/about/blog/02-22-2024-open-social-web> (Abrufdatum: 07.07.2024)

o.V. (15.03.2024) Bluesky's Moderation Architecture. Bluesky. Online: <https://docs.bsky.app/blog/bluesky-s-moderation-architecture> (Abrufdatum: 11.05.2024)

o.V. (06.05.2024) Ranking der größten Social Networks und Messenger nach der Anzahl der Nutzer im Januar 2024. Statista. Online: <https://de.statista.com/statistik/daten/studie/181086/umfrage/die-weltweit-groessten-social-networks-nach-anzahl-der-user/> (Abrufdatum: 14.05.2024)

o.V. (31.07.2024) Social Media Trends – Welche Plattformen sind am beliebtesten. Statista. Online: <https://de.statista.com/themen/1842/soziale-netzwerke/#topicOverview> (Abrufdatum: 01.08.2024)

o.V. (15.09.2024) Rate Limits, PDS Distribution v3, and More. BlueSky. Online: <https://docs.bsky.app/blog/rate-limits-pds-v3> (Abrufdatum: 07.07.2024)

o.V. (o.J.): § 1 BDSG. Intersoft Consulting. Online: <https://dsgvo-gesetz.de/bdsg/1-bdsg/> (Abrufdatum: 09.05.2024)

o.V. (o.J.) 4 key differences between Twitter and Mastodon. Opensource. Online: <https://opensource.com/article/22/11/twitter-vs-mastodon> (Abrufdatum: 03.08.2024)

o.V. (o.J.) Account. Mastodon. Online: <https://docs.joinmastodon.org/entities/Account/> (Abrufdatum: 20.07.2024)

o.V. (o.J.) accounts API methods. Mastodon. Online: <https://docs.joinmastodon.org/methods/accounts/> (Abrufdatum: 25.07.2024)

o.V. (o.J.) app.bsky.actor.defs. The AT Protocol SDK. Online: https://atproto.blue/en/latest/atproto/atproto_client.models.app.bsky.actor.defs.html (Abrufdatum: 11.05.2024)

o.V. (o.J.) app.bsky.actor.getProfile. Bluesky. Online: <https://docs.bsky.app/docs/api/app-bsky-actor-get-profile> (Abrufdatum: 23.07.2024)

o.V. (o.J.) app.bsky.actor. The ATProtocol. Online: https://atproto.blue/en/latest/atproto/atproto_client.models.app.bsky.actor.html (Abrufdatum: 26.07.2024)

o.V. (o.J.) app.bsky.embed.external. The AT Protocol SDK. Online: https://atproto.blue/en/latest/atproto/atproto_client.models.app.bsky.embed.external.html (Abrufdatum: 25.07.2024)

o.V. (o.J.) app.bsky.embed. The AT Protocol SDK. Online: https://atproto.blue/en/latest/atproto/atproto_client.models.app.bsky.embed.html (Abrufdatum: 27.07.2024)

o.V. (o.J.) app.bsky.feed.defs. The AT Protocol SDK. Online: https://atproto.blue/en/latest/atproto/atproto_client.models.app.bsky.feed.defs.html (Abrufdatum: 01.05.2024)

o.V. (o.J.) app.bsky.feed.getActorLikes. Bluesky. Online: <https://docs.bsky.app/docs/api/app-bsky-feed-get-actor-likes> (Abrufdatum: 03.08.2024)

o.V. (o.J.) app.bsky.feed.post. The AT Protocol SDK. Online: https://atproto.blue/en/latest/atproto/atproto_client.models.app.bsky.feed.post.html (Abrufdatum: 10.05.2024)

o.V. (o.J.) app.bsky.feed.searchPosts. Bluesky. Online: <https://docs.bsky.app/docs/api/app-bsky-feed-search-posts> (Abrufdatum: 10.05.2024)

o.V. (o.J.) app.bsky.richtext.facet. The AT Protocol SDK. Online: https://atproto.blue/en/latest/atproto/atproto_client.models.app.bsky.richtext.facet.html (Abrufdatum: 13.05.2024)

o.V. (o.J.) Applications model. ATProtocol. Online: <https://atproto.com/guides/applications/#appbskyfeed-repost> (Abrufdatum: 23.06.2024)

o.V. (o.J.) Art. 1 DSGVO. Intersoft Consulting. Online: <https://dsgvo-gesetz.de/art-1-dsgvo/> (Abrufdatum: 09.05.2024)

o.V. (o.J.) Art. 2 DSGVO. Intersoft Consulting. Online: <https://dsgvo-gesetz.de/art-2-dsgvo/> (Abrufdatum: 11.05.2024)

o.V. (o.J.) Art. 4 DSGVO. Intersoft Consulting. Online: <https://dsgvo-gesetz.de/art-4-dsgvo/> (Abrufdatum: 11.05.2024)

o.V. (o.J.) Art. 9 DSGVO. Intersoft Consulting. Online: <https://dsgvo-gesetz.de/art-9-dsgvo/> (Abrufdatum: 11.05.2024)

o.V. (o.J.) AT Protocol DIDs. ATProtocol. Online: <https://atproto.com/specs/did> (Abrufdatum: 10.05.2024)

o.V. (o.J.) AT URI Scheme. ATProtocol. Online: <https://atproto.com/specs/at-uri-scheme> (Abrufdatum: 11.05.2024)

o.V. (o.J.) BDSG. Intersoft Consulting. Online: <https://dsgvo-gesetz.de/bdsg/> (Abrufdatum: 10.05.2024)

o.V. (o.J.) Bellingcat auf Deutsch. Bellingcat. Online: <https://de.bellingcat.com/> (Abrufdatum: 28.06.2024)

o.V. (o.J.) Bluesky App Privacy Policy. Bluesky. Online: <https://bsky.social/about/support/privacy-policy> (Abrufdatum: 14.07.2024)

o.V. (o.J.) Bluesky App Privacy Policy: HOW WE USE PERSONAL INFORMATION. Bluesky. Online: <https://bsky.social/about/support/privacy-policy#personal-information-use> (Abrufdatum: 11.05.2024)

o.V. (o.J.) Bluesky App Privacy Policy: SUPPLEMENTAL NOTICE FOR CERTAIN JURISDICTIONS. Bluesky. Online: <https://bsky.social/about/support/privacy-policy#supplement-jurisdiction> (Abrufdatum: 11.05.2024)

o.V. (o.J.) Bluesky. Crunchbase. Online: <https://www.crunchbase.com/organization/bluesky-514d> (Abrufdatum: 02.08.2024)

o.V. (o.J.) Bluesky Post Count and Author Stats. Jaz Bluesky Index. Online: <https://bsky.jazco.dev/stats> (Abrufdatum: 02.08.2024)

o.V. (o.J.) com.atproto.label.defs. The AT Protocol SDK. Online: https://atproto.blue/en/latest/atproto/atproto_client.models.com.atproto.label.defs.html (Abrufdatum: 14.05.2024)

o.V. (o.J.) com.atproto.repo.getRecord. Bluesky. Online: <https://docs.bsky.app/docs/api/com-atproto-repo-get-record> (Abrufdatum: 29.06.2024)

o.V. (o.J.) com.atproto.repo.listRecords. Bluesky. Online: <https://docs.bsky.app/docs/api/com-atproto-repo-list-records> (Abrufdatum: 30.07.2024)

o.V. (o.J.) com.atproto.sync.get_blob. The AT Protocol SDK. Online: https://atproto.readthedocs.io/en/latest/atproto/atproto_client.models.com.atproto.sync.get_blob.html (Abrufdatum: 01.08.2024)

o.V. (o.J.) Creating a post. Bluesky. Online: <https://docs.bsky.app/docs/tutorials/creating-a-post> (Abrufdatum: 14.06.2024)

o.V. (o.J.) CustomEmoji. Mastodon. Online: <https://docs.joinmastodon.org/entities/CustomEmoji/> (Abrufdatum: 06.04.2024)

o.V. (o.J.) Data Model. ATProtocol. Online: <https://atproto.com/specs/data-model> (Abrufdatum: 11.05.2024)

o.V. (o.J.) Data Privacy. Bluesky. Online: <https://blueskyweb.zendesk.com/hc/en-us/articles/15835264007693-Data-Privacy> (Abrufdatum: 14.07.2024)

o.V. (o.J.) defs.json. GitHub. Online: <https://github.com/bluesky-social/atproto/blob/main/lexicons/app/bsky/actor/defs.json> (Abrufdatum: 11.05.2024)

o.V. (o.J.) DSGVO. Intersoft Consulting. Online: <https://dsgvo-gesetz.de/> (Abrufdatum: 09.05.2024)

o.V. (o.J.) Filter. Mastodon. Online: <https://docs.joinmastodon.org/entities/Filter/> (Abrufdatum: 02.08.2024)

o.V. (o.J.) Handle. ATProtocol. Online: <https://atproto.com/specs/handle> (Abrufdatum: 11.05.2024)

o.V. (o.J.) Integer Types. MySQL. Online: <https://dev.mysql.com/doc/refman/8.4/en/integer-types.html> (Abrufdatum: 02.08.2024)

o.V. (o.J.) I would like you to implement a flag for bot accounts. GitHub. Online: <https://github.com/bluesky-social/atproto/issues/2167> (Abrufdatum: 25.07.2024)

o.V. (o.J.) Labels. ATProtocol. Online: <https://atproto.com/specs/label> (Abrufdatum: 11.05.2024)

o.V. (o.J.) LDSG. Intersoft Consulting. Online: <https://dsgvo-gesetz.de/ldsg/> (Abrufdatum: 09.05.2024)

o.V. (o.J.) Let me help you choose an instance. Mastodon instances. Online: <https://instances.social/> (Abrufdatum: 01.08.2024)

o.V. (o.J.) Links, mentions, and rich text. Bluesky. Online: <https://docs.bsky.app/docs/advanced-guides/post-richtext> (Abrufdatum: 10.05.2024)

o.V. (o.J.) media API methods. Mastodon. Online: <https://docs.joinmastodon.org/methods/media/> (Abrufdatum: 30.07.2024)

o.V. (o.J.) MediaAttachment. Mastodon. Online: <https://docs.joinmastodon.org/entities/MediaAttachment/#type> (Abrufdatum: 07.04.2024)

o.V. (o.J.) MH17 Die Beweise aus öffentlichen Quellen. Bellingcat. Zu finden im Internet: <https://www.bellingcat.com/app/uploads/2015/10/MH17-The-Open-Source-Evidence-DEU.pdf> (Abrufdatum: 04.07.2024)

o.V. (o.J.) Moderation actions. Mastodon. Online: <https://docs.joinmastodon.org/admin/moderation/> (Abrufdatum: 15.07.2024)

o.V. (o.J.) Moving or leaving accounts. Mastodon. Online: <https://docs.joinmastodon.org/user/moving/> (Abrufdatum: 10.07.2024)

o.V. (o.J.): Obtaining client app access. Mastodon. Online: <https://docs.joinmastodon.org/client/token/> (Abrufdatum: 07.07.2024)

o.V. (o.J.) Poll. Mastodon. Online: <https://docs.joinmastodon.org/entities/Poll/> (Abrufdatum: 03.08.2024)

o.V. (o.J.) polls API methods. Mastodon. Online: <https://docs.joinmastodon.org/methods/polls/> (Abrufdatum: 03.08.2024)

o.V. (o.J.) Posting to your profile. Mastodon. Online: <https://docs.joinmastodon.org/user/posting/> (Abrufdatum: 17.07.2024)

o.V. (o.J.) Posts. Bluesky. Online: <https://docs.bsky.app/docs/advanced-guides/posts> (Abrufdatum: 21.05.2024)

o.V. (o.J.) Privacy Policy. Mastodon Social. Online: <https://mastodon.social/privacy-policy> (Abrufdatum: 13.05.2024)

o.V. (o.J.) profile.json. GitHub. Online: <https://github.com/bluesky-social/atproto/blob/main/lexicons/app/bsky/actor/profile.json> (Abrufdatum: 11.05.2024)

o.V. (o.J.) Protocol Overview. ATProtocol. Online: <https://atproto.com/guides/overview> (Abrufdatum: 10.05.2024)

o.V. (o.J.): Rate limits. Mastodon. Online: <https://docs.joinmastodon.org/api/rate-limits/> (Abrufdatum: 07.07.2024)

o.V. (o.J.) Record Keys. ATProtocol. Online: <https://atproto.com/specs/record-key> (Abrufdatum: 11.05.2024)

o.V. (o.J.) search API methods. Mastodon. Online: <https://docs.joinmastodon.org/methods/search/> (Abrufdatum: 18.07.2024)

o.V. (o.J.) Search. Mastodon. Online: <https://docs.joinmastodon.org/entities/Search/> (Abrufdatum: 29.07.2024)

o.V. (o.J.) Server. Mastodon. Online: <https://joinmastodon.org/de/servers> (Abrufdatum: 02.08.2024)

o.V. (o.J.) Servers. Mastodon. Online: <https://joinmastodon.org/servers> (Abrufdatum: 01.08.2024)

o.V. (o.J.) Setting up your profile. Mastodon. Online: <https://docs.joinmastodon.org/user/profile/> (Abrufdatum: 05.08.2024)

o.V. (o.J.) Set your preferences. Mastodon. Online: <https://docs.joinmastodon.org/user/preferences/> (Abrufdatum: 05.08.2024)

o.V. (o.J.) statuses API methods. Mastodon. Online: <https://docs.joinmastodon.org/methods/statuses/#boost> (Abrufdatum: 03.08.2024)

o.V. (o.J.) Status. Mastodon. Online: <https://docs.joinmastodon.org/entities/Status/> (Abrufdatum: 02.08.2024)

o.V. (o.J.) The AT Protocol. ATProtocol. Online: <https://atproto.com/> (Abrufdatum: 03.08.2024)

o.V. (o.J.) The BLOB and TEXT Types. MySQL. Online: <https://dev.mysql.com/doc/refman/8.4/en/blob.html> (Abrufdatum: 02.08.2024)

o.V. (o.J.) The CHAR and VARCHAR Types. MySQL. Online: <https://dev.mysql.com/doc/refman/8.4/en/char.html> (Abrufdatum: 02.08.2024)

o.V. (o.J.) The DATE, DATETIME, and TIMESTAMP Types. MySQL. Online: <https://dev.mysql.com/doc/refman/8.4/en/datetime.html> (Abrufdatum: 02.08.2024)

o.V. (o.J.) Thread gates. Bluesky. Online: <https://docs.bsky.app/docs/tutorials/thread-gates> (Abrufdatum: 16.05.2024)

o.V. (o.J.) Thüringer Wasser-Innovationscluster. Friedrich-Schiller-Universität Jena. Online: <https://www.thwicc.uni-jena.de/> (Abrufdatum: 14.06.2024)

o.V. (o.J.) Timestamps. Bluesky. Online: <https://docs.bsky.app/docs/advanced-guides/timestamps> (Abrufdatum: 10.05.2024)

o.V. (o.J.) Translation. Mastodon. Online: https://docs.joinmastodon.org/entities/Translation/#spoiler_text (Abrufdatum: 02.08.2024)

o.V. (o.J.) Using the network features. Mastodon. Online: <https://docs.joinmastodon.org/user/network/> (Abrufdatum: 16.07.2024)

o.V. (o.J.) We develop Mastodon. Mastodon. Online: <https://joinmastodon.org/de/about> (Abrufdatum: 02.08.2024)

o.V. (o.J.) Welcome to the social internet. Bluesky. Online: <https://bsky.social/about> (Abrufdatum: 02.08.2024)

o.V. (o.J.) What is a CID. IPFS. Online: <https://docs.ipfs.tech/concepts/content-addressing/#what-is-a-cid> (Abrufdatum: 11.05.2024)

o.V. (o.J.) What is Mastodon. Mastodon. Online: <https://docs.joinmastodon.org> (Abrufdatum: 02.08.2024)

o.V. (o.J.) X API. X Developer Platform. Online: <https://developer.x.com/en/products/twitter-api> (Abrufdatum: 24.06.2024)

Ozturkcan, S. et al. (12.07.2017) An analysis of the Gezi Park social movement tweets. emerald insight. Zu finden im Internet: <https://www.emerald.com/insight/content/doi/10.1108/AJIM-03-2017-0064/full/html> (Abrufdatum: 06.06.2024)

Park, D./Kim, W./Choi, S. (29.07.2018) Application of social media analytics in tourism crisis communication. Taylor & Francis. Zu finden im Internet: <https://www.tandfonline.com/doi/full/10.1080/13683500.2018.1504900> (Abrufdatum: 05.06.2024)

Pilař, L. et al. (2018): Questionnaire vs. Social Media Analysis - Case Study of Organic Food. AgEcon. Zu finden im Internet: <https://ageconsearch.umn.edu/record/281648?v=pdf> (Abrufdatum: 06.06.2024)

Ragini, J./Anand, R./Bhaskar, V. (März 2018) Mining crisis information: A strategic approach for detection of people at risk through social media analysis. ScienceDirect. Zu finden im Internet: <https://www.sciencedirect.com/science/article/abs/pii/S2212420917303485?via%3Dihub> (Abrufdatum: 05.06.2024)

Rochko, E. (08.12.2021) Mastodon Recap 2021. Mastodon. Online: <https://blog.joinmastodon.org/2021/12/>

mastodon-recap-2021/ (Abrufdatum: 04.08.2024)

Schwartmann, R./Ohr, S. (2015) Recht der Sozialen Medien. C.F. Müller. Zu finden im Internet: <https://books.google.de/books?id=vvPDCAAQBAJ&lpg=PR5&dq=arten%20sozialer%20medien&lr&hl=de&pg=PR3#v=onepage&q&f=false> (Abrufdatum: 25.07.2024)

Singh, P. et al. (16.04.2019) Smart Monitoring and Controlling of Government Policies Using Social Media and Cloud Computing. Springer Link. Zu finden im Internet: <https://link.springer.com/article/10.1007/s10796-019-09916-y> (Abrufdatum: 03.08.2024)

Whittingham, N./Boecker, A./Grygorcyk (07.04.2019): Personality traits, basic individual values and GMO risk perception of twitter users. Taylor & Francis. Zu finden im Internet: <https://www.tandfonline.com/doi/full/10.1080/13669877.2019.1591491> (Abrufdatum: 06.06.2024)

Widemar, N. et al. (06.06.2020) Public Perceptions of Veterinarians from Social and Online Media Listening. MDPI. Zu finden im Internet: <https://www.mdpi.com/2306-7381/7/2/75> (Abrufdatum: 06.06.2024)

Wiegmann, M. et al. (2024) A Mastodon Corpus to Evaluate Federated Microblog Search. WOWS 2024. Zu finden im Internet: <https://djoerdhiemstra.com/wp-content/uploads/wows2024proceedings.pdf#page=43> (Abrufdatum: 03.08.2024)

Wilkins, A. (06.02.2024) Bluesky ist jetzt für alle offen. Heise. Online: <https://www.heise.de/news/Bluesky-ist-jetzt-fuer-alle-offen-9620717.html> (Abrufdatum: 02.08.2024)

Xu, Z. et al. (23.12.2016): Building the Multi-Modal Storytelling of Urban Emergency Events Based on Crowdsensing of Social Media Analytics. Springer Link. Zu finden im Internet: <https://link.springer.com/article/10.1007/s11036-016-0789-2> (Abrufdatum: 05.06.2024)

Zachlod, C. et al. (Mai 2022) Analytics of social media data - State of characteristics and application. ScienceDirect. Zu finden im Internet: <https://www.sciencedirect.com/science/article/pii/S0148296322001321> (Abrufdatum: 29.07.2024)

Anhang

subject	category	keywords
water conflict	water scarcity water security water crisis transboundary conflict	
water management	economics	water market water trade water privatization water pricing
	management	clean water water consumption water use water transfer
	accounting	water footprint water quality clean water fresh water resources
water and social justice	water governance public participation	
water knowledge	water literacy	ocean literacy river literacy lake literacy

Tabelle 1: Schlüsselwörter, Themen und Kategorien im ThWIC-Projekt




Abbildung 1: Erstellung eines Mastodon-Beitrags mit Sichtbarkeitsstufe „quiet public“ („unlisted“)

```

{
  "id": "112326101948116650",
  "created_at": "2024-04-24T12:04:55.840Z",
  "in_reply_to_id": null,
  "in_reply_to_account_id": null,
  "sensitive": false,
  "spoiler_text": "",
  "visibility": "unlisted",
  "language": "en",
  "uri": "https://mastodon.social/users/bachjubo/statuses/112326101948116650",
  "url": "https://mastodon.social/@bachjubo/112326101948116650",
  "replies_count": 0,
  "reblogs_count": 0,
  "favourites_count": 0,
  "edited_at": null,
  "favourited": false,
  "reblogged": false,
  "muted": false,
  "bookmarked": false,
  "pinned": false,
  "content": "<p>We should strive to combat water scarcity!</p>",
  "filtered": [],
  "reblog": null,
  "application": {
    "name": "Web",
    "website": null
  }
}

```



```

{
  "account": {
    "id": "111386477186250961",
    "username": "bachjubo",
    "acct": "bachjubo",
    "display_name": "",
    "locked": false,
    "bot": false,
    "discoverable": null,
    "indexable": false,
    "group": false,
    "created_at": "2023-11-10T00:00:00.000Z",
    "note": "",
    "url": "https://mastodon.social/@bachjubo",
    "uri": "https://mastodon.social/users/bachjubo",
    "avatar": "https://mastodon.social/avatars/original/missing.png",
    "avatar_static": "https://mastodon.social/avatars/original/missing.png",
    "header": "https://mastodon.social/headers/original/missing.png",
    "header_static": "https://mastodon.social/headers/original/missing.png",
    "followers_count": 0,
    "following_count": 0,
    "statuses_count": 2,
    "last_status_at": "2024-04-24",
    "hide_collections": null,
    "noindex": false,
    "emojis": [],
    "roles": [],
    "fields": []
  },
  "media_attachments": [],
  "mentions": [],
  "tags": [],
  "emojis": [],
  "card": null,
  "poll": null
}

```

Abbildung 2: Mastodon-Beitrag mit „unlisted“ Sichtbarkeitsstufe wird öffentlich aufgefunden

```

{
  "id": "103270115826048975",
  "created_at": "2019-12-08T03:48:33.901Z",
  "in_reply_to_id": null,
  "in_reply_to_account_id": null,
  "sensitive": false,
  "spoiler_text": "",
  "visibility": "public",
  "language": "en",
  "uri": "https://mastodon.social/users/Gargron/statuses/103270115826048975",
  "url": "https://mastodon.social/@Gargron/103270115826048975",
  "replies_count": 5,
  "reblogs_count": 6,
  "favourites_count": 11,
  "favourited": false,
  "reblogged": false,
  "muted": false,
  "bookmarked": false,
  "content": "<p>&quot;I lost my inheritance with one wrong digit on my sort
↪ code&quot;</p><p><a href=\"https://www.theguardian.com/money/2019/dec/07/i-los
↪ t-my-193000-inheritance-with-one-wrong-digit-on-my-sort-code\" rel=\"nofollow
↪ noopener noreferrer\" target=\"_blank\"><span
↪ class=\"invisible\">https://www.</span><span
↪ class=\"ellipsis\">theguardian.com/money/2019/dec</span><span
↪ class=\"invisible\">/07/i-lost-my-193000-inheritance-with-one-wrong-digit-on-m
↪ y-sort-code</span></p>",
  "reblog": null,
  "application": {
    "name": "Web",
    "website": null
  },
},
"account": {
  "id": "1",
  "username": "Gargron",
  "acct": "Gargron",
  "display_name": "Eugen",
  "locked": false,
  "bot": false,
  "discoverable": true,
  "group": false,
  "created_at": "2016-03-16T14:34:26.392Z",
  "note": "<p>Developer of Mastodon and administrator of mastodon.social. I post
↪ service announcements, development updates, and personal stuff.</p>",
  "url": "https://mastodon.social/@Gargron",
  "avatar": "https://files.mastodon.social/accounts/avatars/000/000/001/original/d
↪ 96d39a0abb45b92.jpg",
  "avatar_static": "https://files.mastodon.social/accounts/avatars/000/000/001/ori
↪ ginal/d96d39a0abb45b92.jpg",
  "header": "https://files.mastodon.social/accounts/headers/000/000/001/original/c
↪ 91b871f294ea63e.png",
  "header_static": "https://files.mastodon.social/accounts/headers/000/000/001/ori
↪ ginal/c91b871f294ea63e.png",

```

```

"followers_count": 322930,
"following_count": 459,
"statuses_count": 61323,
"last_status_at": "2019-12-10T08:14:44.811Z",
"emojis": [],
"fields": [
  {
    "name": "Patreon",
    "value": "<a href=\"https://www.patreon.com/mastodon\" rel=\"me nofollow
↳ noopener noreferrer\" target=\"_blank\"><span
↳ class=\"invisible\">https://</span><span
↳ class=\"\">patreon.com/mastodon</span><span class=\"invisible\"></span>\"",
    "verified_at": null
  },
  {
    "name": "Homepage",
    "value": "<a href=\"https://zeonfederated.com\" rel=\"me nofollow noopener
↳ noreferrer\" target=\"_blank\"><span
↳ class=\"invisible\">https://</span><span
↳ class=\"\">zeonfederated.com</span><span class=\"invisible\"></span>\"",
    "verified_at": "2019-07-15T18:29:57.191+00:00"
  }
]
},
"media_attachments": [],
"mentions": [],
"tags": [],
"emojis": [],
"card": {
  "url": "https://www.theguardian.com/money/2019/dec/07/i-lost-my-193000-inheritan_
↳ ce-with-one-wrong-digit-on-my-sort-code",
  "title": "I lost my 193,000 inheritance with one wrong digit on my sort code",
  "description": "When Peter Teichs money went to another Barclays customer, the
↳ bank offered 25 as a token gesture",
  "type": "link",
  "author_name": "",
  "author_url": "",
  "provider_name": "",
  "provider_url": "",
  "html": "",
  "width": 0,
  "height": 0,
  "image": null,
  "embed_url": ""
},
"poll": null
}

```

Abbildung 3: Beispiel für einen Mastodon-Beitrag („Post“)

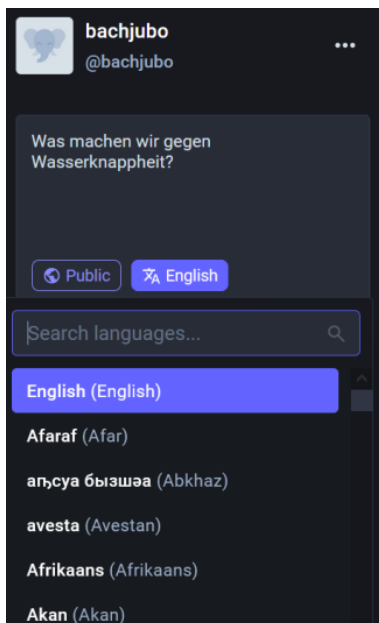


Abbildung 4: Die primäre Sprache eines Mastodon-Beitrags ist per default Englisch




Abbildung 5: Festgelegte Sprache für einen Beitrag wird von Mastodon nicht überprüft

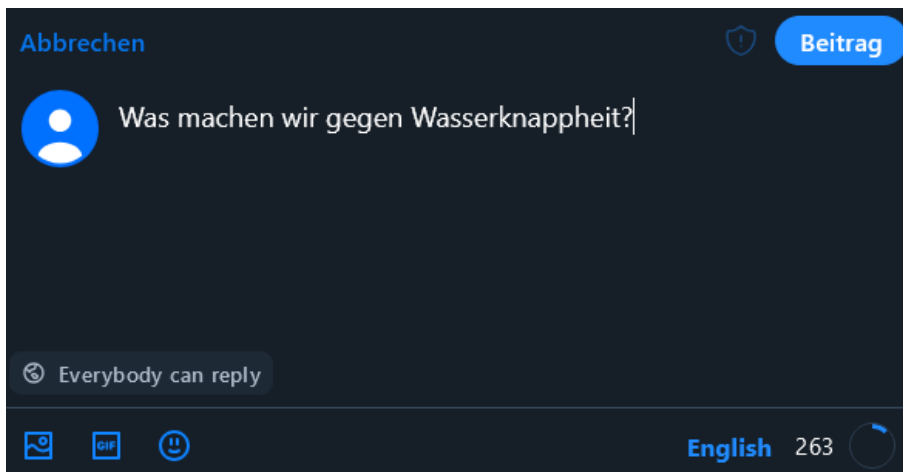


Abbildung 6: Die primäre Sprache eines BlueSky-Beitrags ist per default Englisch

```
{
  "uri": "at://did:plc:crijktj4e6fu54ohlmitfbit/app.bsky.feed.post/3ky463jlx7x2e",
  "cid": "bafyreiea6ssiynt5ftkzuq24fkqaoavqam7adnbayxzjjxokf657tji",
  "author": {
    "did": "did:plc:crijktj4e6fu54ohlmitfbit",
    "handle": "jubo.bsky.social",
    "viewer": {
      "muted": false,
      "blockedBy": false
    },
    "labels": [],
    "createdAt": "2023-12-01T16:27:53.777Z"
  },
  "record": {
    "$type": "app.bsky.feed.post",
    "createdAt": "2024-07-25T11:51:14.235Z",
    "langs": [
      "en"
    ],
    "text": "Was machen wir gegen Wasserknappheit?"
  },
  "replyCount": 0,
  "repostCount": 0,
  "likeCount": 0,
  "indexedAt": "2024-07-25T11:51:13.712Z",
  "viewer": {
    "threadMuted": false
  },
  "labels": []
},
```

Abbildung 7: Festgelegte Sprache für einen Beitrag wird von BlueSky nicht überprüft

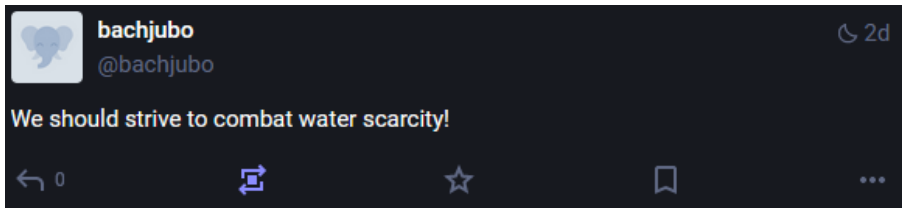


Abbildung 8: Eigener Mastodon-Beitrag wurde geboostet




Abbildung 9: Reposts erscheinen nicht in Mastodon Suche

BASIC INFORMATION									
Display name Your full name or your fun name.	Extra fields Your homepage, pronouns, age, anything you want.								
	<table border="1"> <tr> <td>Label</td> <td>Content</td> </tr> <tr> <td>Label</td> <td>Content</td> </tr> <tr> <td>Label</td> <td>Content</td> </tr> <tr> <td>Label</td> <td>Content</td> </tr> </table>	Label	Content	Label	Content	Label	Content	Label	Content
Label	Content								
Label	Content								
Label	Content								
Label	Content								
Bio You can @mention other people or #hashtags.	<table border="1"> <tr> <td>Label</td> <td>Content</td> </tr> <tr> <td>Label</td> <td>Content</td> </tr> <tr> <td>Label</td> <td>Content</td> </tr> <tr> <td>Label</td> <td>Content</td> </tr> </table>	Label	Content	Label	Content	Label	Content	Label	Content
Label	Content								
Label	Content								
Label	Content								
Label	Content								

Abbildung 10: Profil in Mastodon erstellen: Beschreibung („Bio“) und Metadaten („Extra fields“) werden separat angegeben

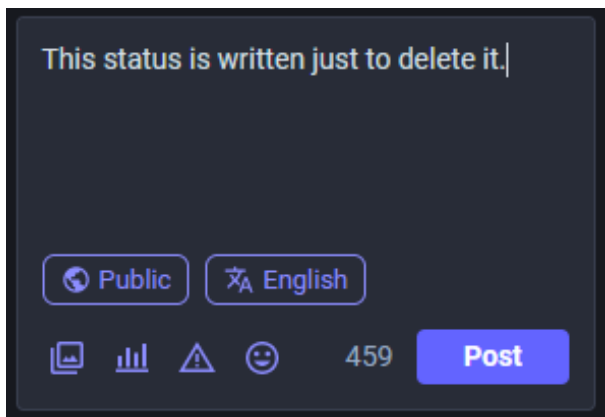


Abbildung 11: Erstellung eines Mastodon-Beitrags, der für ein Experiment wieder gelöscht wird




Abbildung 12: Erstellter Beitrag wurde über Such-Request aufgefunden

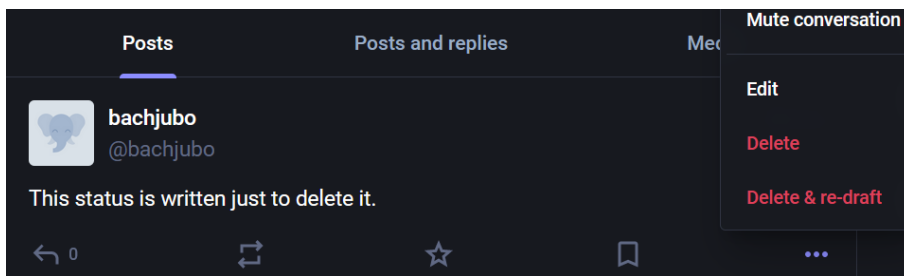


Abbildung 13: Mastodon-Beitrag löschen

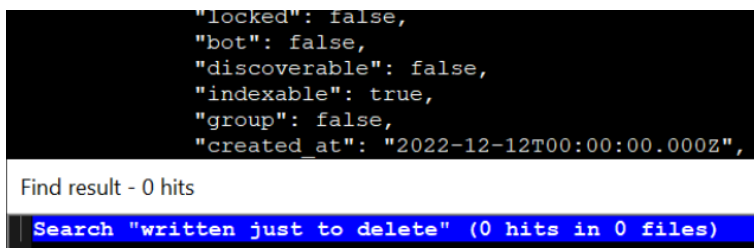


Abbildung 14: Mastodon-Beitrag wurde tatsächlich gelöscht

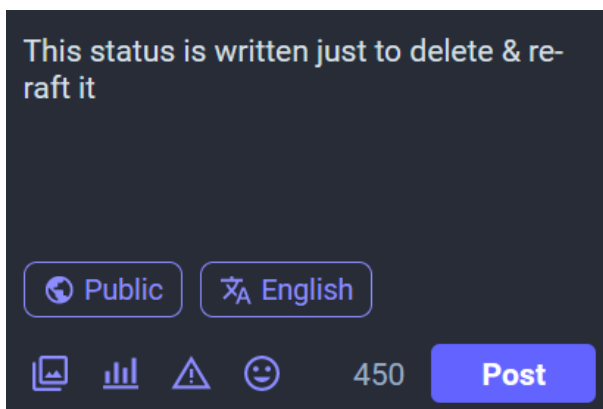


Abbildung 15: Delete & re-draft: Mastodon-Beitrag erstellen




Abbildung 16: Mastodon-Beitrag mit Such-Endpunkt aufgefunden

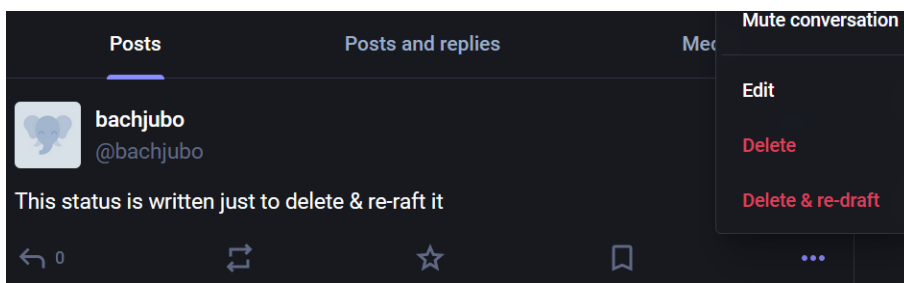


Abbildung 17: Delete & re-draft: Mastodon-Beitrag

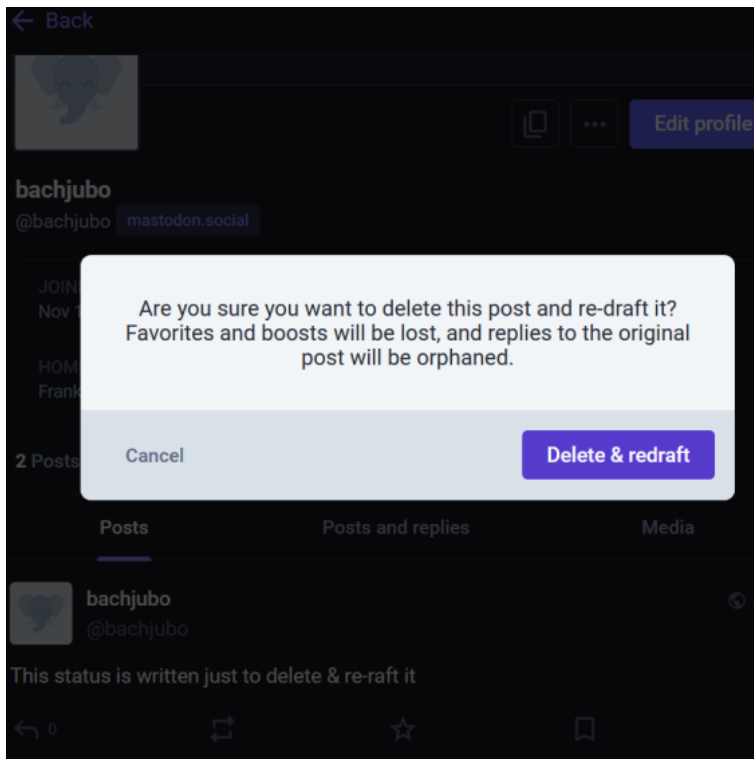


Abbildung 18: Delete & re-draft: Warnung

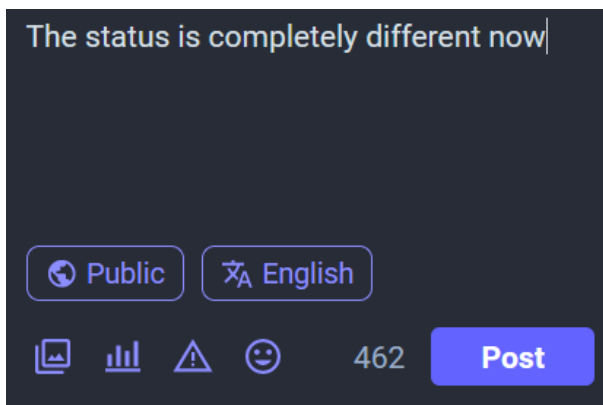


Abbildung 19: Re-drafting des Mastodon-Beitrags




Abbildung 20: Delete & re-draft: ursprünglicher Beitrag nicht mehr auffindbar

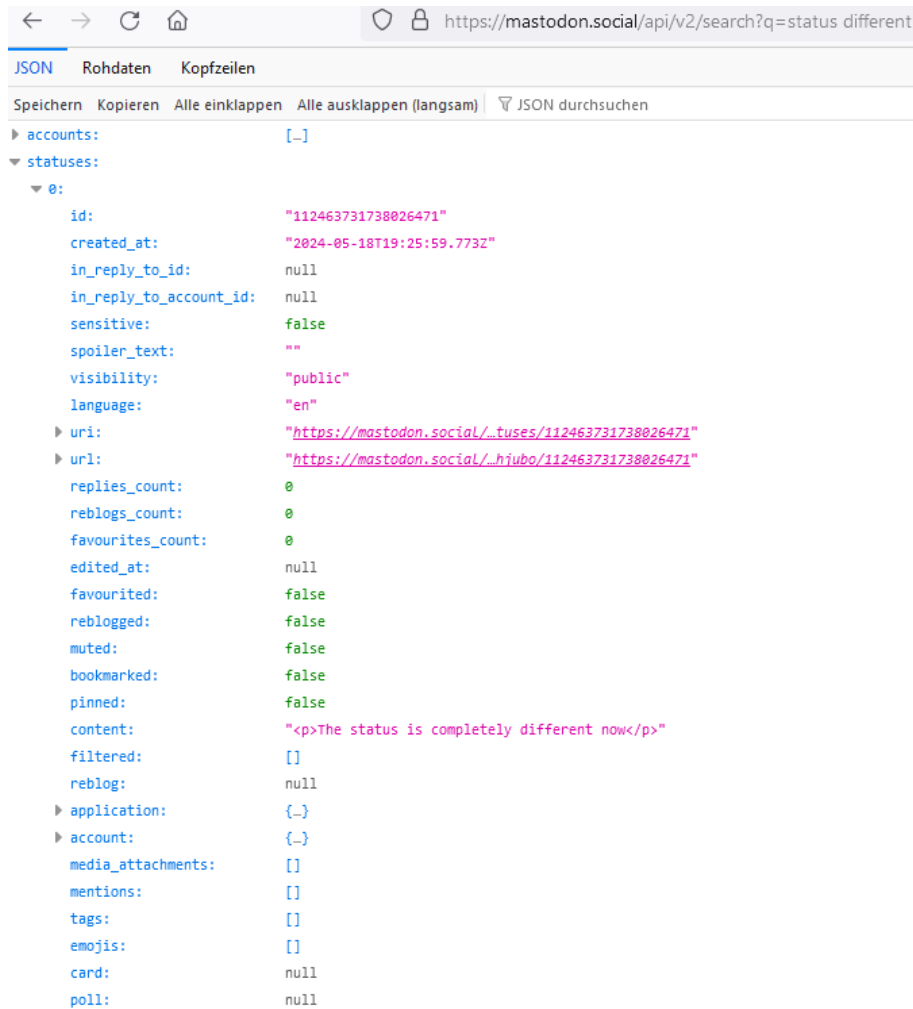


Abbildung 21: Delete & re-draft: neuer Beitrag ist über Keyword-Suche auffindbar




Abbildung 22: Delete & re-draft: ursprünglicher Beitrag nicht auffindbar




Abbildung 23: Migrating: Test Account erstellt

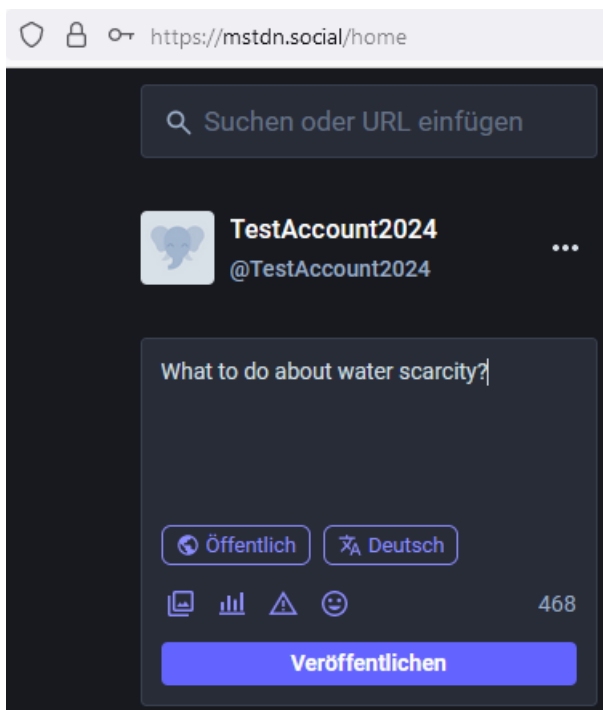


Abbildung 24: Migrating: Beitrag erstellen




Abbildung 25: Migrating: Beitrag ist auffindbar




Abbildung 26: Migrating: Alias erstellen



Account migration

Your account is not redirecting to any other account currently.

Move to a different account

Before proceeding, please read these notes carefully:

- This action will move all followers from the current account to the new account
- Your current account's profile will be updated with a redirect notice and be excluded from searches
- No other data will be moved automatically
- The new account must first be configured to back-reference this one
- After moving there is a waiting period during which you will not be able to move again
- Your current account will not be fully usable afterwards. However, you will have access to data export as well as re-activation.

Alternatively, you can [only put up a redirect on your profile](#).

Handle of the new account *
Specify the username@domain of the account you want to move to

Current password *
For security purposes please enter the password of the current account

Move followers

Moving from a different account

To move from another account to this one, first you need to [create an account alias](#).

Abbildung 27: Migrating

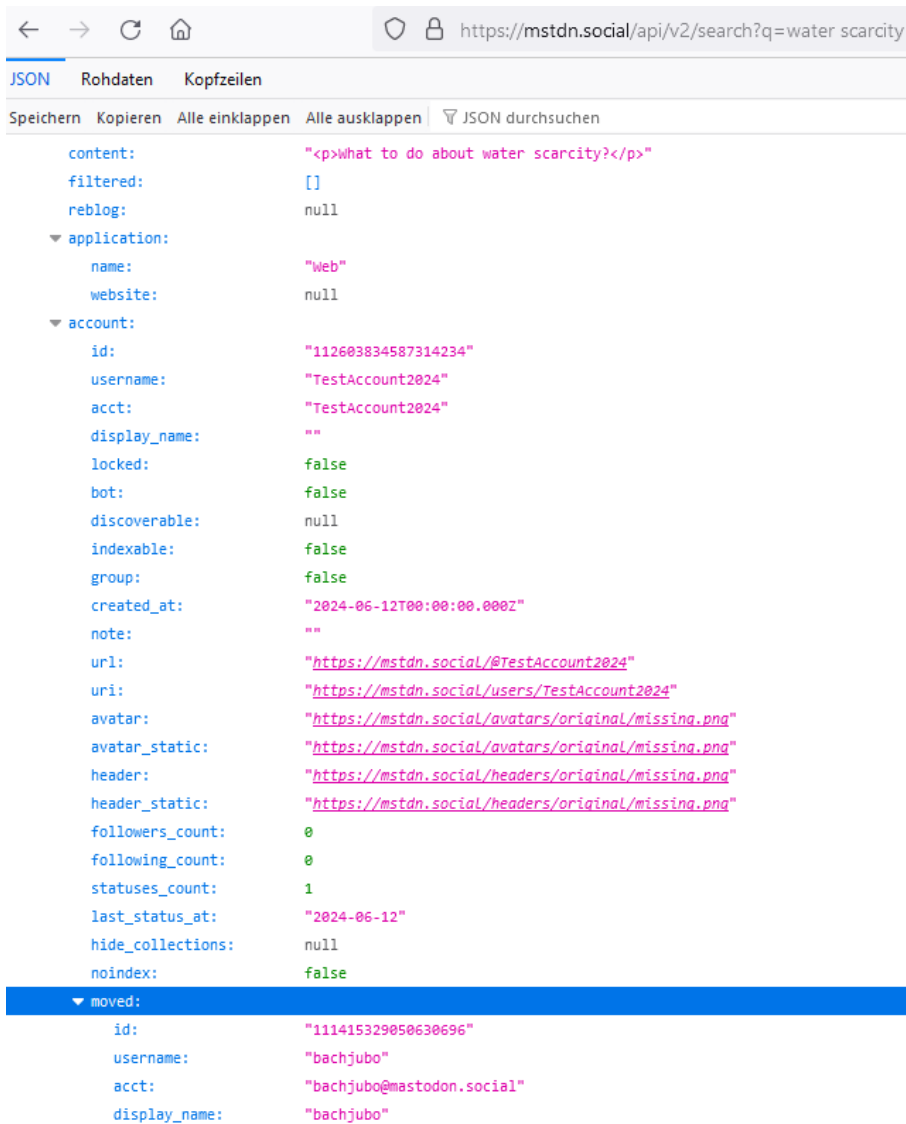


Abbildung 28: Migrating: moved-Informationen werden angezeigt




Abbildung 29: Migrating: ID nicht gefunden

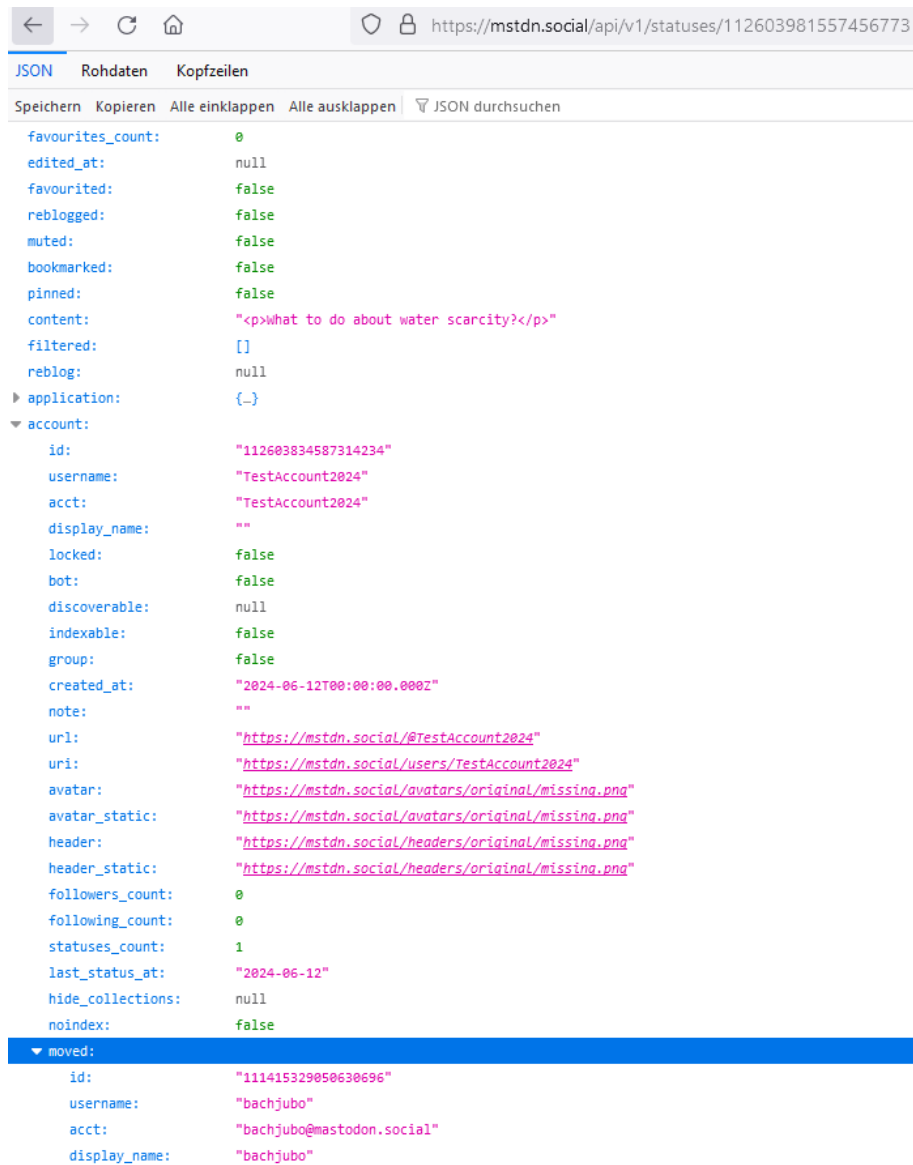


Abbildung 31: Migrating: Such-Endpunkt kann noch verwendet werden




Abbildung 32: Migrating: Account mit ursprünglicher Domain auffindbar

← → ↺ 🏠 🔒 🔒 https://mstdn.social/api/v1/accounts/112603834587314234	
JSON	Rohdaten Kopfzeilen
Speichern Kopieren Alle einklappen Alle ausklappen 🔍 JSON durchsuchen	
id:	"112603834587314234"
username:	"TestAccount2024"
acct:	"TestAccount2024"
display_name:	""
locked:	false
bot:	false
discoverable:	null
indexable:	false
group:	false
created_at:	"2024-06-12T00:00:00.000Z"
note:	""
url:	"https://mstdn.social/@TestAccount2024"
uri:	"https://mstdn.social/users/TestAccount2024"
avatar:	"https://mstdn.social/avatars/original/missing.png"
avatar_static:	"https://mstdn.social/avatars/original/missing.png"
header:	"https://mstdn.social/headers/original/missing.png"
header_static:	"https://mstdn.social/headers/original/missing.png"
followers_count:	0
following_count:	0
statuses_count:	1
last_status_at:	"2024-06-12"
hide_collections:	null
noindex:	false
▼ moved:	
id:	"111415329050630696"
username:	"bachjubo"
acct:	"bachjubo@mastodon.social"

Abbildung 33: Migrating: Informationen mittels ursprünglicher Domain und ID

```

CREATE TABLE accounts (
    account_id VARCHAR(255) PRIMARY KEY,
    is_bot BOOLEAN,
    created_at DATETIME,
    description TEXT,
    noindex BOOLEAN,
    limited BOOLEAN,
    from_platform VARCHAR(20),
    instance_name VARCHAR(255)
);

CREATE TABLE account_indexable_info (
    account_id VARCHAR(255),
    key_name VARCHAR(255) NOT NULL,
    value VARCHAR(255),
    PRIMARY KEY (account_id, key_name),
    FOREIGN KEY (account_id) REFERENCES accounts(account_id)
);

CREATE TABLE account_dynamic_info (
    account_id VARCHAR(255),
    followers_count INT,
    following_count INT,
    statuses_count INT,
    last_status_at DATETIME,
    PRIMARY KEY (account_id),
    FOREIGN KEY (account_id) REFERENCES accounts(account_id)
);

CREATE TABLE categories (
    category_id INT AUTO_INCREMENT,
    subject VARCHAR(255),
    keyword_category VARCHAR(255),
    keywords VARCHAR(255),
    PRIMARY KEY (category_id)
);

CREATE TABLE account_migrations (
    old_account_id VARCHAR(255),
    new_account_id VARCHAR(255),
    PRIMARY KEY (old_account_id, new_account_id),
    FOREIGN KEY (old_account_id) REFERENCES accounts(account_id),
    FOREIGN KEY (new_account_id) REFERENCES accounts(account_id)
);

CREATE TABLE posts (
    post_id VARCHAR(255) PRIMARY KEY,
    created_at DATETIME,
    visibility VARCHAR(20),
    content TEXT,
    edited_at DATETIME,
    keyword_category_id INT,
    date_collected_for_thwic DATETIME,
    account_id VARCHAR(255),
    FOREIGN KEY (account_id) REFERENCES accounts(account_id),
    FOREIGN KEY (keyword_category_id) REFERENCES categories(category_id)
);

```

```

CREATE TABLE replies (
    post_id VARCHAR(255),
    in_reply_to_id VARCHAR(255),
    related_to_post_id VARCHAR(255),
    in_reply_to_account_id VARCHAR(255),
    related_to_account_id VARCHAR(255),
    PRIMARY KEY (post_id),
    FOREIGN KEY (post_id) REFERENCES posts(post_id)
);

CREATE TABLE posts_dynamic_info (
    post_id VARCHAR(255),
    replies_count INT,
    reposts_count INT,
    likes_count INT,
    is_sensitive BOOLEAN,
    PRIMARY KEY (post_id),
    FOREIGN KEY (post_id) REFERENCES posts(post_id)
);

CREATE TABLE post_hashtags (
    post_id VARCHAR(255),
    hashtag VARCHAR(255),
    PRIMARY KEY (post_id, hashtag),
    FOREIGN KEY (post_id) REFERENCES posts(post_id)
);

CREATE TABLE post_mentions (
    post_id VARCHAR(255),
    mentioned_account_id VARCHAR(255),
    from_instance VARCHAR(255),
    PRIMARY KEY (post_id, mentioned_account_id),
    FOREIGN KEY (post_id) REFERENCES posts(post_id)
);

CREATE TABLE post_polls (
    poll_id VARCHAR(255) PRIMARY KEY,
    poll_expires_at DATETIME,
    multiple_choice BOOLEAN,
    votes_count INT,
    voters_count INT,
    option_titles VARCHAR(255),
    votes_for_options VARCHAR(255),
    post_id VARCHAR(255) UNIQUE,
    CONSTRAINT fk_polls_posts FOREIGN KEY (post_id) REFERENCES posts(post_id)
);

CREATE TABLE post_media_attachments (
    id_attachment VARCHAR(255) PRIMARY KEY,
    from_id VARCHAR(255),
    attachment_type VARCHAR(20),
    post_id VARCHAR(255),
    FOREIGN KEY (post_id) REFERENCES posts(post_id)
);

```

Abbildung 34: SQL-Befehle zum Erstellen der Datenbank

Eigenständigkeitserklärung

1. I hereby confirm that this work is my own work and that I have not used any sources or resources other than those referenced. I take responsibility for the quality of this text and its content and have ensured that all information and arguments provided are substantiated with or supported by appropriate academic sources. I have clearly identified and fully referenced any material such as text passages, thoughts, concepts or graphics that I have directly or indirectly copied from the work of others or my own previous work. Except where stated otherwise by reference or acknowledgement, the work presented is my own in terms of copyright.

2. I understand that this declaration also applies to generative AI tools which cannot be cited (hereinafter referred to as “generative AI”). I understand that the use of generative AI is not permitted unless the examiner has explicitly authorized its use (Declaration of Permitted Resources). Where the use of generative AI was permitted, I confirm that I have only used it as a resource and that this work is largely my own original work. I take full responsibility for any AI-generated content I included in my work. Where the use of generative AI was permitted to compose this work, I have acknowledged its use in a separate appendix. This appendix includes information about which AI tool was used or a detailed description of how it was used in accordance with the requirements specified in the examiner’s Declaration of Permitted Resources. I have read and understood the requirements contained therein and any use of generative AI in this work has been acknowledged accordingly (e.g. type, purpose and scope as well as specific instructions on how to acknowledge its use).

3. I also confirm that this work has not been previously submitted in an identical or similar form to any other examination authority in Germany or abroad, and that it has not been previously published in German or any other language.

4. I am aware that any failure to observe the aforementioned points may lead to the imposition of penalties in accordance with the relevant examination regulations. In particular, this may include that my work will be classified as deception and marked as failed. Repeated or severe attempts to deceive may also lead to a temporary or permanent exclusion from further assessments in my degree programme.

Ort, Datum

Name, Unterschrift